

博士論文

ウェブサイト最適化問題の定式化と解法に関する研究

指導教員 松尾 豊 特任准教授

東京大学大学院 工学系研究科
技術経営戦略学専攻

飯塚修平

This page is intentionally left blank.

概要

ウェブサービスは私たちの生活にとって身近なものになっている。私たちは日常的に情報収集のために Google や Yahoo!をはじめとする検索サービスを活用し、物品の購入に Amazon や楽天をはじめとする E コマースサービスを活用している。ウェブサイトは、ウェブサービスにおいてサービスとユーザのコミュニケーションの媒体となる重要な存在である。ウェブサービスを運営する各企業は、ユーザにとってより魅力的なウェブサイトを構築することでウェブサービスの収益性を改善することができる。特に、ユーザにサービスを提供したときの反応の違いを観測することで、より企業活動の上で望ましい状態にサービスを改善する活動は**ウェブサイト最適化**と呼ばれている。

ウェブサイト最適化では、あらかじめウェブサイトの一部を変更したバリエーションを用意し、それぞれに訪問ユーザを振り分け、その反応の違いを比較することで最も望ましい反応を引き出すバリエーションを探索する。たとえばある商品を販売するウェブサイトを対象とするならば、商品を購入するボタンの文言を変える、商品写真を変えるなどの変更を施することで、よりユーザの購買率を高めるウェブサイトのデザインを発見することができると考えられる。デザイン上のわずかな変更でも、ユーザ行動には大きな違いをもたらすことが知られており、低コストで高い効果を得ることができるウェブサイトの改善方法としてウェブサイト最適化は注目を集めている。集客、広報、販売など様々な側面でウェブが活用されている今、ウェブサイト最適化は業種にかかわらずあらゆる企業にとって重要な企業活動のひとつである。

しかし、企業がウェブサイト最適化を実施する上で課題になるのが、ウェブサイト最適化の高速化である。すなわちできるだけ少ないユーザ数で最適なウェブサイトの状態を獲得することである。市場経済のなかで企業活動を営む限りそこには市場競争があり、各企業はより高速にサービスの業績を向上することが求められている。したがって、ウェブサイトが企業活動に

において重要な役割を担っている以上、高速なウェブサイト最適化を実現し、収益向上のスピードを向上することは重要な課題である。

ここで、ウェブサイト最適化を様々なバリエーション候補の中から、クリック率や購買率などの目的指標を最大化するバリエーションを探索する行為であると考えれば、バリエーションを解としたひとつの数理的最適化問題として捉えることができる。高速なウェブサイト最適化を実現することは、より少ない解の評価回数で最適解を発見する性能の良い最適化手法を構築することに相当する。ノーフリーランチ定理でも示されているとおり、ある最適化問題において高速に動作する最適化手法を編み出すには、その問題の特性を捉えることが本質的に重要である。そこで本研究では、ウェブサイトとユーザの相互作用に起因する特性を活用した、ウェブサイト最適化問題の定式化および最適化手法を提案し、高速なウェブサイト最適化を実現することを目的とする。

一般に、最適化問題は $x^* = \arg \max_{x \in X} f(x)$ を満たす最適解 x^* を求める問題として表される。この定式化に着目すると、高速な最適化手法を編み出すための問題領域は大きく探索方法 ($\arg \max$ に相当する部分)、評価関数 ($f(x)$ に相当する部分)、解空間 (X に相当する部分) の 3 つに分けて考えることができる。各論ではそれぞれの部分について工夫を施すことで、高速なウェブサイト最適化手法を構築する。

第一研究では、探索方法の設計問題に取り組む。ウェブサイトを様々な要素の組み合わせとして表現したときに、それぞれの要素間には交互作用すなわち非線形性が発生することが考えられるが、十分に距離が離れた要素や性質が異なる要素についてはユーザの認知に影響を与える、交互作用が無視できるほど小さいかもしれない。そこで第一研究では、一部の要素間の効果に非線形性があり、他方には線形性を仮定できるような評価関数に対して高速に動作する最適化手法を提案する。実際のウェブサイトから得られたログデータによるシミュレーションおよび実際のウェブサイトへの導入実験を通して評価した結果、提案手法を用いることで既存手法よりも少ないユーザ数で最適なバリエーションを発見できることが確かめられた。

第二研究では、評価関数の設計問題に取り組む。最適化問題における評価関数として、分散が小さいものを採用することは高速な最適化のために重要であるが、ウェブサイトの目的によっては評価指標の分散が大きくなってしまうことも考えられる。そのような場合でも、目的となる評価指標を予測する指標をユーザの様々な行動の変化から読み取ることができれば、そ

れを活用することで探索を高速化できるかもしれない。そこで第二研究では、ウェブサイトを表示したときにユーザから得られる即時的なフィードバックを手がかりとすることで、分散が大きい評価指標に対しても高速に最適なバリエーションを発見する手法を提案する。実際のウェブサイトから得られたログデータをもとにシミュレーションを行った結果、既存手法よりも高速に最適なバリエーションを発見できることが示された。さらに、探索時に構築されたモデルを用いることで、未知のバリエーションに対しても最適なバリエーションを推定できることが確かめられた。

第三研究では、探索対象となる解空間の絞り込みに工夫を導入することによる高速化に取り組む。ウェブサイト最適化でテストされるバリエーションはウェブデザイナやウェブエンジニアによって人手で制作されることが多く、このことがウェブサイト最適化による仮説検証サイクルの自動化への障壁となっている。これは言い換えると、人間の直感にもとづいて有望な解を絞り込んでいることに相当する。この作業を自動化することができれば、より一層高速なウェブサイト最適化を実現できる可能性がある。そこで第三研究では、ウェブ上の事例を用いて膨大な仮説空間の中から有望な解を絞り込み、ウェブサイト最適化を高速化する手法を提案して評価する。評価実験では、提案手法を実際のバリエーション生成システムとして実装し、ウェブサイト最適化に適したバリエーションを生成できることをアンケート調査によつて評価した。その結果、提案手法によってユーザの行動をより喚起するバリエーションを提示できることが示された。

ウェブサイト最適化をある人工物の最適化に利用するための条件は、提供する人工物がインターネットをはじめとする何らかのネットワークによって事業者と結びついており、任意のタイミングで修正の反映、およびその修正に対するユーザの反応が計測できることである。この条件が満たされれば、ウェブサイト最適化の手法を応用することで、より効果的に人間の認知および行動に働きかける製品およびサービスを作り上げることができる。今後 IoT (Internet of Things) 技術の進展とともにウェブサイトに限らず様々なハードウェアがインターネットに接続されるようになると、私たちの身の回りの様々な製品およびサービスが事業者のコントロール下に置かれるようになるかもしれない。本研究の提案手法は、そのような時代における製品およびサービスの改善を考える上で、重要な役割を果たすものになると考えている。

目次

第1章 序論	1
1.1 研究の背景	1
1.1.1 ウェブサイト最適化の重要性とその定義	1
1.1.2 ウェブサイト最適化の高速化への課題	6
1.2 本研究の目的	7
1.3 本論文の構成	8
第2章 関連研究	11
2.1 ウェブサイト最適化の起源	11
2.1.1 実験計画法	11
2.1.2 ソフトウェア開発手法の変遷	13
2.1.3 データに基づくサービス改善に関する関連研究	20
2.2 数理最適化	22
2.2.1 数理最適化問題の概要	22
2.2.2 数理最適化問題の類型	23
2.2.3 ウェブサイト最適化問題の位置づけ	27
2.2.4 ソフトウェア開発手法と数理最適化の関連	29
2.3 探索手法にまつわる既存研究	30
2.3.1 メタヒューリスティクス	31
2.3.2 バンディット問題とバンディットアルゴリズム	32
2.3.3 ウェブサイト最適化への応用	38

2.3.4	本節のまとめ	39
2.4	評価指標にまつわる既存研究	40
2.4.1	ノイズの問題	40
2.4.2	観測に時間がかかる問題	41
2.5	解空間にまつわる既存研究	44
2.5.1	ウェブページの解析	44
2.5.2	ウェブページの生成	45
2.6	ウェブサイト最適化の実装手法	47
2.6.1	バリエーションの割り当て方法	47
2.6.2	代表的なウェブサイト最適化ツール	49
第3章	線形性仮定と局所探索を組み合わせた探索手法の提案	52
3.1	本章の背景と目的	52
3.1.1	既存のウェブサイト最適化手法	55
3.1.2	既存のウェブサイト最適化手法の整理	56
3.2	提案手法	57
3.2.1	局所探索法を用いた解法	57
3.2.2	線形性仮定を導入した解法	58
3.2.3	動的サンプル割り当てを導入した解法	61
3.3	評価実験	62
3.3.1	比較検討するアルゴリズム	62
3.3.2	仮想の評価関数によるシミュレーション実験	63
3.3.3	大規模ウェブサイトでのシミュレーション実験	65
3.3.4	小規模ウェブサイトにおける導入実験	68
3.4	考察	71
3.4.1	提案手法の適用可能性と限界	71
3.4.2	実験計画法との関係	73
3.4.3	文脈付きバンディット問題との関係	73
3.4.4	実用化に向けて	74

3.5	まとめ	75
第4章 ユーザからのフィードバックを活用した評価関数の設計手法		76
4.1	本章の背景と目的	76
4.2	関連研究	79
4.2.1	分散低減法	79
4.2.2	予測モデルによる目的指標の予測	81
4.3	提案手法	84
4.3.1	フィードバック付きウェブサイト最適化問題の定式化	85
4.3.2	フィードバック指標に対するベイズ最適化の利用	86
4.4	評価実験	89
4.4.1	ウェブサイト最適化の高速化の評価	91
4.4.2	未知のバリエーションに対する推定	93
4.5	考察	97
4.6	まとめ	99
第5章 ウェブページの文脈を用いた有望な解候補の生成方法		101
5.1	本章の背景と目的	101
5.2	関連研究	105
5.3	提案手法	106
5.4	実験結果	109
5.4.1	実装方法	110
5.4.2	定性的評価	111
5.4.3	交差検証による定量的評価	112
5.4.4	アンケート調査による定量的評価	113
5.5	考察	115
5.5.1	提案手法の適用可能性	115
5.5.2	より汎用的なバリエーション生成に向けて	117
5.6	まとめ	118

第 6 章 考察	119
6.1 各論の総括	119
6.2 ウェブサイト最適化システム全体における各論の位置づけ	120
6.3 提案手法の適用可能性とその限界	123
6.3.1 複数のウェブページにまたぐ最適化	123
6.3.2 数値化が困難な評価指標	124
6.3.3 様々な種類のウェブサイトに対する最適化	125
6.4 ウェブサイト以外への応用可能性	128
6.4.1 仮説検証のための条件	128
6.4.2 製品とサービスの性質の違い	130
6.4.3 まとめ	134
第 7 章 結論	136
付録 A Imagerous バリエーション例	138
謝辞	140
参考文献	142
発表文献	151

図目次

1.1	2008 年アメリカ合衆国大統領選挙にて、バラック・オバマ氏公式ウェブサイトの実験で用いられた写真とボタンのバリエーション	5
1.2	本論文の構成	9
2.1	ウォーターフォール・モデルの概観	14
2.2	アジャイル開発モデルの概観	15
2.3	リーンスタートアップ・モデルにおける BML サイクルの概観	18
2.4	既存のソフトウェア開発手法の概観	19
2.5	Bricolage によるテンプレートとコンテンツの入れ替え（図は [Kumar 11] より引用）	46
2.6	サーバサイド方式の全体像	48
2.7	クライアントサイド方式の全体像	49
3.1	提案手法の概観	54
3.2	ウェブサイト A の相関図ページのスクリーンショット	66
3.3	ウェブサイト A から得た評価関数における各アルゴリズムの正確度の推移 .	68
3.4	最適化システムの概要	70
4.1	提案手法の概観	78
4.2	長期的なクリック率に対する予測モデルの動作例（図は [Hohnhold 15] より引用）	83
4.3	各ウェブサイト最適化問題において仮定する確率モデル	85

4.4	提案手法の概観	87
4.5	正確度の推移	92
4.6	累積クリック数の推移	93
4.7	フィードバック空間 Z におけるクリック率の分布	94
4.8	各最適化エージェントが推定する最適バリエーションがもたらす目的指標の期待値比較	97
5.1	構造最適化における解の表現方法の違い	102
5.2	提案手法の概観	104
5.3	CTA ボタンのラベルに提案手法を適用する場合の概要	108
5.4	実験対象のウェブサイトのスクリーンショット	112
6.1	ウェブサイト最適化システムの全体像	121
6.2	住田らによる作用モデル（図は [住田 12] より引用）	131
A.1	$\mathbf{x} = (0, 0, 0, 0)$	139
A.2	$\mathbf{x} = (1, 0, 0, 0)$	139
A.3	$\mathbf{x} = (0, 1, 0, 0)$	139
A.4	$\mathbf{x} = (0, 0, 1, 0)$	139
A.5	$\mathbf{x} = (0, 0, 0, 1)$	139
A.6	$\mathbf{x} = (1, 2, 2, 1)$	139

表目次

2.1	各類型に属する最適化問題の例（★は主に離散最適化問題として表される問題の例を示す）	24
3.1	既存のウェブサイト最適化手法の整理	57
3.2	比較検討するアルゴリズム	63
3.3	シミュレーションの問題設定	64
3.4	シミュレーション実験における各アルゴリズムの正確度	65
3.5	ウェブサイト A における各施策の効果	67
3.6	ウェブサイト B を構成する変数と値	69
3.7	暫定解と期待値の推移	71
4.1	2013年5月16日にウェブサイト A においてテストされたバリエーションに対する目的指標およびフィードバック指標の推定分布	91
4.2	2013年6月6日にウェブサイト A においてテストされたバリエーションに対する目的指標およびフィードバック指標の推定分布	95
5.1	提案手法によって生成されたウェブサイト A, B, C の CTA ボタン候補（括弧内はコサイン距離を表す）	110
5.2	評価実験において生成されたラベル候補および獲得した肯定意見の割合 ($n = 300$)	115
6.1	サービスおよび製品の例	132

第1章

序論

1.1 研究の背景

1.1.1 ウェブサイト最適化の重要性とその定義

インターネットの普及に伴い、インターネットを介したサービスが私たちの生活にとって身近なものになっている。Amazon^{*1}や楽天^{*2}をはじめとするEコマースの普及によって、インターネットを介して行われるモノおよびサービスの取引の割合は年々増加している^{*3}。私たちの日々の情報収集においてGoogle^{*4}やYahoo!^{*5}などの検索エンジンおよびポータルサイトは欠かせないものになっており、Twitter^{*6}やFacebook^{*7}などのソーシャル・ネットワーキングサービスは、私たちの日常のコミュニケーションにおいて重要な役割を果たしている。ここでは、インターネットを介して提供されるこれらのサービスを総称してウェブサービスと呼ぶことにする^{*8}。

スマートフォンをはじめとするデバイスの普及は私たちにインターネット環境との接点をも

^{*1} Amazon <https://www.amazon.com>

^{*2} 楽天 <http://www.rakuten.co.jp>

^{*3} 平成27年度 我が国経済社会の情報化・サービス化に係る基盤整備（電子商取引に関する市場調査），経済産業省. http://www.meti.go.jp/policy/it_policy/statistics/outlook/ie_outlook.html

^{*4} Google <https://www.google.com>

^{*5} Yahoo! <https://www.yahoo.com>

^{*6} Twitter <https://twitter.com>

^{*7} Facebook <https://www.facebook.com>

^{*8} 厳密には、電子メールやインターネット電話はウェブサーバを用いないためウェブサービスには含まれない。しかし、このウェブに属しない部分のみでサービスが構成されることは少ないため、これらを部分的に活用したサービスも含めてウェブサービスと呼ぶことにする。

たらし、これらのサービスをより身近なものにしている。Android Wear^{*9}やApple Watch^{*10}をはじめとするウェアラブルデバイスや、Google Home^{*11}やAmazon Echo^{*12}をはじめとするインターネットに接続された家庭用デバイスも登場しあげてはいる。今後モノのインターネット (Internet of Things: IoT) の標語のもと、私たちの周りの様々なデバイスがインターネットに接続されるようになると、私たちの生活の中でウェブサービスが占める役割がますます大きくなるだろう。

ウェブサービスを提供する企業は、サービスを提供するウェブサイトを魅力的なものにすることで業績を伸ばすことができる。たとえば、Amazonはユーザが閲覧している商品と関連する商品を推薦して表示することで購入促進を図っており、このような推薦システムは売上向上に大きく貢献している [Kohavi 09]。他にも、GoogleやBing^{*13}などの検索エンジンは広告を表示するアルゴリズムおよびそのデザインを変更することで、より広告のクリックを訴求する方法を常に模索している [Kohavi 14, Hohnhold 15]。ウェブサービスを提供する企業にとって、ウェブサイトを改善してより良いユーザ体験を提供することは、直接業績の向上につながる重要な企業活動のひとつである。

ウェブサービスを主力事業としない企業にとっても、ウェブの活用は無視できないものになっている。多くの消費者が情報検索サービスを用いて商品の情報を手に入れて商品の比較検討を行っており、ウェブが消費者の購入プロセスに与える影響は大きい^{*14}。業種にかかわらず企業は商品およびサービスの魅力を伝えるウェブサイトを作ることが重要になっている。また、企業の活動を広く消費者に知つてもらうために様々な企業がソーシャルメディアを広報活動に活用しはじめており^{*15}、多角的なウェブの活用が進んでいる。ウェブ関連企業か否かを問わず、あらゆる企業がウェブにおける情報発信を活用しており、ウェブ上での施策を改善することで業績を伸ばすことができる可能性がある。ウェブサイトの改善は、もはやウェブ関連

*⁹ Android Wear <https://www.android.com/wear/>

*¹⁰ Apple Watch <https://www.apple.com/watch/>

*¹¹ Google Home <https://madeby.google.com/home/>

*¹² Amazon Echo <https://www.amazon.com/dp/B00X4WHP5E>

*¹³ Bing <https://www.bing.com/>

*¹⁴ 平成23年版 情報通信白書、総務省。 <http://www.soumu.go.jp/johotsusintokei/whitepaper/ja/h23/html/nc213330.html>

*¹⁵ 平成27年度 商取引適正化・製品安全に係る事業（ソーシャルメディア情報の利活用を通じたBtoC市場における消費者志向経営の推進に関する調査）、経済産業省。 http://www.meti.go.jp/policy/economy/consumer/consumer/pdf/sns_report.pdf

企業だけではなく、あらゆる企業にとっての課題となっている。

企業だけではなく、ウェブサービスを利用するユーザにとってもウェブサイトの改善によって得られる利益は大きい。各企業がウェブサイトの改善を繰り返していくことで、ウェブサイトがユーザのニーズにより良く応えるようになり、結果的にユーザ体験が向上されると考えられる^{*16}。たとえば検索エンジンであれば、より検索結果と関連の深い広告が表示されることで、ユーザにとって必要な情報へのアクセスが簡単になるかもしれない。Eコマースサイトであれば商品の要点を容易に理解できるようになり、商品購入の検討を行うための作業が減り、より満足度の高い購買体験をユーザに提供できるようになるかもしれない。ユーザに提供するユーザ体験の向上が、結果的にウェブサービスの収益の向上にも寄与すると考えられる。

このようにウェブサイトを改善することで、企業活動の上で望ましい状態にすることを**ウェブサイト最適化**と呼ぶ。ウェブサイト最適化にも様々な種類があり、ウェブサイトの表示を高速化することでより使いやすくすること（パフォーマンス最適化）、適切なキーワードを設定したりウェブページの構造を整理したりすることで当該サイトが検索サービスの上位に表示されるよう策を施すこと（検索エンジン最適化）などもウェブサイト最適化と呼ばれることがある。その中でも特に、ウェブサイトにおけるユーザ行動を最適化し、よりビジネス上望ましい行動を引き出すことに着目したものが**コンバージョン最適化**である。コンバージョンとは、Eコマースサイトにおける商品の購入や、検索エンジンにおける広告のクリックのように、対象のウェブサイトにおいてユーザに達成してほしい目的の行動のことを指す。つまり、ウェブサイトにおけるコンバージョンの発生率を最大化するようにウェブサイトを修正することがコンバージョン最適化である。

コンバージョン最適化ではユーザの行動を好ましい方向に制御することを目指すが、様々な心理的要因や状況依存性を含む人間の行動を一様に制御することは容易ではない。同じウェブサイトを前としても、ユーザによって反応が大きくばらつくのが通常である。そこでコンバージョン最適化において主に用いられるアプローチが、ユーザをサンプルとした比較対照実験である。このアプローチでは、まずウェブサイトの一部に変更を施すことで、複数の異なるバリエーション^{*17}を生成する。ウェブサイトの写真やテキストなどのデザインを構成する視覚要

*16 ウェブサイトの収益性が向上することと、ユーザ体験が向上することが必ずしも同じとは限らない。この両者を達成するための適切なウェブサイト最適化手法については、主に第4章で述べることにする。

*17 厳密に言えば、バリエーション（variation）は変化そのものを指す言葉であり、変化を施されたものを指す語

素を変更することもあれば、特定の機能の有無や特定の要素の動作を変更することもある。その後、ウェブサイトを訪問するユーザを各バリエーションに振り分けてユーザ行動の違いを比較し、よりユーザの望ましい行動を引き出すバリエーションを採用することで、コンバージョン発生率の向上を目指す。

わずかなウェブサイトの変化がユーザの行動に大きな影響を与えることが知られており、このアプローチは実際に様々なウェブサイトで活用されている。たとえば検索サービス Bing では、検索結果ページのリンクの色の濃さをわずかに変更するだけで年間 10 億円の収入増を実現した [Kohavi 14]。また、2008 年アメリカ合衆国大統領選挙では、バラック・オバマ氏が公式ウェブサイトで支援者の登録率を向上させるために、ウェブサイト最適化を活用した。この実験では図 1.1 に示す 6 種類の写真と 4 種類のボタンからなる 24 種類のパターンに対してテストが行われた。実験の結果、最もパフォーマンスの高かったパターンを採用することで、約 6000 万ドルの献金を追加で獲得することに成功した^{*18}。

このとき採用されたバリエーションは、オバマ氏とその家族が写った写真（図 1.1 中の Family Image）と“LEARN MORE”と書かれたボタンの組合せであった。この結果は、政治家としての自信を全面に押し出したバリエーションや、多くの後援者に彼が支持されている様子を表したバリエーションよりも、家族を大切にしている様子が映し出されたバリエーションが人々の行動を促したことを見ている。実験を始めた当初、ほとんどの関係者はこのバリエーションが有望だと予想していなかったそうだが、ウェブサイト最適化はしばしば実施者の直感とは異なる結果をもたらすことが知られている [Crook 09]。このことは、ウェブサイト制作者の勘や経験だけではなく、実際のユーザの反応にもとづいて決断を下すことの重要性を示していると言えるだろう。

ウェブサイトにおける対照実験は実装が容易な上に、収益性に大きな改善をもたらため、様々なウェブサイトに導入されている。ここでは、このユーザをサンプルとして対照実験を行うアプローチを狭義のウェブサイト最適化とする。以上をまとめると、ウェブサイト最適化の定義は以下のようになる。

としてバリエント (variant) を用いるのが正しいが、ここでは外来語としてより馴染みのあるバリエーションをバリエントと同義で用いることにする。海外のウェブサイト最適化ツールでは variant を用いることが多い。

^{*18} How Obama Raised \$60 Million by Running a Simple Experiment <http://blog.optimizely.com/2010/11/29/how-obama-raised-60-million-by-running-a-simple-experiment/>



図 1.1: 2008 年アメリカ合衆国大統領選挙にて、バラック・オバマ氏公式ウェブサイトの実験で用いられた写真とボタンのバリエーション

ウェブサイト最適化の定義

- 広義** ウェブサイトを改善し、より企業活動の上で望ましい状態にすること。
- 狭義** ユーザをサンプルとした対照実験にもとづいて、より望ましいユーザ行動を引き出すウェブサイトのバリエーションを探査すること。

広義のウェブサイト最適化には、パフォーマンス最適化や検索エンジン最適化も含まれる。しかし、これらに対する有効な手法は検索エンジンの仕様やその時々で用いることができる技術に大きく左右されるため、解法を一般化することは難しい。一方、狭義のウェブサイト最適化は人間の感覚、知覚、認知の過程をブラックボックスとして扱い、そこから生まれる反応を最適化する試みである。したがって、人間であるユーザと対峙するウェブサイトを作る限り有用なものであると考えられる。そこで、本研究では特に狭義のウェブサイト最適化を研究対象として取り上げることにする。

1.1.2 ウェブサイト最適化の高速化への課題

企業が市場経済の中で経済活動を営む限りそこには市場競争があり、各企業は競合企業よりも高速にサービスを改善して業績を上げることが求められている。したがって、ウェブサイトが企業活動において重要な役割を担っている以上、ウェブサイト最適化による仮説検証のサイクルを高速に回すことは、どの企業にとっても重要な課題である。また、仮説検証のサイクルを高速化できれば、同期間にさらに多くのバリエーションを試すことができるようになるため、サービス改善の速度を加速させることができる。このフィードバックループが発生することで、市場における強者はますます力を得る収穫過増のメカニズムが働くため、どの企業もその速度に満足することは無い。世界1位のアクセス数を誇るGoogleでさえ^{*19}、そのサンプルサイズには満足していないことが報告されている[Tang 10]。仮説検証サイクルの速度は今後の企業活動の競争力となるものであり、容易には満足されることがない重要な課題である。

ウェブサイト最適化を高速化するための手段には様々なものが考えられる。広告を介したプロモーション活動を行うことでユーザ数すなわちサンプルを増やすこともひとつの手段であろう。他にも、クラウドソーシングを用いてバリエーションを大量生成することも有効かもしれない。しかし本研究では特に、ウェブサイト最適化をひとつの数理的最適化問題として捉えたときに、より性能の良い最適化手法を開発することによる高速化に着目する。なぜならば、ウェブサイト最適化を最適化問題として定式化することによって、数式によってこの問題を議論できるようになり、これまでに数学や工学の分野において培われてきた様々な最適化手法をサービスの改善のために導入できるようになるためである。最適化理論と実社会の問題をつなげることができれば、今後の更なる研究および産業応用の発展が期待される。また、ウェブサイト最適化を様々なウェブサイトにおいて利用可能なものにするためにも、最適化アルゴリズムという形で再現可能な手続きとして記述することが重要である。

では、ウェブサイト最適化を最適化問題として定式化したときに、高速に最適なバリエーションを発見するような最適化手法とはどのようなものだろうか。この問題を考える上で重要な定理として、ノーフリーランチ定理[Wolpert 97]がある。これは数学的に定義可能なあらゆる評価関数に対して万能なアルゴリズムは存在せず、どのアルゴリズムも平均性能は同じで

^{*19} SimilarWeb (2017年2月現在) <https://www.similarweb.com/website/google.com>

あることを示した定理である。したがって、ウェブサイト最適化において性能良く動作する最適化手法を開発するためには、ウェブサイトとユーザの相互作用に起因するウェブサイト最適化特有の性質に着目することが有用である。

1.2 本研究の目的

そこで本研究では、ウェブサイト最適化を数理的最適化問題として定式化し、高速に最適なバリエーションを発見する最適化手法を構築することを目的とする。

ウェブサイト最適化は、収益につながる指標を最大化するバリエーションを探索することである。したがって、ユーザに表示するバリエーションを解、収益につながる指標を目的関数とした定式化が基本になる。しかしこれ以外にも、ウェブサイト最適化特有の要素を定式化に含めることで、高速な最適化手法を生み出す手がかりにできるかもしれない。たとえば、ボタンのクリック率を目的関数とした場合でも、ウェブページの滞在時間やスクロール量のように、ユーザの興味の深さを示す何らかの指標が観測できるかもしれない。そういう場合にはその指標も定式化に含めることで、高速な最適化手法を生み出す手がかりになると考えられる。本研究ではこのようなウェブサイトとユーザの相互作用から生じる特徴を踏まえて、ウェブサイト最適化という現象を**ウェブサイト最適化問題**として定式化する方法を提案する。

また、このウェブサイト最適化問題に対する高速な最適化手法を考える際にも、ウェブサイト最適化の特徴は重要な役割を果たす。たとえば、ウェブブラウザの画面の大きさが有限であることを考えれば、十分に離れた視覚要素がユーザの認知にもたらす交互作用は無視できるほど小さいと予想される。このように、人間がウェブサイトを知覚・認知する過程にはなんらかの制約や特性があり、それがウェブサイト最適化問題における評価関数の特徴を形成していると考えられる。ノーフリーランチ定理で述べたように、こういった最適化問題の特性を利用することができ性能の良いアルゴリズムを構築する上で本質的に重要になる。そこで本研究では、こういったウェブサイト最適化の特徴を活かした、ウェブサイト最適化問題に対する高速な最適化手法を構築することを目指す。つまり本研究は、ウェブサイトを改善するという最適化問題に問題を限定したときに、汎用的に動作する最適化手法を構築しようとするものである。

1.3 本論文の構成

一般に、最適化問題は $x^* = \arg \max_{x \in X} f(x)$ を満たす最適解 x^* を求める問題として表される。ただし、 X は実行可能解空間、 $f(x)$ は評価関数である。この最適解 x^* または近い性能を示す近似解をできるだけ少ない評価回数で求めることができ、探索アルゴリズム構築の中心的な課題である。ウェブサイト最適化においては、解の評価回数を減らすことは少ないユーザ数で最適解を探索することを意味する。すなわちこれは探索の高速化であり、できるだけ少ないユーザ数で優良な解を求めるアルゴリズムを構築することが本研究の課題である。

ここでこの最適化問題の定式化に着目すると、最適化問題は探索方法 $\arg \max$ 、評価関数 $f(x)$ 、解空間 X の三つの問題領域に分けて高速化の工夫を検討することができる。本研究はこの三つの問題領域それぞれについてウェブサイト最適化を高速化する手法について提案し、評価する。

第2章では、まずウェブサイト最適化の起源について説明する。次に、既存の数理最適化問題について説明し、ウェブサイト最適化問題が属する類型を整理する。さらに、この三つの問題領域に関する関連研究を中心にウェブサイト最適化にまつわる既存研究を説明する。続く各論で中心的な役割を果たす用語や手法についても、ここで整理する。最後に、ウェブサイト最適化の具体的な実装方法についても、本章で説明する。

第3章（第一研究）では、 $\arg \max$ の部分に相当する探索手法に工夫を導入することによる高速化に取り組む。ウェブサイトを様々な要素の組み合わせとして表現したときに、それぞれの要素によって張られる特徴空間におけるユーザの反応には一般に非線形性が含まれることが予想される。つまり、要素の定義の方法によっては要素間に強い交互作用が発生してしまう可能性がある。しかし一方で、十分に距離が離れた要素間や性質が異なる要素間の交互作用は無視できる程度に小さく、独立性を仮定できるかもしれない。もし独立性が仮定できるのならば、線形性を仮定できるため探索が容易になる。そこで第一研究では、一部の要素間に非線形性があり、他方には線形性を仮定できるような解空間で高速に動作する最適化手法を提案する。評価実験では、実際のウェブサイトから得られたログデータをもとにシミュレーションを行い、提案手法の有効性を評価する。また、提案手法をウェブサイト最適化プログラムとして実装し、実際のウェブサイトに適用することで提案手法の実用性を評価する。

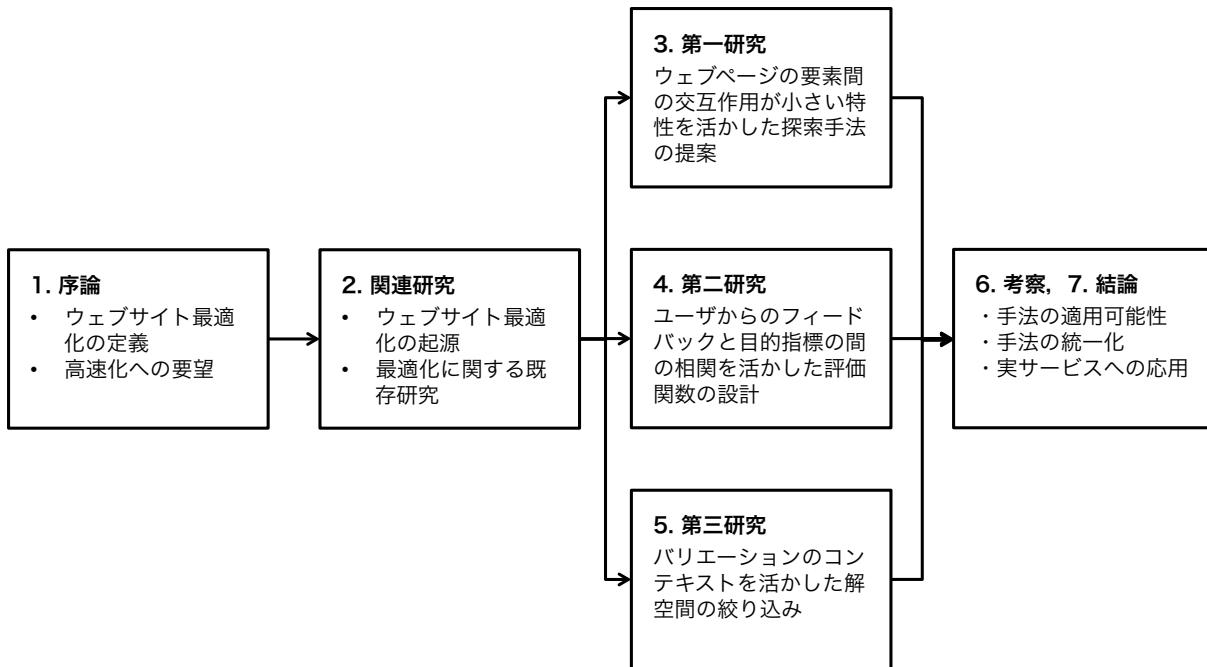


図 1.2: 本論文の構成

第4章(第二研究)では、 $f(x)$ の部分に相当する評価指標に工夫を導入することによる高速化に取り組む。一般に、ウェブサイト最適化の対象となる目的指標の観測値には、様々な背景を持つユーザとの相互作用である以上、大きなばらつきが含まれる。しかし一方で、ユーザの反応を多面的に捉えることで、ユーザの表面的な反応には現れない変化を捉えることができる可能性がある。たとえば、ある商品を販売するウェブサイトをユーザが目にしたときに、即座に購入を行うことは少ないかもしれないが、もし気になる商品であれば滞在時間が長くなる、ウェブページのスクロール量が増えるといった行動の変化が見られるかもしれない。つまり、ウェブサイトの目的となる指標のみを評価指標とするのではなく、目的となる指標以外のユーザ行動も評価指標に取り組むことで、より潜在的なユーザ反応の変化を捉えることができるかもしれない。そうすることで、発生頻度の低い目的指標に対しても高速に最適化を行うことができる評価指標を設計できる可能性がある。そこで第二研究では、ウェブサイトの目的となる指標以外のフィードバックも取り込んだウェブサイト最適化手法を提案する。評価実験では、実際のウェブサイトから得られたログデータをもとにシミュレーションを行い、提案手法の有効性を評価する。

第5章（第三研究）では、 X の部分に相当する解空間に工夫を導入することによる高速化に取り組む。ウェブサイト最適化でテストされるバリエーションはウェブデザイナやウェブエンジニアによって人手で制作されることが多く、ウェブサイト最適化による仮説検証サイクルの自動化への障害となっている。このサイクルから人手の作業が取り除かれれば、より一層高速なウェブサイト最適化を実現できる可能性がある。ここで、人手で行われているバリエーション生成作業を仮説の探索行為として捉えると、本来的には膨大に存在する解候補の中から勘と経験にもとづいてテストする解候補を絞り込んでいる行為だと捉えることができる。これと同様の動作を機械学習を用いて再現することができれば、ウェブサイト最適化の自動化および高速化を実現できる可能性がある。そこで第三研究では、ウェブ上の事例を用いることで膨大な仮説空間の中から有望な解を絞り込み、ウェブサイト最適化を高速化する手法を提案し、評価する。評価実験では、提案手法を実際のバリエーション生成システムとして実装し、ウェブサイト最適化に適したバリエーションを生成できることをアンケート調査によって評価する。

第6章では、各論で提案した手法を概観し、本研究で提案するウェブサイト最適化の定式化的活用の可能性およびその限界について議論する。また、ウェブサービスに限らない一般的なサービスに対しての応用可能性を議論し、最後に、第7章にて本稿を締めくくる。

ウェブサイト最適化を適用するための条件は、提供する製品もしくはサービスがインターネットをはじめとする何らかのネットワークによって事業者と結びつき、任意の修正、およびその修正に対するユーザの反応が計測できることである。今後我々の身の回りの様々なハードウェアがインターネットに接続されるようになると、それらを組み合わせることでより効果的にユーザにサービスを提供することが求められるようになる可能性がある。本研究で提案した手法は、私たちの様々なものがインターネットに接続されて事業者のコントロール下に置かれるようになる時代において、重要な役割を占めるものになると考えられる。

第2章

関連研究

本章では、ウェブサイト最適化にまつわる既存研究を概観し、本研究の位置づけを明確にする。まず、第2.1節ではウェブサイト最適化の起源を説明し、ウェブサイト開発に実験計画法が持ち込まれた経緯について説明する。第2.2節では、数理最適化の関連研究を説明し、ウェブサイト最適化の最適化問題としての性質を説明する。続いて、ウェブサイト最適化を探索手法（第2.3節）、評価指標（第2.4節）、解空間（第2.5節）の三つの問題領域に分けたときの既存研究を説明する。最後に、第2.6節にてウェブサイト最適化の具体的な実装方法について説明する。

2.1 ウェブサイト最適化の起源

2.1.1 実験計画法

最も単純なウェブサイト最適化はユーザをサンプルとした比較対照実験として表される [Kohavi 11]。比較対照実験は、ある操作による効果を比較によって検証する実験方法である。一般的には、コントロール群とトリートメント群の二つの実験群を設定し、コントロール群に属するサンプルには操作を施さず、トリートメント群に属するサンプルには操作を施す。その二つの群に見られる効果を比較することで、操作による効果を検証する。得られた結果の差は統計学的仮説検定や区間推定によって評価される。比較対照実験は農業、工業、創薬、医療などあらゆる研究領域で用いられている手法である。

比較対照実験において検証する操作が複数になったり、操作が組み合わせ構造を持ったりす

る場合に、より信頼性が高い実験結果を得るために実験を設計する手法をまとめたものに、**実験計画法**がある。実験計画法はもともと農学において適切に施肥効果を評価するために Fisher によって考案された [栗原 11]。

実験計画法は以下の局所管理、反復、無作為化を三つの原則としている。

■局所管理の原則 対象の操作の要因のみを評価するために、空間的・時間的に実験環境を小分けにすること。たとえば、ある肥料を与えることによる収穫量への影響を評価するには、ひとつの圃場で操作を加えた前後で収穫量などの影響を調べるよりも、圃場を小分けにして同じ期間で肥料を与える群と与えない群を比較するほうが良い。そうすることで、本来調べたい施肥効果以外の要因（この場合は天候や連作障害など）を取り除くことができる。

■反復の原則 同じ条件下に複数のサンプルを配置すること。これによってサンプル間の誤差（誤差変動）と操作によって生じた変動（要因変動）を分けて評価することができる。データを収集した後に各操作の効果を評価する上で前提となる重要な原則のひとつである。

■無作為化の原則 局所管理によって制御できない要因に関しては無作為化すること。たとえば、先ほどの圃場における施肥効果の例では、局所管理によって時間的な要因を制御することには成功しているが、特定の圃場の部分の水はけが悪い、日当たりが良いなどの理由で空間的には制御が難しい可能性がある。そのような場合には、小分けにした圃場に条件を割り当てる順番を無作為化することで、制御できない要因を誤差に含めてしまうことができる。

実験計画法には適切に操作の効果を評価する方法だけではなく、効率的に評価を行うための工夫も含まれている。その工夫のひとつが**直交計画**である。直交計画は、特定の操作が組み合わされることによって生じる高次の交互作用を無視することで、検証する条件の数を減らす工夫である。ひとつの条件下での検証に時間的または金銭的なコストがかかる場合には、検証すべき条件の数が複数の操作の組み合わせによって膨れ上がってしまうと実験が実施できなくなってしまう。そのため、実験を減数するための工夫が用いられてきた。

直交計画は製造業に導入され、品質向上および生産性向上の目的で活用されてきた。田口玄一は製品の機能を理想機能に近づけることを品質向上と位置づけ、機能のばらつきを最小化するパラメータを設計するための手法として直交計画を活用した。製造業における機能のばらつきを最小化するために田口が見出した手法群は、品質工学またはタグチメソッドと呼ばれてい

る [田口 93].

実験による品質および生産性の向上の試みは、特に自動車産業において盛んに行われてきた。トヨタ自動車は生産性を向上するために削減すべきムダを定義し、ムダを排除して生産性を上げるために手法群を編み出してきた。その一連の手法は**リーン生産方式**という名前で体系化されている [Womack 90]。リーン生産方式による生産性の向上がトヨタ自動車の競争力の源泉であり、より顧客満足度の高い製品の生産につながっていると考えられてきた。トヨタ自動車において実験による生産性の向上が日常的に行われている様子は、[Spear 04] にて詳しく述べられている。

実験計画法は特定の操作の効果について完全な知識がない下で、製品の品質および生産性の向上のための手段として製造業において広く活用されてきた。仮説検証によってより良い製品を生み出すアプローチをウェブサイト開発に応用したものとして、ウェブサイト最適化を捉えることができる。

2.1.2 ソフトウェア開発手法の変遷

一方で、ウェブサイト最適化はソフトウェア開発手法が変遷の結果たどり着いた一形態としても捉えることができる。ここではソフトウェアの開発にウェブサイト最適化のような仮説検証に基づくアプローチが取り入れられてきた経緯について説明する。その中で、実験計画法を背景にして発展したリーン生産方式がウェブサービスの改善に持ち込まれた経緯についても触れる。

1960 年代ごろから銀行の業務システムや ATM の開発などの大規模かつ複雑な情報システムに対する需要が急激に高まりを見せ、ソフトウェア開発者の不足や開発されるソフトウェアの品質が問題になった。この問題は NATO の会合において議論され、**ソフトウェア危機**と呼ばれるようになる。工学的なアプローチによって系統立てられたソフトウェア開発手法を確立することで、これらの問題を解決しようとする試みとして**ソフトウェア工学**が生まれ、効率的なソフトウェア開発を実現する手法が産業界と学術界の双方から模索されるようになった [松本 92]。今もなお、ソフトウェア開発手法はその時代に求められるソフトウェアの性質に応じて絶えず変化を続けている。

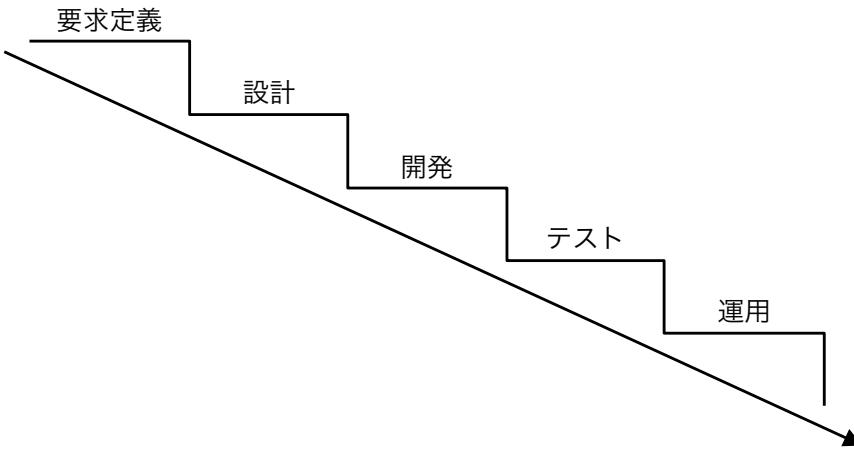


図 2.1: ウォーターフォール・モデルの概観

ウォーターフォール・モデル

大規模なソフトウェア開発において当初主流だったソフトウェア開発モデルは、**ウォーターフォール・モデル**である。ウォーターフォール・モデルの概要を図 2.1 に示す。ウォーターフォール・モデルは上流工程から下流工程に向かって逐次的に要件定義、設計、開発、テスト、運用と各工程を進めていくものである。基本的に前工程の成果物を前提として次の工程に移るため、原則として前工程の修正は行わないのが特徴である [Sommerville 11]。

ウォーターフォール・モデルの利点は開発プロジェクト全体を概観しやすいことにある。ウォーターフォール・モデルは設計が完了した時点の成果物として仕様書が出来上がるため、この時点で全体の工数を見積もることができるようになる。したがって、必要なリソースを構成しやすい、開発中の進捗状況を確認しやすいなどの利点がある。また、プロジェクト全体を概観しやすいことは顧客との合意形成および契約に結びつける上でも有利に働くと考えられる。

一方で、ウォーターフォール・モデルの欠点はプロジェクト途中での仕様変更が困難なことである。ウォーターフォール・モデルでは前工程の成果物を前提としているため、下流工程に入った後に仕様が変更されると大きな手戻りが発生する可能性がある。また、開発中に設計の誤りが発見された際には、設計工程に手戻りすることが余儀なくされる。したがって、ウォーターフォール・モデルはプロジェクト途中で仕様および設計が変更される蓋然性が低い

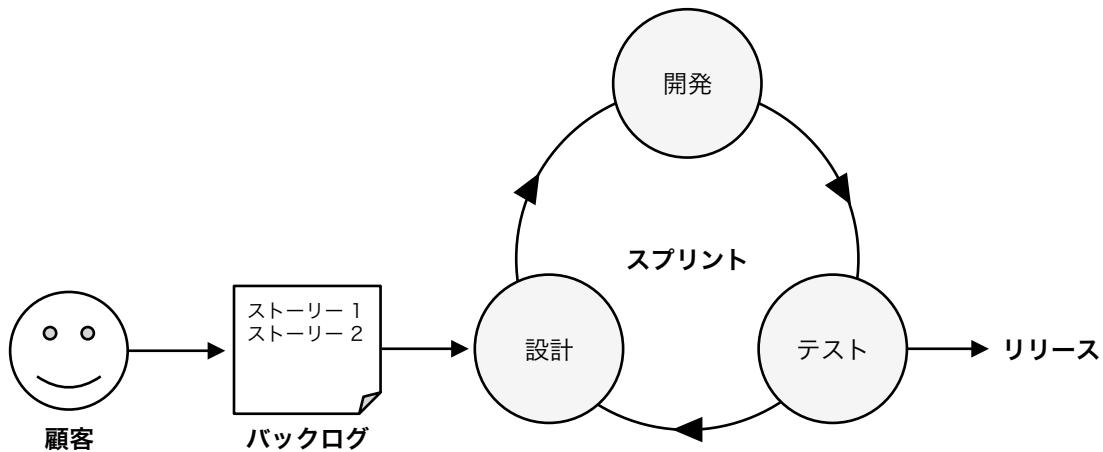


図 2.2: アジャイル開発モデルの概観

プロジェクトには向いているが、設計に不確実要素が含まれる場合には不向きな手法である [有沢 88].

アジャイル開発モデル

開発対象となるソフトウェアが多様化するにつれて開発工程の前に完璧な設計を完了することが困難になってくると、ウォーターフォール・モデルに変わるソフトウェア開発モデルが模索されるようになった。その中で生まれたのが、**アジャイル開発モデル**である。アジャイル開発モデルの概観を図 2.2 に示す。アジャイル開発モデルでは、設計、開発、テストを 1 週間から 1 ヶ月といった短い期間で反復的に行うところに特徴がある。この反復のことをスプリントと呼ぶ。要件定義はバックログとよばれる顧客からの要求をリスト化したものに蓄積されており、設計を行う際にはバックログからストーリー（要求される機能性の単位）を取り出して設計を行う。アジャイル開発モデルは柔軟にかつ迅速にソフトウェア開発を行うための手法群の総称であり、他にもペアプログラミング（二人のエンジニアが共同してプログラミングを行い、ミスの発見および知識の共有を効率的に行うこと）やスクラムミーティング（プロジェクトメンバー全員が情報共有を行う高頻度かつ短期間のミーティング）などのテクニックも含まれる [Leffingwell 07].

アジャイル開発モデルの利点は完璧な設計を前提とせず、設計からテストまでを反復して行うため、事前の設計が困難なプロジェクトに対しても大きな手戻りが発生しにくいことであ

る。また、プロジェクト途中で仕様が変更された場合でも、バックログに含まれるストーリーを変更することで対応することができる。そのため、ウォーターフォール・モデルに比べると柔軟性の高いソフトウェア開発モデルだと言うことができる。

一方で、アジャイル開発モデルの欠点はプロジェクトの概観が見渡しにくいことである。設計が逐次的になされるため事前に全体の工数を見積もることが難しく、途中の仕様変更によって大幅に変更になる可能性もある。そのため、ウォーターフォール・モデルと比較すると顧客との合意形成が難しくなる場合も発生すると考えられる。

以上のような欠点はあるものの、アジャイル開発モデルは柔軟に製品開発ができる手法として多くのソフトウェア開発者の間で親しまれていった。特にアジャイル開発モデルはウェブアプリケーションの開発と相性が良く、2000年代以降インターネットが普及するに伴ってさらに人気を集めようになった。ウェブアプリケーションは従来のソフトウェアとは異なり、利用者は自身の端末にソフトウェアをインストールする必要がない。ウェブサーバ上で動作するため、開発者がウェブサーバ上のプログラムを書き換えるだけで、最新のソフトウェアを利用者に提供することができる。そのため、ウェブアプリケーションの開発は従来型のソフトウェアと異なり完成期限を定める必要がなく、逐次的に開発し、公開することができる。このようなウェブアプリケーションの特徴がアジャイル開発モデルの強みと合致したことが普及を促進したと考えられる。

リーンスタートアップ・モデル

一般家庭にもコンピュータおよびインターネットが普及し始めたことにより、今までの企業の業務目的のB2B^{*1}ソフトウェア開発だけではなく、一般消費者が利用することを想定したB2C^{*2}ソフトウェア開発も増えていった。B2Bソフトウェアでは、顧客企業の担当者が顧客プロキシ^{*3}となって対話することによって要件定義を行い、仕様書の策定およびバックログの更新ができる。しかし、B2Cソフトウェアでは一般消費者が顧客となるため、顧客がバックログを更新してくれることを期待することは難しい。

このように要求の定義そのものが難しい場合におけるソフトウェア開発モデルとして、

*1 Business to Business. 企業間で行う商取引のこと。

*2 Business to Consumer. 企業対消費者の取引のこと。

*3 疑似顧客. 顧客の要望を代弁する者のこと。

2010 年代に入るとリーンスタートアップが注目を集めた。リーンスタートアップは 2008 年に Eric Ries によって提唱されたサービス設計手法であり、開発 (Build), 測定 (Measure), 学習 (Learn) の 3 ステップからなる BML サイクルを反復することで、顧客が求めていない製品を開発するムダを省き、より顧客満足度の高いソフトウェアの開発を進める手法である [Ries 11]。

リーンスタートアップ・モデルにおける BML サイクルの概観を図 2.3 に示す。BML サイクルは、まず顧客の要求に対する仮説を作ることから始まる。その仮説を検証するための必要最小限の機能を持った製品を開発する。成果物として得られた製品を公開して顧客に利用してもらい、その顧客の振る舞いを測定することでデータを収集する。得られたデータから、当初の仮説が検証できたことを評価する。評価の結果に応じて仮説を作り直し、次の BML サイクルに入る。リーンスタートアップ・モデルは、以上のプロセスを繰り返すことで顧客に対する仮説および製品の両方を同時に構築する手法である。

反復によって製品の開発を進める点はアジャイル開発モデルと類似しているが、リーンスタートアップ・モデルでは、バックログを更新してくれる顧客の存在を仮定しないのが特徴である。顧客の要求が不明確だからこそ、データを介した仮説検証によって顧客の要求を聞くのが、リーンスタートアップ・モデルのアプローチである。データを介した仮説検証によって顧客の要求を理解することは、顧客開発とも呼ばれる。リーンスタートアップ・モデルはこの製品開発と顧客開発の両輪を同時に走らせる開発手法である。

リーンスタートアップの名称はリーン生産方式が由来となっており、リーン生産方式におけるカンバンやジャスト・イン・タイム生産などの工夫をソフトウェア開発に取り組む方法についても紹介されている。リーンスタートアップは、実験を通じて製品の品質を向上するリーン生産方式の考え方をウェブサービス開発に導入したものと捉えることができる。このようにして製造業で培われたデータによる仮説検証のアプローチが、ソフトウェア開発にも持ち込まれるようになった。

以上で取り上げたソフトウェア開発手法を図 2.4 にまとめた。図示に際して Eric Ries 氏の基調講演のスライド^{*4}を参考にした。まず、ウォーターフォール・モデルは開発すべきソフト

^{*4} Eric Ries Lean Startup Presentation For Web 2.0 Expo April 1 2009 A Disciplined Approach To Imagining, Designing, And Building New Products. <http://www.slideshare.net/startuplessonslearned/eric-ries-lean-startup-presentation-for-web-20-expo-april-1>

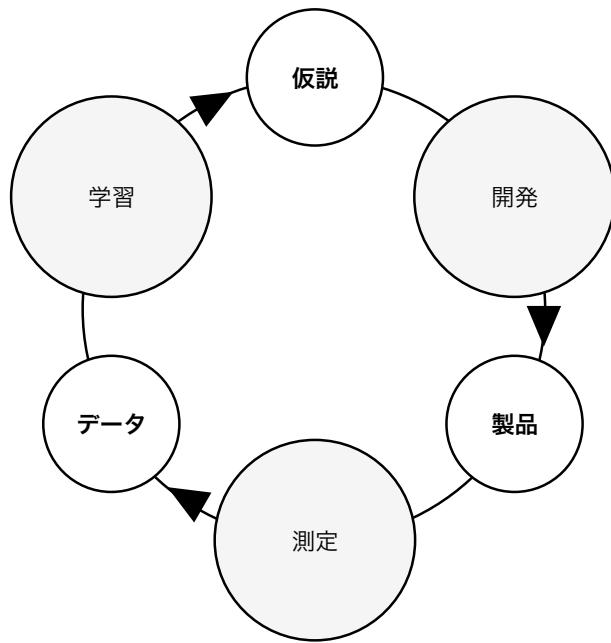


図 2.3: リーンスタートアップ・モデルにおける BML サイクルの概観

ウェアに対する要求（問題）が明確であり、かつその要求を満たすソフトウェアを開発する方法（解法）が明確である場合に有効な開発手法だと考えられる。業務目的のシステムや ATM のように、ソフトウェアに求められる機能が明確であり、その要求を設計として明文化できるソフトウェアと相性が良いソフトウェア開発手法である。

一方アジャイル開発モデルは、ソフトウェアに対する要求は顧客もしくは顧客プロキシから与えられるため明確であるものの、その要求を満たす設計の明文化が困難な場合に有効な開発手法であると考えられる。アジャイル開発モデルでは完全な設計の記述が困難であっても、顧客に現時点での製品を見せてることでその良し悪しについてはフィードバックをもらうことができる。そのため、短いスパンの製品の制作と顧客からのフィードバックを繰り返すことで、真に顧客が求めているものに製品を近づけていくアプローチを取る。

最後にリーンスタートアップは、製品に対してフィードバックを与えてくれる顧客もしくは顧客プロキシの存在も仮定しない。アジャイル開発モデルのスプリントに相当する製品開発サイクルに加えて、データにもとづいた仮説検証によって顧客の要望を学習する顧客開発サイクル

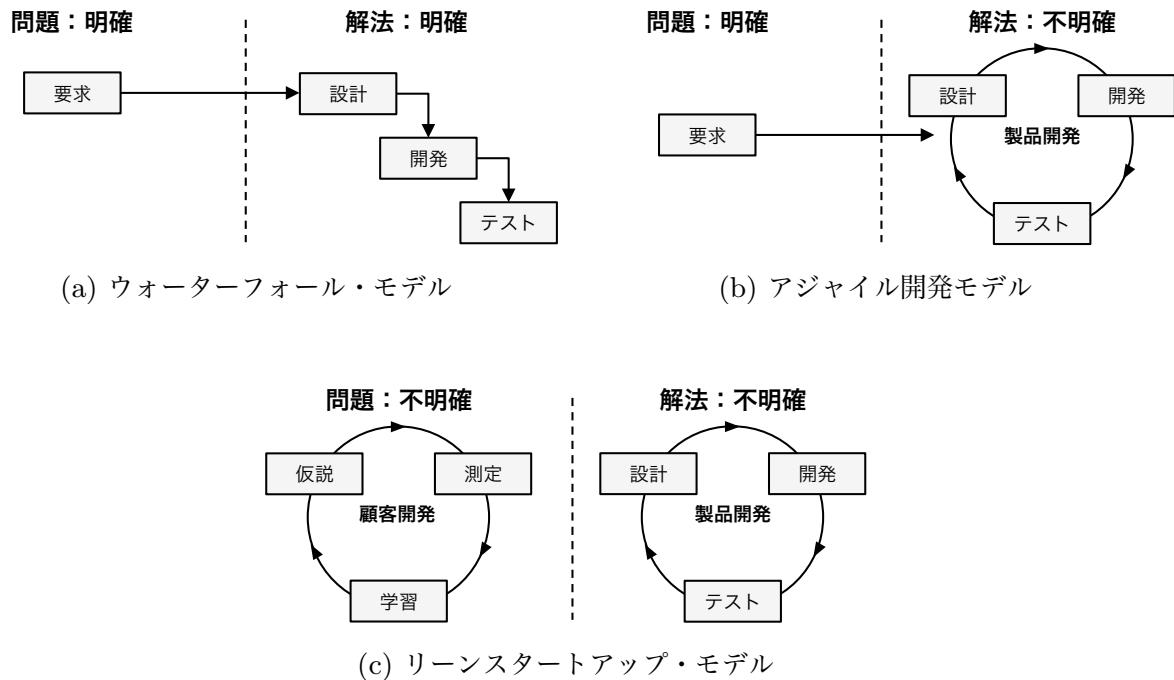


図 2.4: 既存のソフトウェア開発手法の概観

ルの両輪を同時に回すことで、ソフトウェアに求められる要求もその実現方法も不明確な状況下で最適なソフトウェアを開発することを目指すアプローチである。ユーザをサンプルとした対照実験にもとづいて、より望ましいユーザ行動を引き出すウェブサイトを構築することを目指す狭義のウェブサイト最適化は、ウェブサイト開発にこのリーンスタートアップの考え方を導入したものと考えることができる。

実験を通じて品質を向上していくためには、実験計画法で上げた三原則を対象の製品が満たしている必要がある。ここで、ウェブサイトがこの原則を満たしていることを確認しておく。

■局所管理の原則 ウェブサイトは訪問するユーザごとに表示するバリエーションを操作し、ユーザを各バリエーションに振り分けて局所管理することができる。現実世界の店舗では訪問客ごとにレイアウトを変える、商品のディスプレイを変えるといった操作が非現実的のとは対象的に、ウェブサイトではあらかじめそのようにプログラムさえされていれば、ほとんどコスト無しでユーザをバリエーションごとに小分けにすることができる。

■反復の原則 ウェブサイトの規模にも依るが、試すバリエーションの数が訪問ユーザ数より小さい限りは、ひとつのバリエーションに対して複数人のユーザすなわちサンプルを割り当てることができる。

■無作為化の原則 ユーザを各バリエーションに振り分ける際には、乱数を出力するプログラムを応用することで無作為に振り分けることができる。したがって、各訪問ユーザにはウェブブラウザの違いやデバイスの違いなど様々な属性の違いはあるものの、無作為にバリエーションを割り当てることで、バリエーション以外の効果を無作為化することができる。

2.1.3 データに基づくサービス改善に関する関連研究

本節の最後に、データに基づく仮説検証によるサービスの改善と関連のある研究分野をいくつか紹介する。

サービス工学

ウェブサイト最適化は、ウェブを介したサービスの収益性を向上することが目的であるため、サービスの品質改善と関連が深い。サービスの品質を工学的アプローチによって制御しようとする学問領域として、**サービス工学**がある。サービス工学では、従来は事業者の経験や勘に依存して展開してきたサービスを、客観的なデータによって観測することで、パラメータによって制御可能なものにすることを目的としている [本村 12]。

サービス工学は、従来の製造業で培われてきた品質工学のノウハウをサービス業に適用しようとするものとして捉えることもできる。従来の品質工学では出荷する製品を最適化する対象とし、理想機能に対する機能のばらつきを品質と定義して諸々のパラメータの最適化を行う。一方、サービス工学では提供するサービスを最適化する対象とし、サービスに対する顧客の満足度およびその結果として発現する消費者行動を品質と定義して最適化を行う。製造業では出荷する前に工場の中で機能を測定して品質を評価することができるのに対し、サービス業では実際に顧客にサービスを提供しないと品質を評価することができない。そのため、最適化を行うシステムの中に顧客を含めて考えるのがサービス工学の特徴である。これは、製品に対する需要が大きいために設計通りに製品を生産することが求められる時代から、基本的な製品が充足しているために顧客に受け入れられる新たな製品を開発することが求められる時代へのパラ

ダイムシフトを表しているとも考えられる。

顧客も含めた最適化のシステムを取り扱うことでサービスの改善を図るという点で、本研究はウェブサービスに焦点をあてたサービス工学研究のひとつと捉えることができる。一方で、サービス工学はデータマイニングを用いたサービスの解析およびモデル化に重点が置かれており、その解析結果をうけた実際のサービス改善施策はサービス事業者に委ねられることが多い。これは、サービス工学では小売サービスや医療サービスなど様々な分野のサービスを取り扱うため、施策の具体的な方策を一般的な形で記述することが難しいことに起因している。一方、ウェブサービスに限って言えば、その具体的な施策はすべてソースコードの形で表現することができる。したがって、本研究はサービス工学の一部と位置づけることもできるが、ウェブサービスに限定することで解析から施策までを一気通貫した手法を扱う部分が異なる。

対話的進化計算

人間との相互作用を通してある人工物の状態を最適化するという点では、本研究は**対話型進化計算**(Interactive Evolutionary Computation)とも関連が深い。対話型進化計算とは、人間の主観的な評価を評価関数として対象システムの挙動を最適化する枠組みである[Takagi 01]。最適化手法としては、名前にもある通り遺伝的アルゴリズムや遺伝的プログラミングをはじめとする遺伝的計算が用いられることが多い。ビジュアル・アートの生成[Lewis 08]やポスターの生成[尾畠 00]など様々な応用が提案されており、出力の形態に関わらず人間の感性を捉えることができる仕組みの研究が行われてきた。

人間の望ましい反応を最大化するために、システムと人間の相互作用を通して最適化を行う点では本研究と関連が近い。一方で、本研究は特にウェブサイトの最適化に着目している点、最適化手法を遺伝的アルゴリズムに限定しない点が異なる。また、対話的進化計算では被験者からの主観的評価を評価関数として扱うことが多いため、被験者の疲労およびサンプルサイズの少なさがしばしば問題になる[Takagi 01]。それに対して、ウェブサイト最適化ではウェブサイトを訪問する任意のユーザから暗示的に得られる評価を元に最適化を行うため、このような問題が議論されることはない。

2.2 数理最適化

ウェブサイト最適化は、ある評価値を元に最適なバリエーションすなわち解を発見することができるため、数理的最適化問題との関連が深いと考えられる。本節では、数理的最適化問題の既存研究を説明し、ウェブサイト最適化との関係を整理する。

2.2.1 数理最適化問題の概要

私たちは日常生活の中で様々な意思決定を行っており、色々な制約があるなかで最も好ましいと思われる選択肢を選んでいる。これらの制約や目的を数理モデルとして表現し、計算によって最善策を求めるこれを**数理的最適化**と呼ぶ。数理的最適化の応用範囲は広く、これまで様々な分野で応用が進められている [穴井 15]。

最適化問題は一般に、ある制約のもとで目的関数を最小または最大とする解を探索する問題として表現される。

最適化問題

実行可能な解 x の集合を X 、最大にしたい目的関数を $f(x)$ としたとき、下式を満たす最適解 x^* を求めよ。

$$x^* = \arg \max_{x \in X} f(x)$$

ここでは最大化問題として最適化問題を表したが、目的関数の符号を反転することによって一般性を失うこと無く最小化問題として定式化することも可能である。

最適化問題は以上のように定式化されるものの、その問題の性質や難易度は数理モデルを当てはめようとする現象によって大きく異なる。適切な解法すなわち最適化アルゴリズムもそれに応じて変化する。ここではまず最適化問題を

- 連續最適化／離散最適化
- 線形最適化／非線形最適化
- バッチ最適化／オンライン最適化

の3つの軸で類型化し、それぞれの最適化問題の特徴および適切な解法を整理する。さらに、

その中のウェブサイト最適化の位置づけを考えることにする。

まず、それぞれの軸の特徴について見てみよう。

■連続最適化／離散最適化 最適化問題は、解が連続値を取る場合と離散値を取る場合で分類することができる。前者は連続最適化問題、後者は離散最適化問題もしくは組合せ最適化問題と呼ばれる。特に整数のみで解が構成される問題を整数最適化問題と呼ぶ。ここでは連続値と離散値の両方を扱う混合整数最適化問題も後者に含まれるものとする。一般に、離散値条件が入るとより難しい最適化問題になる。

■線形関数／非線形関数 最適化問題は目的関数および制約条件の線形性によって分類することができる。目的関数および制約式が線形の方程式や不等式で表される場合には、線形最適化問題に分類される。一方、線形関数に限らない場合は非線形最適化問題に分類される。一般に、非線形関数に対する最適化は困難になるが、目的関数が凸性を持つ場合には大域的最適解と局所最適解が一致するため、計算上取り扱いやすくなる。

■バッチ最適化／オンライン最適化 最適化問題は、あらかじめ目的関数が完全に観測される中でのバッチ最適化と、逐次的に目的関数が観測される中でのオンライン最適化に分類することができる。オンライン最適化の中でも、逐次的に入力されるデータに対する目的関数 f およびその勾配 ∇f が観測できる設定は**完全情報設定**と呼ばれる。一方、完全情報設定より厳しい設定として**バンディット設定**がある。バンディット設定は目的関数およびその勾配に関する情報は観測できず、現状解 x に対する目的関数の値 $f(x)$ のみが観測できる設定である[畠塙 16]。

2.2.2 数理最適化問題の類型

表 2.1 に第 2.2.1 項で述べた軸をもとに分類した既存の数理最適化問題および解法の例を示す。

線形最適化・バッチ最適化

線形最適化かつバッチ最適化の最適化問題には、生産計画問題や巡回セールスマン問題などが属する。生産計画問題は、利用できる原料の制約の中で利益を最大化するように製品の生産

表 2.1: 各類型に属する最適化問題の例 (★は主に離散最適化問題として表される問題の例を示す)

	バッチ最適化	オンライン最適化 (完全情報設定)	(バンディット設定)
線形最適化	生産計画問題, 巡回セールスマント問題*	オンライン配分問題, エキスパート統合問題*	多腕バンディット問題*
非線形最適化	非線形ナップザック問題*, 機械学習モデルのバッチ学習	機械学習モデルのオンライン学習	機械学習モデルの超パラメータチューニング, ウェブサイト最適化問題*

量の決定する問題である。生産量としてある値域の任意の値が許される場合には連続線形最適化問題となるが、生産量や原料の消費量に離散値の制約が課せされると離散線形最適化問題となる。ある経路グラフにおいて、すべての接点を通過する最短閉路を求める巡回セールスマント問題も、離散線形最適化問題に属する有名な例題である。

連続線形最適化問題についてはシンプレックス法が古くから用いられている。また、内点法や楕円体法など多項式時間で解を得ることができる手法もある [伊理 95]。ソルバの充実とともに、近年では大規模な問題でも比較的高速に解くことが可能になっている [久保 12]。

離散線形最適化問題については分岐限定法や動的計画法に代表される厳密解法が用いられる。これらの厳密解法では、問題の構造を利用して効率的に探索する解を列挙することで、厳密な最適解を見出すことができる。しかし、離散最適化問題において探索すべき解は組合せ的な構造を持つため、解の数は組合せ爆発によって指数関数的に増加する。したがって、厳密解では無くとも性能の良い解を短時間で求めることができる近似解法が用いられることもしばしばである [穴井 15]。近似解法に属する解法としては局所探索法やメタヒューリスティクスがある。これらの近似解法については第 2.3.1 項で詳しく述べる。

非線形最適化・バッチ最適化

一般的な線形最適化問題にある種の条件を加えることで、非線形最適化問題になることがある。たとえば、整数線形最適化問題の例題としてナップザック問題を考えてみよう。ナップザック問題は、子供が遠足に行くときにできるだけ好きなお菓子をたくさんナップザックに詰

め込むことを目指す問題である。ナップザックに入れることができるお菓子の重量（もしくは合計金額）には制約があり、その中で遠足に持っていくことができるお菓子の価値を最大化することが目的である。一般的なナップザック問題では、 N 個のお菓子の選択の可否を表す解 $\mathbf{x} \in \{0, 1\}^N$ と各お菓子の価値 $\mathbf{w} \in \mathbb{R}$ の内積 $\mathbf{w}^\top \mathbf{x}$ を最大化する線形最適化問題として定式化される。しかし、ここに「チョコレートとクッキーとマシュマロを持っていくと、おいしいスモア^{*5}ができるため価値がその和以上になる」といった現象が目的関数に入ると、これは非線形最適化問題になる。非線形最適化問題に対して厳密解法を適用することは難しく、近似解法が用いられることが多い。

また、ニューラルネットワークやサポートベクトルマシンなどの機械学習モデルのバッチ学習も非線形バッチ最適化と捉えることができる。ここでは単純な例として、入力層と出力層のみからなるニューラルネットワークである、単純パーセプトロンの学習を例に説明する。単純パーセプトロンの学習では、ある学習データ $D = \{(\mathbf{x}_n, y_n) \mid n = 1, \dots, N\}$ が与えられたとき、ある入力 \mathbf{x}_n に対する予測値 $f(\mathbf{w}^\top \mathbf{x}_n)$ と正解値 y_n の誤差 $l(\mathbf{x}_n, y_n, \mathbf{w})$ の期待値（損失関数と呼ぶ） $L(D, \mathbf{w}) = \frac{1}{N} \sum_{n=1}^N l(\mathbf{x}_n, y_n, \mathbf{w})$ を最小にするようなパラメータ \mathbf{w} を獲得することを目指す。このことを最適化問題として捉えると、解をパラメータ \mathbf{w} 、目的関数を損失関数 $L(D, \mathbf{w})$ とした最適化問題を解くことに相当する。

機械学習モデルのバッチ学習は連続最適化であるため、勾配を計算できる。そのため勾配降下法が用いられることが多い。勾配降下法では、

$$\mathbf{w}_{t+1} = \mathbf{w}_t + \eta \nabla L(D, \mathbf{w}_t)$$

としてパラメータ \mathbf{w} を更新することで学習を行う^{*6}ただし、 \mathbf{w}_t は t 回目の更新を行った時点でのパラメータ \mathbf{w} を表すものとする。また、 η は学習率と呼ばれる正の値である。

線形最適化・完全情報設定オンライン最適化

完全情報設定下の線形オンライン最適化に属する最適化問題の例には、オンライン配分問題がある。オンライン配分問題は複数の株銘柄への投資や複数のタスクに対する計算資源の配分

^{*5} スモア (S'more, some more) は焼いたマシュマロとチョコレートをビスケットで挟んで食べるキャンプファイヤーの人気デザートである。

^{*6} ここでは最適化問題を最大化問題として考えているため勾配方向 $\nabla L(D, \mathbf{w}_t)$ をそのまま更新方向として用いているが、最小化問題では負の勾配方向 $-\nabla L(D, \mathbf{w}_t)$ を更新方向に用いることになる。これは次に述べる確率的勾配降下法でも同様である。

など、複数の選択肢へ資源をうまく配分して利益を最大化することを目指す問題である。プレイヤーは各試行 $t = 1, \dots, T$ においてある配分 \mathbf{x}_t を提示すると、それに対する利益（もしくは損失） $\mathbf{w}_t^\top \mathbf{x}_t$ が観測される。このやりとりを繰り返すことでも最適な配分 \mathbf{x}^* を決定することが目的となる。同様の問題設定として、複数のエキスパートが提示する解を統合して最適な解を逐次的に推定するエキスパート統合問題と呼ばれる問題設定もある。解法としては、各試行で得られる目的関数 \mathbf{w} の和を最大にする点を逐次的に選択する Follow-The-Leader (FTL) アルゴリズムや、正則化項を加えた Follow-the-Regularized-Leader (FTRL) アルゴリズムなどが知られている [海野 15]。

非線形最適化・完全情報設定オンライン最適化

機械学習モデルをオンライン学習によって訓練することは、完全情報設定下の連続非線形オンライン最適化問題を解いていると捉えることができる。バッチ学習ではすべての学習データ D から目的関数 $L(D, \mathbf{w})$ を算出し、勾配降下法によってパラメータ \mathbf{w} を学習したが、オンライン学習では学習データ $(\mathbf{x}_n, y_n) \in D$ が与えられるたびに逐次的にパラメータを更新することで学習を行う。

ここではオンライン学習の例として、確率的勾配降下法を説明する。確率的勾配降下法では、逐次的に与えられる学習データ (\mathbf{x}_n, y_n) に対する誤差 $l(\mathbf{x}_n, y_n, \mathbf{w})$ を目的関数の近似値として用いることによって、パラメタの更新を行う。すなわち、

$$\mathbf{w}_{t+1} = \mathbf{w}_t + \eta \nabla l(\mathbf{x}_n, y_n, \mathbf{w}_t)$$

として n 番目の学習データ (\mathbf{x}_n, y_n) が与えられるたびに、誤差の勾配 $\nabla l(\mathbf{x}_n, y_n, \mathbf{w}_t)$ にもとづいてパラメタの更新を行う手法である。ここで示した例では誤差 $l(\mathbf{x}_n, y_n, \mathbf{w}_t)$ によって損失関数を近似しているが、より近似の精度を向上する手法として、小さなバッチに対して学習を行うミニバッチ学習がある。

バンディット設定オンライン最適化

これまでに見てきたように、完全情報設定におけるオンライン最適化では、目的関数そのもの（オンライン配分問題における $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x}$ に相当する）や目的関数の勾配 ∇f （機械学習における $\nabla l(\mathbf{x}_n, y_n, \mathbf{w}_t)$ に相当する）が計算できることが重要な役割を果たしている。一方、バンディット設定オンライン最適化では、目的関数の形や勾配に関する情報は与えられず、あ

る解に対する評価値のみが与えられる状況下で最適化を行う。

バンディット設定下の線形オンライン最適化問題の例としては、多腕バンディット問題がある。多腕バンディット問題は、プレイヤーの目の前に複数のスロットマシンがあると仮定したときに、最も収益が大きくなるように腕を引くスロットマシンを逐次選択する問題である。各試行で試したスロットマシンについての情報は得ることができるが、それ以外のスロットマシンの収益性についての情報は一切得られない。各試行で「他のスロットマシンを選んでいたらこれだけの報酬が得られたはず」という情報が得られると仮定する完全情報設定とは対照的である。バンディット設定下でのオンライン最適化問題のさらなる分類および解法については第2.3.2項で詳しく述べる。

2.2.3 ウェブサイト最適化問題の位置づけ

それでは、ウェブサイト最適化を数理的最適化問題とみなしたもの、すなわち**ウェブサイト最適化問題**はどの数理最適化問題のクラスに属するのだろうか。

まず、ウェブサイト最適化問題は離散最適化問題に属すると考えられる。最適化したい対象のウェブページを、画像やキャッチコピー等の複数の視覚要素の組合せとして捉えると、そのそれぞれのバリエーションの中から、最適なものの組合せを探索する問題として考えることができる。たとえば、ある食料品を紹介するウェブページ x が商品の写真 x_1 、キャッチコピー x_2 、購入ボタンの色 x_3 という 3 つの要素の組み合わせによって表現されるとき、購入ボタンの色 x_3 は $V_3 = \{ \text{赤, 青, 緑, 黄} \}$ のいずれかひとつの値を取ることになる。したがって、最適化する要素の中には画像のサイズや色の値など連続値で表すことができるものも含まれるかもしれないが、一般的には混合整数最適化問題も含めた離散最適化問題に属するものと捉えられる。

また、ウェブサイト最適化問題は非線形最適化問題として捉えられる。たとえば、ウェブページの背景色と、その上に設定するボタンの色をそれぞれ視覚要素として最適化することを考えたとき、背景色とボタンの色が類似の色だと視認性が低くなり、望ましいユーザの反応が得られにくくなるかもしれない。このように、ウェブサイト最適化によって最適化する要素の間には交互作用が発生する可能性があるため、目的関数の非線形性を仮定するのが自然だと考えられる。

さらに、ウェブサイト最適化問題はバンディット設定下のオンライン最適化問題に属する。ウェブサイトが用意しているバリエーションに対するユーザの反応は、テストを行う前からあらかじめ反応曲線のような関数の形で与えられるものではなく、あくまでユーザとの相互作用の中で逐次的に観測されるものである。したがって、ウェブサイト最適化はオンライン最適化問題に分類される。また、この目的となる指標はユーザにあるバリエーションを表示したときの反応として観測されるものであり、その他のバリエーションについては何も情報は得られない。したがって、ウェブサイト最適化は完全情報設定ではなく、バンディット設定に属する。

以上をまとめると、ウェブサイト最適化問題はバンディット設定下の離散非線形オンライン最適化問題という、この分類の中では最も難易度の高い最適化問題のクラスに属するものであることがわかる。以上の考察より、ウェブサイト最適化問題の定式化は下記のように表すことができる。

ウェブサイト最適化問題

ある離散値で表される n 個の要素の組合せによって表されるバリエーション $\mathbf{x} \in \mathbb{R}^n$ に対するユーザの反応 y が、ある確率分布 $p(y | \mathbf{x})$ にしたがって与えられるものとする。このとき、最もユーザの好ましい反応を引き出すと期待される最適バリエーション \mathbf{x}^* を求めよ。

$$\begin{aligned} & \text{maximize} && \mathbb{E}[y | \mathbf{x}] \\ & \text{subject to} && 0 \leq x_i \leq L_i \\ & && x_i \in \mathbb{Z}, i = 1 \dots n \\ & && y \sim p(y | \mathbf{x}) \\ & && y \in \mathbb{R} \end{aligned} \tag{2.1}$$

ただし、 L_i は i 番目の要素が取ることができる値の数を表すものとする。

ここでは目的指標 y がその期待値を最適化したい指標そのものを表すものとし（つまり $f(y)$ のような変換を要しないものとし）、最大化問題として表すものとする。これは $-y$ とすることで最小化問題にも対応できるため、最適化問題としての一般性は失わない。

ウェブサイト最適化問題と同じクラスに属する問題として、機械学習における超パラメータのチューニングが挙げられる。大規模データセットを用いて機械学習システムを構築する際、その学習に数日かかることも珍しくない。また、データを分割して交差検定を行う場合には

データを分割した数だけ機械学習モデルの学習を行う必要があるため、一回の施行にかかる時間的コストは大きい。性能の良い機械学習システムを獲得するためには、その機械学習モデルに紐づく超パラメータを適切に設定することが肝要であるが、以上の理由によってできるだけ少ない試行回数で性能の良い超パラメータの組を推定することが求められている。ここで、ひとつの超パラメータの組を解 \mathbf{x} 、得られた機械学習システムの汎化性能を評価値 y として捉えることで、バンディット設定下の非線形最適化問題として捉えることができる [Hoffman 14]。

このウェブサイト最適化問題および類似問題に対しては、目的関数そのものおよび勾配の情報を用いることなく探索ができるような近似解法が有効であると考えられる。これらの問題に適用できる近似解法については第 2.3 節で詳しく述べることにする。本研究では、この基本的なウェブサイト最適化問題および派生して定式化された問題に対して高速に動作する最適化手法を提案するものである。

2.2.4 ソフトウェア開発手法と数理最適化の関連

本節の最後に、第 2.1.2 項で述べたソフトウェア開発手法の変遷と数理最適化問題の関連について整理したい。

ウォーターフォール・モデルでは顧客が求めている製品の設計を行い、その設計どおりに開発を進める。このことは、顧客が求めている製品についての完全な知識があることを前提としており、その中で最適な製品を解を提示することに相当する。したがって、これはあらかじめ顧客の要求すなわち目的関数について完全な知識があると仮定した状況下での、バッチ最適化を行っていることに相当すると考えられる。

一方、アジャイル開発モデルは、最初から顧客が求めている製品について完全な知識があるとは仮定せず、顧客からのフィードバックを受けながら、逐次的にソフトウェアを更新していく手法である。これは、完全情報下のオンライン最適化に近いアプローチを取っていると考えられる。あらかじめ目的関数の完全な知識はないものの、逐次的に現状解に対する評価は得ることができる。それに加え、顧客プロキシがバックログに機能の要望を追加してくれるため、これは次に解を更新すべき勾配方向を示していると捉えることができる。

最後に、リーンスタートアップは、バンディット設定下での最適化問題として捉えることができる。アジャイル開発モデルではバックログとして解を更新すべき方向が示されていたのと

は対照的に、リーンスタートアップでは現状の製品すなわち解に対する評価は観測できるものの、次に向かうべき方向は提示されない。したがって、評価値にもとづいて解を更新するための方策を持つ必要がある。

このように、ソフトウェア開発手法を最適化手法という観点で捉えると、より難しい最適化問題を解くことができるよう進化を遂げていることがわかる。本研究は、この進化の最終地点である、現状解に対する評価値のみが与えられる状況下で、ウェブサービスを逐次的に改善する手法について取りあげたものである。

2.3 探索手法にまつわる既存研究

本節では、ウェブサイト最適化をバンディット設定下の離散非線形オンライン最適化問題として定式化したときに、解法として有効だと思われる探索手法を説明する。

離散最適化問題を解く際、問題の構造を利用することによって効率的な解法を導入したり、解きやすい問題に変換したりすることで厳密解法を適用できるようになることがある。しかし、問題の構造が事前に不明な場合には、探索すべき解候補が多くなると厳密解法を適用することが難しい。そこで、特別な問題の知識を仮定することなく短期間で性能の良い解を得ることができる近似解法としてメタヒューリスティクスがある [柳浦 00]。

メタヒューリスティクスは、生命活動の仕組みや物理現象にヒントを得て最適化アルゴリズムを実装したものである。そのアルゴリズムの多くは解の有望な解の重点的に評価する**集中化**の工夫と局所最適解から抜け出して大域的最適解を目指すために広く解を評価する**多様化**の工夫を組み合わせることで、性能良く解を探索できるようになっている [金澤 04]。メタヒューリスティクスでは、関数全体の情報が得られている必要はなく、解に対する評価値さえ得られれば適用可能である。そのため、ウェブサイト最適化に対する解法としても有望な手法のひとつであると考えられる。第2.3.1項にて、メタヒューリスティクスを用いた様々な最適化手法を説明する。

一方、バンディット設定下のオンライン最適化問題はバンディット問題とも呼ばれており、様々な解法（**バンディットアルゴリズム**と呼ばれる）も提案されている。バンディット問題の定式化の中には、ある解に対する評価値が一意ではなく、ある確率分布にもとづいて与えられるとする定式化も含まれている。このことは、同じバリエーションであってもユーザによって

反応が異なるウェブサイト最適化を定式化する上で都合の良い設定である。第 2.3.2 項では一般的なバンディット問題およびその解法であるバンディットアルゴリズムについて概要を説明する。

2.3.1 メタヒューリスティクス

山登り法

山登り法は暫定解に小さな操作を施すことによって近傍解を生成し、近傍解に暫定解よりも評価値が高い解があればそれを暫定解と入れ替えるという動作を繰り返すことで最適解を探索する。評価値が高い解に似た解も同様に評価値が高いというヒューリスティクスを導入した探索手法であり、最も単純な局所探索法である。簡単に実装できる反面、極値に値が収束してしまい局所最適解に陥りやすいという欠点がある。局所最適解への収束を克服するための工夫として、解が収束した後に再びランダムに初期値を選択して探索を再開するランダム再スタート山登り法や、複数の異なる初期解から探索を行ない、最もよい局所最適解を選択する多スタート山登り法などがある。

焼きなまし法

焼きなまし法は局所探索法の一種であり、山登り法の局所最適解に陥ってしまう欠点を克服するための工夫を取り入れた手法である。焼きなまし法では近傍解の評価値が暫定解より悪い場合でも、ある確率で暫定解の更新を行うことを許可する。受理が行われる確率は温度 τ と呼ばれるパラメータによって決定され、温度が高いほど受理が行われる確率が高くなる。探索の初期では高い温度を設定することで局所最適解に収束させず大域的な探索を行い、探索が進むにつれて温度を低くしていくことで最適解に収束させる。良い解を得るために、温度を低下させる冷却スケジュールを適切に設定する必要があり、パラメータを試行錯誤して調整する必要がある。

遺伝的アルゴリズム

遺伝的アルゴリズムは生物の進化過程を模して探索を行うメタヒューリスティクスである。これまでに述べた山登り法、焼きなまし法はひとつの解について更新を行う単点探索手法だが、遺伝的アルゴリズムでは複数の個体群による多点情報を用いて探索を行う多点探索手法に

分類される。遺伝的アルゴリズムでは「世代」と呼ばれるサイクルを繰り返すことで、最適解を求める。世代と世代の間では「淘汰」「交叉」「突然変異」の3つの操作を施し、次の世代で探索を行う解集合を決定する。

■淘汰 淘汰は評価値の低い解を探索対象の解集合から取り除く操作である。自然界において環境への適合度が低い個体が、自然から淘汰されることに対応している。

■交叉 交叉は淘汰を耐えて生き残った解同士で、解の一部を交換したものを次の世代で探索する解集合に追加する操作である。優秀な解の良い部分同士を兼ね備えた解が生まれる可能性があるため、さらに評価値の高い解を得られることが期待される。

■突然変異 突然変異は解のある変数を他の値に書き換えることである。評価値の低い解を生成してしまうリスクがある一方、局所最適解への収束を防いで多様性を確保するために重要な役割を果たす操作である。

分布推定アルゴリズム

遺伝的アルゴリズムにおける遺伝子操作を確率操作によって行うように発展させたものが分布推定アルゴリズムである。有望な解を構成する各変数が従う確率分布を推定することで最適解を探索する手法であり、実装は容易であるにも関わらず、単純な遺伝的アルゴリズムを超える性能を示すことが知られている [倉橋 03]。学習する確率分布のネットワーク、すなわちベイジアンネットワークの設計によっては交互作用も含めた確率分布を表現することが可能になる。このように学習するベイジアンネットワークを仮定し、最適解が生成される確率分布を推定するアプローチを**ベイジアン最適化アルゴリズム (Bayesian Optimization Algorithm: BOA)** と呼ぶ。学習するベイジアンネットワークを複雑にするほど学習は困難になることが知られている [Bengoetxea 02]。

2.3.2 バンディット問題とバンディットアルゴリズム

バンディット問題とは、ある確率分布にしたがって報酬を与える複数の選択肢を前にしたときに、獲得する報酬和を最大にするように逐次的に決定を行う問題である [本多 16]。ある選択肢に関する報酬の情報を得るためにその選択肢を選ぶほか無いが、もしその選択肢の期待

値が低かった場合には、その間最適な選択肢を選ばなかっことによる機会損失が増加することになる。このように、未評価の選択肢を選択する行為（探索）と既知の選択肢の中で最も期待値が高い選択肢を選ぶ行為（活用）のトレードオフは**探索と活用のジレンマ**と呼ばれており、強化学習問題にも共通する重要なテーマである [牧野 16]。バンディット問題に対する解法であるバンディットアルゴリズムは、このトレードオフに対処するための方法を提供するものである。ここではウェブサイト最適化と関連が深いバンディット問題の様々なクラスと、それらに対する解法の代表的なものを説明する。

確率的バンディット問題

確率的バンディット問題は、各選択肢が独立した報酬の確率分布を持っている問題設定であり、バンディット問題の中でも一般的な定式化である。手法の評価方法としては、累積報酬の他に**リグレット（後悔）**を用いることが一般的である。リグレットは、最適な選択肢を選ばなかっことに依る機会損失の和である。時刻 T におけるリグレット $R(T)$ の期待値は下式によって表される。

$$\mathbb{E}[R(T)] = \mathbb{E} \left[\max_i \sum_{t=1}^T r_i(t) - \sum_{t=1}^T r_i(t) \right]$$

ただし、 $r_i(t)$ は時刻 t に i 番目の選択肢を選択したときに得られる報酬を表すものとする。

以下に、確率的バンディット問題に対するバンディットアルゴリズムの代表的なものを挙げる。

■ ε -greedy ε -greedy アルゴリズムではあらかじめ非常に小さな値としてパラメータ $0 < \varepsilon < 1$ が設定されており、 ε の確率で探索を行い、 $1 - \varepsilon$ の確率で活用を行う。探索が選択された場合には解候補の中からランダムに一つの解を選んで表示する。一方、活用が選択された場合は最も期待値が大きい解を選んで表示する。このように探索と活用の間を行き来することで未評価の解を評価しつつも、評価値の期待値が大きい解を優先的に表示することで実験による損失を免れている。

■Softmax ε -greedy アルゴリズムは解の期待値を考慮せず探索または活用の選択を行うため、明らかに他より期待値が劣る解があった場合でも他の解と同様に評価されてしまう欠点がある。この弱点を補強したのが Softmax アルゴリズムである。Softmax アルゴリズムでは、

解の評価値の期待値に応じて表示する確率を変化させる。解候補を X 、解 $x \in X$ の評価値の期待値を $\mathbb{E}[y|x]$ とすると、解 x をユーザに表示する確率 $p(x)$ を下式のように定める。

$$p(x) = \frac{\exp(\mathbb{E}[y|x]/\tau)}{\sum_{x \in X} \exp(\mathbb{E}[y|x]/\tau)}$$

τ は温度パラメータであり、探究心の強さを表している。温度が非常に高いとき、すなわち $\tau \rightarrow \infty$ のときは解 x を選ぶ確率 $p(x)$ は $1/|X|$ に収束するため、すべての解が均等の確率で選ばれことになる。逆に温度が低いときは最も評価値の期待値が高い解が 1 に近い確率で選ばれるようになる。メタヒューリスティクスの焼きなまし法同様、冷却スケジュールの調整がパフォーマンスに影響を与える。

■UCB これまで述べたバンディットアルゴリズムは乱数を取り入れたアルゴリズムであったが、UCB (Upper Confidence Bound) アルゴリズムは乱数を使わず期待値の上側信頼限界に着目するアルゴリズムである。UCB は期待値 $\mathbb{E}[y|x]$ に信頼区間の半幅を加えた値が最大となる解を選択するアルゴリズムである。解 $x \in X$ を表示した回数を N_x とすると、解 x の UCB 値 U_x は

$$U_x = \mathbb{E}[y|x] + \sqrt{\frac{2 \log(\sum_{x \in X} N_x)}{N_x}}$$

であり、この UCB 値を最大にする解 x が選択される。UCB アルゴリズムは「不確かなときは楽観的に (optimism in face of uncertainty)」と呼ばれる楽観主義原理を表現したアルゴリズムと言うことができる。

最適腕峻別問題

一般的なバンディット問題では、探索時に最適解を選択しなかったことによる損失を最小化することを目的とするが、最適腕峻別問題では探索時の損失は考慮せず、最適解を発見するまでに要する解の評価回数を最小化することを目的とする。したがって活用のことは考えずに探索のことのみを考えれば良いが、与えられたサンプルを高速な探索のために効率的に振り分けることが中心的な課題となる。

■レーシングアルゴリズム レーシングアルゴリズムは最適腕峻別問題に用いられる逐次削除方策のひとつの実装である。強化学習やメタヒューリスティクスを実装した機械学習シ

ステムにおいて、最適なパラメータを探索する目的で利用されてきたアルゴリズムである [Birattari 02, Heidrich-Meisner 09].

レーシングアルゴリズムでは観測値から比較対象の解 x の評価値の信頼区間 $[\mu_x^{lower}, \mu_x^{upper}]$ を隨時計算する。もし、他のいずれの解の信頼区間の下界より自らの信頼区間の上界が小さいような解が存在すれば、その解を敗者解 x_{loser} として評価対象から取り除く。すなわち、下式を満たすような解を解候補から取り除く。

$$\mu_{x_{loser}}^{upper} < \min_{x \in X \setminus \{x_{loser}\}} \mu_x^{lower}$$

この操作を、ここでは**敗者解の除去**と呼ぶことにする。

一方、他のいずれの解の信頼区間の上界より自らの信頼区間の下界が大きいような解が存在すれば、その解を勝者解 x_{winner} として決定して探索を終了する。すなわち、下式を満たすような解が見つかれば探索を終了する。

$$\mu_{x_{winner}}^{lower} < \max_{x \in X \setminus \{x_{winner}\}} \mu_x^{upper}$$

この操作を、ここでは**勝者決定**と呼ぶことにする。以上の操作を信頼区間が更新される度に繰り返すことで、有望な解により多くのサンプルを割り当てるこを可能にしている。

文脈付きバンディット問題

確率的バンディット問題では各選択肢が独立に報酬の期待値を持っていると想定したが、文脈付きバンディット問題では各選択肢が期待値に加えてある特徴ベクトル $\mathbf{x}_i \in \mathbb{R}^d$ を持つものとする。ただし d は各選択肢が持つ特徴ベクトルの次元数とする。これは、各選択肢やその時々の環境が組み合わせ的な構造を持っている場合に有用な定式化である。

■LinUCB Lin-UCB アルゴリズムは、特徴ベクトルに対する線形モデルによって各選択肢の期待値が推定できると仮定することで、UCB アルゴリズムを文脈付きバンディット問題に適用できるように拡張したものである。つまり選択肢 \mathbf{x}_i の期待値 μ_i が、あるパラメータ θ を用いて、 $\mu_i = \theta^T \mathbf{x}_i$ と線形モデルで表されることを仮定している。期待値の線形モデルと得られる報酬の最小二乗法を解くことで更新式を得ることができる。選択肢の特徴ベクトル \mathbf{x} のある素性 x_a と x_b の間に交互作用があることを表現したいときは、交互作用項 $x_a x_b$ を特徴ベクトルの素性に加えれば良い。

Li らは, Yahoo!のトップページに表示するニュース記事を表示するアルゴリズムに LinUCB を用いた [Li 10a]. 推薦するニュース記事に対してニュースカテゴリや提供元にもとづいて特徴表現を与えることで, 文脈付きバンディット問題として定式化している. さらに Li らは, トップページを訪れるユーザにもデモグラフィック情報や利用状況にもとづいてある特徴表現 u を与えることで, ユーザそれぞれに合わせたニュース推薦を行う仕組みを構築できることを示した. この方法を用いると, ある時刻 t にユーザ u_t が訪れたとすると各選択肢は

$$\mathbf{x}_{i,t} = \begin{pmatrix} \mathbf{x}_i \\ \mathbf{u}_t \\ \mathbf{f}(\mathbf{x}_i, \mathbf{u}_t) \end{pmatrix}$$

と表され, 各選択肢の特徴ベクトルはユーザが訪れる時刻ごとに変化することになる. ただし, $\mathbf{f}(\mathbf{x}_i, \mathbf{u}_t)$ はもともとの選択肢の特徴ベクトル \mathbf{x}_i とユーザの特徴ベクトル \mathbf{u}_t の交互作用項を含んだベクトルを返す関数とする. もし交互作用を仮定しない, すなわち $\mathbf{f}(\mathbf{x}_i, \mathbf{u}_t)$ が空であるならば, 各時刻で期待値を最大にする選択肢は

$$\mathbf{x}_t^* = \arg \max_i \begin{pmatrix} \boldsymbol{\theta}_x \\ \boldsymbol{\theta}_u \end{pmatrix}^T \begin{pmatrix} \mathbf{x}_i \\ \mathbf{u}_t \end{pmatrix} = \arg \max_i \boldsymbol{\theta}_x^T \mathbf{x}_i$$

となり, 時刻に依存しないものになる点に注意されたい. このようにユーザの特徴を含めることで, パーソナライゼーションを考慮した最適化を行うことができるのも文脈付きバンディット問題の特徴である. また, 一般化線形モデルにも適用できるよう拡張したモデルとして GLM-UCB が提案されている [Filippi 10].

連続腕バンディット問題

ここまで述べたバンディット問題では各選択肢が離散的であることを仮定していたが, 連続腕バンディット問題では選択肢が連続的, つまり無限個あることを仮定する. 連続腕バンディット問題は, 選択肢の特徴ベクトルによって張られる特徴空間の上で期待値を最大にする点を探す連続最適化問題となる. しかし, 期待値関数が強い非連続性を持ったり, 急激な勾配の変化があったりする場合には, 最適解を求めることが難しい. そのため期待値関数が滑らかであるという仮定, 特にリップシツツ連続の仮定を置くことが多い. 関数 $f(x)$ に対して下式が成り立つとき, リップシツツ連続である.

$$\exists c > 0 \text{ s.t. } |f(x') - f(x)| \leq c \|x' - x\| \quad \forall x, x' \in X$$

ところで、形状の分からぬブラックボックス関数の最大値を効率的に求めるための枠組みとして、**ベイズ最適化**がある。ベイズ最適化はガウス過程を用いて目的関数の期待値および分散の分布を推定し、それらから何らかの方法で定義される獲得関数を最大にする点を逐次的に選択することで、最小のリグレットで目的関数の最大値および最大値を与える点を推定することを目指す枠組みである。このベイズ最適化の枠組みを連続腕バンディット問題の方策として利用することで、探索と活用のバランスを取りながら最適な選択肢を探索することができる [Srinivas 10]。名前は似ているが、第 2.3.1 項で紹介したベイジアン最適化アルゴリズムとベイズ最適化は異なるものであることに注意されたい。

獲得関数の設計方法に応じてベイズ最適化には様々なバリエーションがあり、改善確率 (PI: Probability of Improvement) 方策や期待改善量 (EI: Expected Improvement) 方策などがある。それぞれの方策の振る舞いの違いについて詳しくは [Brochu 10] を参照されたい。ここではその中でも直感的にわかりやすい実装である GP-UCB (Gaussian Process Upper Confidence Bound) を取り上げる。

■GP-UCB GP-UCB アルゴリズムは過去にサンプルされたデータからガウス過程を用いて特徴空間における期待値の分布を求め、その上側信頼限界を獲得関数として逐次的に観測点を選択するアルゴリズムである。つまり、時刻 t に特徴空間のある選択肢 x_t を観測した際に、ガウス過程によって求められた報酬の分布が期待値 $\mu_t(x)$ 、標準偏差 $\sigma_t(x)$ として与えられたとき、

$$x_{t+1} = \arg \max_{\mathbf{x} \in X} \mu_t(\mathbf{x}) + \sqrt{\beta} \sigma_t(\mathbf{x})$$

なる点を次の観測点とする操作を繰り返す。ただし、 β は上側信頼限界の幅を扱う超パラメータであり、探索と活用のバランスをコントロールする役割を担っている。 β が大きいと探索、小さいと活用を重視する振る舞いを示すようになる。

ガウス過程では RBF (Radial Basis Function) カーネル関数 $k(\mathbf{x}, \mathbf{x}') = \exp(-\|\mathbf{x} - \mathbf{x}'\|^2/\sigma^2)$ またはそれを一般化したマターンカーネル関数を用いることが一般的であり、このことが特定の分布の形を仮定しないノンパラメトリックな推定を可能にしている。一方で、用いるカーネル関数を変えることで、分布の形に過程を導入して探索の振る舞いを変化させることができる。たとえば、線形カーネル関数 $k(\mathbf{x}, \mathbf{x}') = \mathbf{x}^\top \mathbf{x}'$ を用いると、その挙動は期待値分布に線形モデルを仮定した UCB 方策、すなわち LinUCB と一致する。したがって UCB 方

策のバリエーションは用いるカーネル関数の違いとして表現できる。

■トンプソン抽出 トンプソン抽出は各選択肢が期待値最大である確率にもとづいてランダムに選択肢を抽出する確率一致法のひとつであり、確率的バンディット問題および文脈付きバンディット問題にも適用可能な手法である。トンプソン抽出では各選択肢の期待値の事後分布にもとづいて乱数を生成し、その乱数を最大にする選択肢を選択する手続きを繰り返す。連続腕バンディット問題に適用する場合には、離散化された特徴空間の各点についてガウス過程で推定された期待値分布に従って乱数を生成し、その乱数を最大とする特徴ベクトルを選択する。

2.3.3 ウェブサイト最適化への応用

現在、ウェブサイト制作の現場で用いられているウェブサイト最適化手法は、上記の探索手法を一部利用したり、組み合わせたりしたものとして表現できる。それらの対応関係は第3章で述べることにして、ここでは直接的にこれらの探索手法をウェブサイト最適化に導入した例を説明する。

メタヒューリスティクスを直接的にウェブサイト最適化に応用したものとしては、遺伝的アルゴリズムを採用したものが多いた。Aslliani らは遺伝的アルゴリズムを用いてウェブページを構成する要素の表示順を最適化する試みを紹介している [Asllani 07]。他にも、配色の最適化 [Park 07] やレイアウトの最適化 [Penalver 98] に遺伝的アルゴリズムが活用されている。2.1.3 で紹介した対話型進化計算も、遺伝的アルゴリズムもしくは遺伝的プログラミングを通して最適化を行う試みであった。このように人間の感性を扱う問題設定に遺伝的アルゴリズムが多く用いられる理由として、多点探索手法であるため適切な初期解についての知識がない場合でも適用できることがその理由のひとつとして考えられる。

ただし、遺伝的アルゴリズムを含むすべてのメタヒューリスティクスは、なんらかの初期解を生成し、近傍解から移動を繰り返すという意味では一般化された局所探索として表されることが示されている [柳浦 00]。したがって、遺伝的アルゴリズム以外のメタヒューリスティクスも導入可能と考えられる。たとえば多点スタートと焼きなまし法を組み合わせた方法も有効かもしれない。それぞれの手法で解の多様性を保つ機構および有望な解への集中化を行う機構の実装が異なるため、遺伝的アルゴリズムに限定せず、与えられた問題の特性に適した手法を選択することが重要である。

一方、バンディットアルゴリズムを用いてウェブサイトの表示を最適化した例として Yahoo! における Li らの取り組み [Li 10a] を紹介したが、その他にも検索エンジンにおけるディスプレイ広告の選択方法 [Lu 10, Li 10b] や、ゲームインターフェイスの最適化 [Lomas 16] など、その応用事例は多岐にわたる。また、バンディットアルゴリズムを導入すると統計的検定を行わずとも最適なバリエーションが表示される状態に収束するため、ウェブサイト最適化のプロセスを自動化する目的で用いられることがある [Kohavi 09].

2.3.4 本節のまとめ

本節では、離散非線形最適化問題への解法としてメタヒューリстиクスを取り上げ、様々な実装方法を説明した。決定論的なアルゴリズムからはじまり、確率分布を扱うアルゴリズムに拡張することで、評価関数をベイジアンネットワークによってモデリングできること、さらに評価値が統計的不確実性を含む場合でも対応できることを見てきた。

一方、バンディット問題においても、最も初歩的な確率的バンディット問題から非線形性かつ連続な評価関数のモデリングを可能にする連続腕バンディット問題へ拡張する様子を見てきた。確率的バンディット問題では各解を独立に扱うため、解の組合せ的構造を取り扱うことができないが、評価関数の期待分布のモデリングを行う文脈付きバンディット問題や連続腕バンディット問題に拡張することで、組合せ構造を持つ解に対する探索も可能になることがわかる。

メタヒューリстиクスから派生したベイジアン最適化アルゴリズムは、陽にベイジアンネットワークを扱って分布推定を行う。一方、バンディットアルゴリズムとして機能するベイズ最適化では、あるカーネル関数を用いたガウス過程によって分布推定を行う。ベイズの定理を用いて評価関数の分布推定を行い、最大値と期待される点を積極的に観測する点でこの二つは共通しているが、推定分布を記述するための手段としてベイジアンネットワークを用いるかカーネル関数を用いるかの違いがあると考えることができる。それぞれの探索手法は出発点こそ異なるものの、ある特徴空間における未知の関数の最大値を、ばらつきのある観測値からできるだけ少ない試行回数で推定する逐次的最適化の枠組みを提供する点では共通している。

2.4 評価指標にまつわる既存研究

ウェブサイト最適化において評価指標の設計はひとつの大きな問題領域であり、Google や Bing, Yahoo!を中心には様々な取り組みがなされている。評価指標にまつわる問題は大きくノイズが大きい評価指標の問題と、観測に時間がかかる評価指標の問題の二つに分けられる。ここでは、まずそれぞれの問題点とこれまでに提案してきた解決方法を概観する。

2.4.1 ノイズの問題

一つ目の問題として、ウェブサイト最適化におけるバリエーションの評価値には様々な要因によるノイズが入りやすいことがある。ウェブサイトを利用するユーザの属性は多岐にわたるが、ウェブサイト最適化を行う際にはそれらの違いは無作為化することによって、あるバリエーションに対する評価値に対するノイズとして扱うことになる。この過程で性別や年齢などのデモグラフィック情報、利用しているデバイスやオペレーティングシステムなどの利用環境情報などをノイズとして含むことになるため、ウェブサイト最適化における評価値はバラつきが大きくなる。他にも長期間テストを行う場合には時間帯や曜日による利用状況の違いや、特定のイベントの前後などもノイズを大きくする要因として考えられる。ウェブサイト最適化による改善のサイクルを高速化するには、この問題を克服して少數のサンプルサイズでもテストの結論を下せるようになることが重要な課題である。

Deng らはウェブサイト最適化においてノイズを小さくすることが、容易には満足されることがない問題である理由を以下の 3 点にまとめている [Deng 13].

■小さな効果量の追求 ウェブサイト最適化においては 1% 以下の変化でも貴重なものであり、特に Google や Bing などの大規模サイトでは、その小さな変化が年間数百万ドルという収益増につながる。一般的な平均値の差の検定として t 検定を想定した場合、検定に要するサンプルサイズは効果量 Δ の二乗の逆数に比例するため [Belle 98]、現実的なサンプルサイズで小さな目的指標の変化を特定するには、目的指標の分散を小さくすることが重要な課題となる。ただし、効果量は $\Delta = |\mu' - \mu|/\sigma$ として表される量であり、 $|\mu' - \mu|$ は目的指標にもたらされる変化量、 σ は目的指標の分散を表す。

■実験に使えるユーザ数の少なさ ウェブサイト最適化では、すべての訪問ユーザを実験に割り当てるのではなく、一部のユーザを実験のバリエーションに割り当てるのが一般的である。そのため、実験に用いることができるユーザ数は常に限られており、実験に必要なサンプルサイズを小さくすることが要求されている。また、同時に多くのバリエーションを試している場合でも、ひとつのバリエーションに割り当てるこことできるユーザ数は少なくなる。

■高速な仮説検証への要請 企業活動においては高速に収益性を向上し、競合企業より優位に立つことが重要である。ウェブサイト最適化を通した仮説検証の速度は企業の競争力となるものである。

ウェブサイト最適化における評価指標のノイズを小さくする方法としては、モンテカルロ・シミュレーションで用いられる分散低減法を持ち込んだ手法が提案されている [Deng 13, Guo 15]。この手法では、評価指標と相関関係のある指標を事前に行なった実験データから割り出し、その相関分に相当する分散を差し引くことで、よりバラつきの小さい代替指標をバリエーションの評価に用いている。これはユーザの属性に着目してクラスタリングを行い、クラスタ間の平均値の差異の影響をキャンセルすることに相当している。

一方で Borodovsky らは、評価指標に対してより当てはまりの良い確率分布を仮定することで、必要なサンプルサイズを小さくする手法を提案している。この研究では、クリック率を評価関数として最適化する場合には、すべてのユーザがある一定の確率でクリックを行うと仮定するポアソン分布よりも、ユーザによってクリック率が異なることを仮定する負の二項分布のほうが当てはまりが良いことを示している [Borodovsky 11]。

2.4.2 観測に時間がかかる問題

一方、評価指標によっては観測に時間がかかることによって、ウェブサイト最適化の高速化が阻まれる場合も考えられる。観測に時間がかかる要因としては、大きく二つの要因が考えられる。

ひとつめの要因は、評価指標の定義方法である。たとえば、ユーザの再訪問率はウェブサイトへの定着度を測る上で重要な指標であり、週間アクティブユーザ数 (WAU: Weekly Active Users) や月間アクティブユーザ数 (MAU: Monthly Active Users) といった形で計測される

ことがある。しかし、これらの指標はその定義上、計測にある程度の期間を設ける必要がある。他にも、Google や Bing などの検索エンジンサイトの検索結果ページにおける順位や、Google Play^{*7}や App Store^{*8}などのアプリケーション配信サービスにおける順位なども、各プラットフォームの情報の更新頻度に依存するため、定義上観測に時間を要する例として挙げられる。

ふたつめの要因は、評価指標が収束するまでに時間を要することがある場合である。ウェブサイト最適化においてテストするバリエーションによっては、ユーザがその変更に慣れ親しんだり、変更の影響を受けてユーザが習慣を変更したりするのに時間を要する場合がある。つまり、ユーザの行動は学習と伴って変化するため、バリエーションをテストし始めた直後のユーザ行動を参考にすると、長期的に見て誤った判断をしてしまう可能性がある。したがって、バリエーションの真の性能を評価するにはある程度の時間を置く必要があり、このことがウェブサイト最適化の高速化を阻害するひとつの要因となっている。ユーザの学習による評価値の収束の遅延を引き起こす要因として、以下のような要因が知られている。

■潜在的な因子への副作用 ウェブサイト最適化の評価指標に短期的には良い効果を与えるものの、その評価指標に潜在的に影響を与えるその他の指標に悪い影響を与えててしまうために、長期的に見ると評価値を棄損してしまう場合である。たとえば検索エンジンにおいて、検索結果ページに表示する広告の数を増やせば短期的には広告収益を増やすことができるかもしれないが、その結果使いにくくなればユーザが離脱して長期的には広告収益を減少させることになる [Dmitriev 16]。つまり、評価指標である広告のクリック数を追い求めると、サイトの使いやすさという潜在的に収益に影響を与える因子を棄損してしまう危険性がある。短期的な指標改善のみに注目して最適化を行うと、本来のサービスの使いやすさやユーザの満足度を棄損しまい、長期的に見ると誤った判断を下してしまう可能性がある。

■目新しさ効果 新しい機能やユーザインターフェースがウェブサイトに実装されると、ユーザがその珍しさから通常よりも活発に行動をしたり、逆に新しい変更に慣れ親しんでいないために目的の行動が達成できなくなったりすることがある。このとき、この変更によって影響を受ける行動に関連する評価指標を設定していた場合、短期的な指標変化のみに着目すると、その

^{*7} Google Play <https://play.google.com>

^{*8} iTunes Store <http://www.apple.com/jp/itunes/charts/free-apps/>

変更本来がもたらす効果を過大または過小に評価してしまう危険性がある。時間を経るとユーザーはその変更を学習するため、評価指標がその変更本来の効果を反映するようになる。したがって、実験に大きな変更が含まれる場合には、新しい機能を導入してから十分な期間を空けてから最適なバリエーションの決定を行うことが望ましい [Kohavi 09].

■持ち越し効果 ウェブサイトが継続的に実験を行っている場合、以前に行われていた実験の影響が次の実験に持ち越されてしまう場合がある。そのため、新しく実験を行う際には十分な期間を空け、さらにユーザのバリエーションへの割り当てを初期化することが望ましい [Guo 15].

この観測に時間を見る評価関数の問題に対処するために、いくつか手法が提案されている。Hohnhold らは Google の検索結果ページにおいて、過去に行った長期間に渡る実験結果を用いることで、未知のバリエーションから長期的に収束した後の広告クリック率を推定するモデルを構築する手法を提案した。過去の長期にわたるウェブサイト最適化の実験結果から、これらの特徴量と長期的に収束した後の広告クリック率の関係を線形回帰によって求めている。その結果、これらの特徴量さえ算出できれば、未知のバリエーションに対しても長期的なクリック率を推定できる [Hohnhold 15]。Bing も同様の手法を適用することで、長期的効果に着目することの重要性を述べている [Dmitriev 16].

過去の実験データを用いるのとは異なるアプローチとして、ウェブサイト最適化の評価指標と潜在的な因子の両方を直接最適化しようとする試みもある。Yahoo!の Agarwal らは Yahoo!のニュース欄について、バリエーションの評価指標であるクリック率と、ユーザが記事に興味を持ったことを示す滞在時間の両方を最適化する多目的最適化を行う手法を提案した [Agarwal 11]。提案された手法は Yahoo! トップページのニュース欄に表示するニュース記事選択の最適化に用いられた。その結果ユーザのニュースへの遷移率を高めるだけではなく、ニュース記事へ遷移後の滞在時間も向上するパレート解を探索することに成功している。

以上見てきたように、評価指標の設計はウェブサイト最適化の速度に大きな影響を与える。評価指標のノイズを小さくして必要なサンプルサイズを少なくする試みとしては、仮定する確率分布を変える工夫、分散低減法を利用する工夫などが提案されてきた。観測に時間を見る問題に対しては、バリエーションにある特徴表現を与えることで回帰分析によって推定する方法や、長期的に目的指標に影響を与えると思われる指標に対しても同時に多目的最適化を行う

方法が提案されてきた。

第4章で説明する第二研究では、ウェブサイトとユーザが相互作用するときに発生する即時的なフィードバックと目的指標に間に存在する関係を利用して、高速なウェブサイト最適化を実現する手法を提案する。これは目的指標と副次的な指標の間の相関関係を利用した分散低減法、およびバリエーションに特徴表現を与えることで回帰分析を行う長期的指標の推定手法に着想を得たものである。具体的な手法および評価については第4章にて述べる。

2.5 解空間にまつわる既存研究

ここまで既存研究はテストするバリエーションすなわち解空間が与えられることを前提としてきた。ここでは、ウェブサイト最適化でテストするバリエーションの生成と関連がある研究を説明する。ウェブサイト最適化を目的として、ウェブページのバリエーションの自動生成を実現した研究の例は、筆者の知る限り存在しない。しかし、ウェブページを解析したり、その結果を組み合わせることで新しいウェブページのデザインを生み出した事例は存在する。ここでは、ウェブページの解析、およびウェブページの生成にまつわる研究を紹介する。

2.5.1 ウェブページの解析

ウェブページを解析する試みは Webpage Segmentation と呼ばれ、情報抽出 (Information Retrieval) および検索エンジン開発の分野で活発に研究が進められてきた [Nie 09]。Webpage Segmentation は、ウェブページを解析して情報のかたまりとして表現することを目的としており、主にウェブページが記述された HTML^{*9} に記述された DOM^{*10} の木構造に着目するアプローチと、レンダリングされた視覚情報に着目するアプローチに分けられる。

DOM の木構造に着目したアプローチ

ウェブページを HTML で記述されたテキスト情報として解析し、ソースコードに記述されている DOM 情報に着目してウェブページを構成する要素を抽出するアプローチである。DOM を構成する HTML タグに着目した手法では、<table> や などの特定のタグが

^{*9} HyperText Markup Language: ウェブページを記述するための言語。

^{*10} Document Object Model: HTML および XML 文章を木構造をもったオブジェクトとして扱う枠組み。

ウェブページのレイアウトおよびコンテンツの分割にとって大きな役割を果たしていることに着目し、ウェブページを分割する指針として活用している [Lin 02]。テキスト情報に着目した手法には、要素内に含まれる文字列の密度に着目したもの [Kohlschütter 08]、要素内に含まれる単語に意味解析を行なってその類似度に着目したものなどがある [Joshi 09]。

これらのアプローチはテキスト情報をそのまま扱うので、低コストで解析を行うことができるというメリットがある。しかし HTML タグの利用法はウェブサイト開発者によって異なる上に、記法の流行り廃りもあるため、同一のアプローチがあらゆるウェブページに適用できるとは限らない。また、近年はブラウザが HTML5^{*11}に対応したことによって CSS^{*12}の表現力が増しており、DOM 情報のみから視覚情報を推定することは難しくなっている [Kumar 11]。そのため、このアプローチだけで高い解析精度を実現することは難しいのが現状である。

レンダリングされた視覚情報に着目したアプローチ

ウェブページをレンダリングすることでウェブページ全体を画像として捉え、コンテンツを分割するエッジを検出することでブロックへの分割を行うアプローチである。代表的なものに、VIPS アルゴリズムがある [Cai 03]。VIPS アルゴリズムでは、DOM の葉ノードをサブブロックとして列挙し、その間に存在するエッジを画像情報から見つけ出すことによって、ウェブページのブロック分割を行う。分割されたブロックのツリー構造を再構築する Zone Tree Model という手法も提案されている [Le 06]。視覚情報のみに基づいて解析を行うため、HTML の記法や CSS の記法の影響を受けることなくブロックへの分割が可能である。しかし、画像へのレンダリング処理を行うため、テキスト処理に比べて膨大な計算量が必要になるというデメリットがある。

2.5.2 ウェブページの生成

ウェブページを自動生成する試みは、デスクトップ向けのウェブページを自動でスマートフォン向けのページにレイアウトを再生成したり、ユーザの嗜好に応じてウェブページのデザインを自動で変更することを主な動機として研究が行われてきた。レイアウトの再生成には、

^{*11} HTML の 5 回目にあたる改訂版。新たな HTML タグや CSS 属性が追加され、文章以外の要素をより柔軟に表現できるようになった。

^{*12} Cascading Style Sheets: ウェブページの視覚情報を記述するための枠組み。

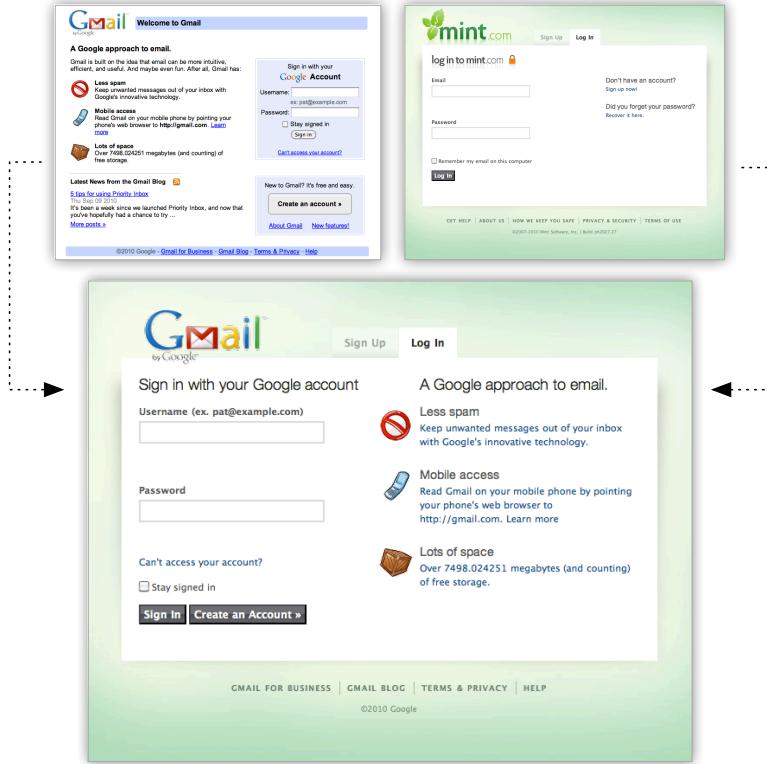


図 2.5: Bricolage によるテンプレートとコンテンツの入れ替え (図は [Kumar 11] より引用)

Web Page Segmentation で抽出したブロックの重要度の推定が密接に関わっており、重要度が高いものから優先的に並べていくアプローチがある [Bajwa 06, Thompson 09].

同じドメインに含まれているウェブページの HTML ファイル同士の差分を取ることで、各要素の重要度を推定する手法が提案されている。これによって、広告やナビゲーションなどコンテンツと関係のない部分を重要度の低いノイズとして取り除くことができる [Sengamedu 08]. また、複数のウェブサイトの要素の対応付けをユーザに入力してもらうことで学習し、テンプレートとコンテンツを入れ替えて新しいウェブページを生成する Bricolage と呼ばれる手法も提案されている [Kumar 11]. テンプレートとコンテンツが入れ替えられた例を図 2.5 に示す.

2.6 ウェブサイト最適化の実装手法

現在、ウェブサイト最適化は大小問わず様々なウェブサイトに導入されており、収益性の向上に貢献している [Kohavi 14]. それに伴い、適切なウェブサイト最適化を実施するまでの知見も共有されるようになってきた. Kohavi らは、自身が務める Microsoft での A/B テストの経験に加え、様々なウェブサイト最適化事例から共通して見られる特徴およびノウハウをまとめている [Kohavi 12]. ここでは特に、ウェブサイト最適化の具体的な実装方法および利用可能なツールについて説明したい.

2.6.1 バリエーションの割り当て方法

ウェブサイト最適化において、ユーザをバリエーションを割り当てる方法には、大きく分けて主にサーバサイド方式とクライアントサイド方式の二つがある [Kohavi 09]^{*13}.

サーバサイド方式

サーバサイド方式は、ウェブサーバ上でバリエーションの割り当ておよび当該バリエーションを表示するための操作を行う方式である. サーバサイド方式の全体像を図 2.6 に示す. サーバサイド方式では、ユーザがウェブブラウザを介してウェブサーバにリクエストを送った後、ウェブサーバ側内でバリエーションへの振り分け、およびバリエーションを表示するための操作がウェブページに適用される. その後、操作が加えられたウェブページが HTML ファイルのレスポンスとしてブラウザに返され、ユーザがそれを閲覧することでバリエーションの割り当てが完了する.

サーバサイド方式は構成がシンプルであるのが利点である. また、データベースへの接続が必要になるような複雑な機能をテストしたい場合でも、サーバサイドのプログラムを書き換えることで、バリエーションとして割り当てることができるため、実験できるバリエーションの柔軟性が高い.

^{*13} [Kohavi 09] では、ユーザの分配方法を Traffic splitting, Page rewriting, Client-side assignment, Server-side assignment の四種類に分けているが、ここではブラウザ上での書き換えの有無に着目して、Traffic splitting および Page rewriting を Server-side assignment に含めている.

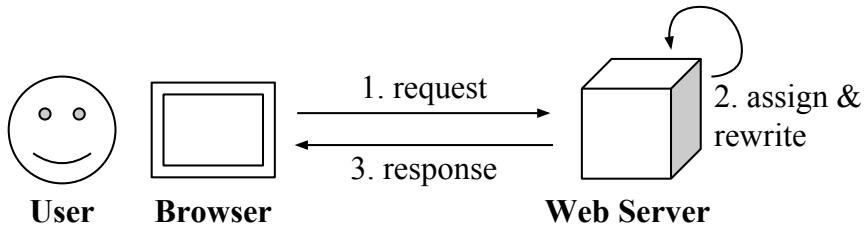


図 2.6: サーバサイド方式の全体像

しかし、実験を行うためにはサーバサイドのプログラムを直接書き換える必要があるため、もし意図しない操作を修正に入れ込んでしまうと（つまりバグを埋め込んでしまうと）、ウェブページの表示そのものができなくなる可能性がある。この状況を避けるためには、自動テストを徹底する、例外処理を適切に行うなどの工夫を徹底することが有効だと考えられる。また、複雑な機能をバリエーションとして試すためには、プログラムを書き換えるためのプログラミング能力が必要になるため、ウェブサイトに関わるエンジニア以外が操作を加えにくいう側面もある。したがって、ウェブサイト最適化の運営者が直接プログラミングを行うことができる環境において、有効な方式であると考えられる。

クライアントサイド方式

クライアントサイド方式は、ウェブサーバから受信した HTML ファイルを Javascript によって記述されたプログラムを用いて書き換えることで、バリエーションを表示する手法である。クライアントサイド方式の全体像を図 2.7 に示す。クライアントサイド方式では、ユーザがブラウザを介してウェブサーバにリクエストを送った後、ウェブサーバから HTML ファイルのレスポンスが返ってくる。その HTML ファイルには Javascript のプログラムが実行されるようになっており、Javascript プログラムがウェブサイト最適化専用のサーバにリクエストを送る。ウェブサイト最適化専用のサーバでバリエーションの割り当てが行われ、その操作を行うのに必要なデータと共にレスポンスが返される。Javascript プログラムはそのデータを元に HTML ファイルに操作を加え、ブラウザ上で表示されることで、バリエーションの割り当てが完了する。

サーバサイド方式に比べると構成が複雑になるデメリットがあり、テストできるバリエーションの種類もウェブサイト最適化サーバが扱うことができるものに限られる。そのため、単

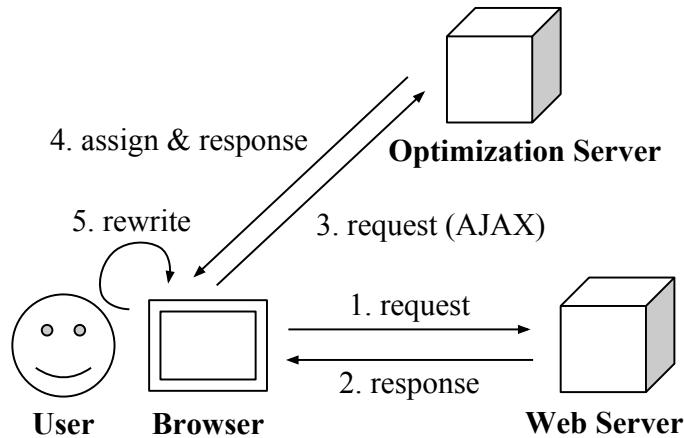


図 2.7: クライアントサイド方式の全体像

純な表示の切り替えはできても、複雑な機能のテストを行うことは難しい。

しかし、ウェブサーバの機能とウェブサイト最適化の機能が分離されているため、万が一ウェブサイト最適化の設定の際にバグが埋め込まれてしまった場合でも、通常のウェブサイトを表示する機能を担保することができる。また、ウェブサイト最適化の運営者はウェブサイト最適化サーバのみを触れば良いため、ウェブサイト最適化サーバが適切なインターフェイスを持っていれば、プログラミング能力が無くてもウェブサイト最適化の運用ができる。このような特性もあり、ウェブサイト最適化ツールはこちらの方式を取り入れていることが多い。

2.6.2 代表的なウェブサイト最適化ツール

最後に、いくつか代表的なウェブサイト最適化ツールを紹介する。プログラミングせずにバリエーションを生成できる GUI ツールの提供や、よい高速に高速なバリエーションを発見するアルゴリズム、モバイル・アプリケーションとの統合の容易さなどがお互いを差別化する争点となっている。なお、ここで述べる情報は 2017 年 3 月現在のものであり、今後提供されるサービスは多少なりとも変更されることが予想される。

- **Apptimize^{*14}** モバイルアプリの最適化に特化したサービス。専用の Software Development Kit (SDK) をインストールすることで、グラフィカルユーザインタフェ

^{*14} <https://apptimize.com/>

ス (GUI) を用いてバリエーションを制作できる。ウェブと異なり、モバイルアプリは公開に際してアプリプラットフォームによる審査を要することが多い。そのため、Apptimize のように公開後にもデザイン要素の最適化を行うことができるツールへの需要は大きい。

- **Conductrics^{*15}** ウェブサイトむけの最適化ツール。GUI によるバリエーションの制作をサポートしている。パフォーマンスの違いを説明するために、決定木によってユーザをクラスタリングする機能を持っており、レポート結果の説明力向上に注力している。
- **Google Analytics Content Experiments^{*16}** 2012 年から Google が無料で提供しているウェブサイト最適化ツール。ユーザに表示したいバリエーションの URL を指定することで、ユーザをリダイレクトによってバリエーションを振り分けてパフォーマンスを比較することができる。ユーザの振り分け方法を決定するアルゴリズムとしてバンディットアルゴリズムが用いられていることが知られており、中でもトンプソン抽出が用いられている [Russo 16]。
- **Google Optimize^{*17}** 2016 年に Google が公開したウェブサイト最適化ツール。有償版の Google Optimize 360 と無償版の Google Optimize が提供されている。Google Analytics Content Experiments ではリダイレクトによるバリエーションの振り分けのみがサポートされていたが、Google Optimize では Conductrics や Optimizely と同様に、オリジナルのウェブページを Javascript, CSS によって書き換えることで同一 URL で複数のバリエーションを表示する A/B テストおよび多変量テストもサポートしている。また、GUI によるバリエーションの制作機能も提供されている。
- **The Grid^{*18}** 表示するコンテンツを与えると、そのコンテンツに合わせて自動的にデザインが施されたウェブサイトを出力するサービス。未だにすべての機能は提供されていないが、目的指標を最大化するように自動でデザインを改善する機能が提供されると言われている。

*15 <https://conductrics.com/>

*16 <https://www.google.com/analytics/>

*17 <https://www.google.com/analytics/optimize/>

*18 <https://thegrid.io/>

- **Kaizen Platform^{*19}** Kaizen Platform の特徴は、クラウドソーシングを用いたバリエーションの制作をサポートしている点である。利用者が直接コーディングすることでバリエーションを製作することも可能であるが、Kaizen Platform と契約しているデザイナーにバリエーションの制作を依頼することで、利用者はデザイン案を考えることなくウェブサイト最適化を実施することができる。
- **Optimizely^{*20}** 第 1 章で紹介したオバマ氏によるキャンペーンの解析チームの長を務めた Dan Siroker 氏によって開発されたウェブサイト最適化ツール。もともとはウェブサイト最適化に特化していたが、現在はモバイルアプリの最適化にも対応している。GUI によるバリエーションの制作もサポートしている。
- **Taplytics^{*21}** モバイルアプリに特化したサービス。ウェブブラウザ上の GUI でバリエーションを制作する機能をサポートしている。
- **Visual Website Optimizer^{*22}** GUI によるバリエーションの制作をサポートしたウェブサイト最適化ツール。ヒートマップの可視化、ユーザの自動セグメンテーションなど、より豊かな解析を可能にする機能が充実している。
- **AI アナリスト^{*23}** Google Analytics によって収集されたデータを解析することで、ウェブサイトの改善案を提供するサービス。株式会社 WACUL^{*24}が提供している。

*19 <https://kaizenplatform.com>

*20 <https://www.optimizely.com/>

*21 <https://taplytics.com/>

*22 <https://vwo.com>

*23 <https://wacul-ai.com/>

*24 <https://wacul.co.jp/>

第3章

線形性仮定と局所探索を組み合わせた探索手法の提案

3.1 本章の背景と目的

本章では第一研究として、高速なウェブサイト最適化を実現するための探索手法の設計に取り組む。ユーザの反応から測定できる指標を目的関数、各バリエーションを解とすると、ウェブサイト最適化は最もユーザの好ましい行動を引き出すバリエーションを探索する問題と捉えることができる。ウェブサイト最適化の探索問題としての特徴は、ユーザにバリエーションを表示したときに得られる観測値を用いて最適なバリエーションを探索することである。バリエーションの評価に人間であるユーザの介在を要するため、計算のみで解を評価できる数理的最適化問題に比べると解の評価に要するコストが大きい。しかも、同じバリエーションに対してユーザが示す反応は一般にばらつくため、ひとつのバリエーションを複数回表示して得られる統計量によって評価する必要がある。したがって、ウェブサイト最適化では解の評価回数を減らすことが実施コストを小さくする上で中心的な課題となる。そこで本章ではウェブサイト最適化を探索問題として捉え、より高速に、つまり少ない解の評価回数（すなわちユーザ数）で最適なバリエーションを発見する探索手法を構築することを目的とする。

高速な探索方法を構築するためには、対象とする問題の特性を十分に活用することが肝要である。なぜならノーフリーランチ定理 [Wolpert 97] でも述べられているとおり、全ての問題に対して万能に動作する探索手法は存在せず、手法の性能を比較できるのは対象とする問題領

域においてのみだからである。ウェブサイト最適化において高速に動作する探索手法を構築するには、ウェブサイトとユーザの相互作用から生じる目的指標の特性を活かすことが本質的な課題となる。

ここで第2.3節で述べた既存の探索手法に目を向けると、バリエーションに組み合わせ構造を仮定すること、すなわち解に何らかの特徴表現を与えることが効率的な探索手法を実現する上で重要であることがわかる。たとえば、組合せ最適化問題に対する解法としてよく用いられるメタヒューリスティクスを用いた探索手法は、解の近傍では大きく評価値が変わることがないことを前提としており、基本的にはすべて局所探索をベースとしたものである[柳浦00]。これはつまり、解に特徴表現を与えたときに発現する「良い解の周辺には良い解が存在する」という空間構造の特徴を高速な探索のために活用していると捉えることができる。解に組み合わせ構造を与えることでその空間構造を有効活用することが可能になり、探索を高速化できることが実問題では多い。

また、第2.1節で述べたように、できるだけ少ない解の評価回数で最適解を探し出したいという問題意識は農業や製造業にも共通するものであるが、これらの分野では実験計画法、特に直交計画が活用されている。直交計画は高次の交互作用を無視できるという仮定を置くことで、試行すべき解の数を絞り込む手法である。一般的には、その分野に精通した技術者の手によって検討すべき交互作用が特定され、それぞれの要素の主作用と一部の要素の交互作用のみを評価できるように直交表を用いて試行する解を特定する。もし全く交互作用が無いと仮定すれば、本来ならば a^n ある組み合わせの数を na 程度に削減できるのでその効果は大きい。ここでは n は解を構成する要素の数（因子数）、 a は各要素が取りうる値の数（水準数）とした。各要素の効果が独立であること、つまり目的関数が各要素の線形結合による線形モデルで表されることを仮定することで試行回数を大きく減らすことができ、また問題によってはこの仮定が有効に働くことが多い。この仮定を探索手法に取り入れることで、ウェブサイト最適化においても高速な探索を実現できる可能性がある。

そこで本研究では、各要素の効果が独立である場合に高速に動作する線形モデルと、非線形性な目的関数に対しても汎用的に動作する局所探索を組み合わせた探索手法を提案する。提案手法の概観を図3.1に示す。提案手法は初期解決定フェーズと局所探索フェーズの二つのフェーズによって成り立っている。初期解決定フェーズでは解空間全体から解を抽出して評価

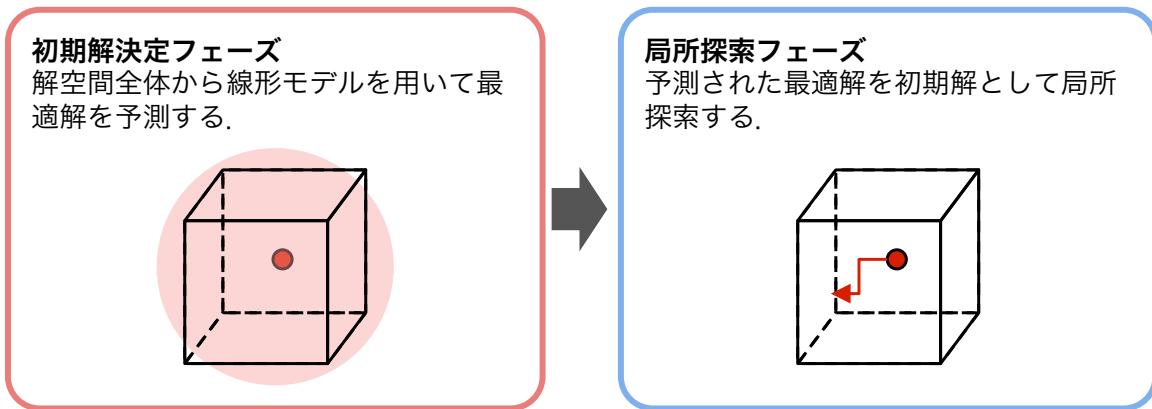


図 3.1: 提案手法の概観

を行い、線形モデルを適用することで最適解を予測する。局所探索フェーズでは初期解決定フェーズで推定された最適解を初期解として局所探索を行い、線形性を仮定することによって見過ごされてしまった性能の良い解を発見することを目指す。

評価実験では、実際のウェブサイトに提案手法を適用することでその有用性を評価する。一日に数万人のユーザが訪れる大規模ウェブサイトと、一日に数百人のユーザが訪れる小規模ウェブサイトの双方を対象とすることで、提案手法がウェブサイトの規模に関わらず有用であることを確かめる。

本研究の貢献は以下のとおりである。

- ウェブサイト最適化問題の定式化をもとに、既存のウェブサイト最適化手法およびその工夫を整理した。ウェブ研究者はこれらの手法および工夫を組み合わせることで、新たなウェブサイト最適化手法を編み出すことが可能になる。
- 少ないユーザ数で性能の良いバリエーションを発見する手法を提案し、評価した。ウェブサイト運営者は本手法を用いることでより高速にウェブサイトの収益性を向上することができる。

本章の構成は以下のとおりである。第3.2節にて提案手法について説明し、第3.3節にて評価実験を行う。第3.4節にて議論を行い、第3.5節を本章のまとめとする。

3.1.1 既存のウェブサイト最適化手法

ここでは、ウェブサイト制作の現場で用いられることが多い既存のウェブサイト最適化手法が、ウェブサイト最適化問題の解法として整理できることを示す。

A/B テスト

A/B テストは最も単純なウェブサイト最適化手法であり、オリジナルのバリエーション (Control) と操作を施したバリエーション (Treatment) 間の比較対照実験である。もともとのバリエーションとある操作を施したバリエーションを用意し、ウェブサイトを訪問したユーザをランダムに振り分ける。それぞれのバリエーションにおけるユーザの振る舞いを比較することで、最適なバリエーションを探索する手法である。複数の操作を一度に加えてしまうと、効果を生み出した操作を特定することが難しくなるため、適用する操作はひとつに絞ることが多い。

また、最適化する対象が要素の組み合わせとして表現できるとき、ひとつの要素に対して複数の値を適用することで三つ以上のバリエーションを生成する手法もある。このような実験方法を **A/B/n テスト** と呼ぶ。この場合、もともとのバリエーションを含め三つ以上の実験群の間の効果を評価することになる。そのため、統計的検定によって評価をする場合、評価する仮説によっては多重比較法を用いる必要がある。

多変量テスト

A/B テストは解を構成するひとつの要素について最適な値を探す上では有用な手法だが、最適化したい要素が複数ある場合は、A/B テストではひとつの実験が終わるまでは他の変数の最適化を行うことができないため、時間がかかってしまう。そこで、複数の要素の最適化を同時に一回のテストで行うのが**多変量テスト** (Multivariate Testing) である。多変量テストでは複数の要素に対して操作を加えることで生成されるすべての組み合わせを解候補として列挙する。解候補にユーザを割り振り、それぞれのユーザの反応を比較することで最適解を探索する [Ash 12]。多変量テストには、すべての組み合わせにユーザを割り当てて実験を行う**総当たり実験** (Full Factorial Test Design) と直交計画を取り入れることで評価すべき解候補を絞り込む**直交計画実験** (Fractional Factorial Test Design) のアプローチがある。

総当たり実験ではすべての組み合わせを試すため、すべての要素間の交互作用を含めて厳密に最適な解を発見することができる。一方で、最適化対象とする要素の数が増えるごとに解候補のサイズが指数関数的に増加するという欠点がある。一方、直交計画実験では、着目する交互作用を絞り込むことでテストすべき解候補の数を大きく減らすことができる。総当たり実験では最適化する要素の数 k に対して $O(c^k)$ の指数オーダーで解候補の数が大きくなるのに対し、解の交互作用を考えない最も楽観的な場合では $O(k)$ の線形オーダーに解候補の増加を抑えることができる。しかし、もし実験計画を組む際に有意に大きい交互作用を組み込まなかった場合には、直交計画実験の結果だけでは厳密に最適な解を見つけることができない。

バンディットアルゴリズム

2.3.3 項で述べたように、ウェブサイト最適化にバンディットアルゴリズムが用いられることが多い。バンディットアルゴリズムは解の組み合わせ構造を仮定しなくても適用することができる。探索によってパフォーマンスの低いバリエーションをユーザに表示することによる損失を最小限に抑えながら、有望なバリエーションを探索する方策を提供するものである。

3.1.2 既存のウェブサイト最適化手法の整理

既存のウェブサイト最適化手法を、式 2.1 で表されるウェブサイト最適化問題に対する解法および工夫として整理したものを表 3.1 にまとめる。A/B テストを繰り返すことは、無作為に選んだ解を初期解 x_0 として局所探索することに相当している。近傍解の生成では、現状の解 x を構成する変数からひとつの変数 x_i を選び、その変数が取りうる値の集合 V_i に含まれる値に入れ替えることで近傍解 X' を生成する。近傍解の評価値の期待値が暫定解より高ければ、その近傍解で暫定解を更新することでひとつの A/B テストが完了する。その後新たな変数 x_j を取り出して再び A/B テストを行うことで、探索を繰り返すことができる。

総当たり実験は実行可能解すべてを評価する総当たり探索に相当する。直交計画実験もあらかじめ設定された解については全て評価する点では総当たり探索である。しかし直交計画実験の特徴は、解を構成する要素の間の高次の交互作用は無視できると仮定して、評価する解候補を絞り込んでいることである。この極端なケース、すなわち全く交互作用を考えずにそれぞれの要素の効果が独立であることを仮定することは、下式で表される線形モデルで評価関数を仮定して

表 3.1: 既存のウェブサイト最適化手法の整理

最適化手法	解法	高速化の工夫
A/B テスト	局所探索	なし
総当たり実験	総当たり	なし
直交計画実験	総当たり	線形性仮定
バンディットアルゴリズム	総当たり	動的サンプル割り当て

最適解の推定を行っていることに相当する。

$$f(\mathbf{x}) = g_1(x_1) + \cdots + g_m(x_m) + a$$

ただし $g_i(x_i)$ は変数 x_i の評価関数 $f(\mathbf{x})$ への寄与を表しており, a は定数である。本研究ではこの線形モデルを仮定する工夫のことを**線形性仮定**と呼ぶことにする。

バンディットアルゴリズムも同様に与えられた解候補全てを評価する意味では総当たり探索に分類される。しかし重要な特徴は、バンディットアルゴリズムは各時点での評価値の期待値 $\mathbb{E}[y|\mathbf{x}]$ に応じてバリエーション \mathbf{x} に割り当てるサンプルサイズを変化させていることである。より有望なバリエーションに多くのサンプル（ユーザ）を割り当てることで、最適解の探索を高速化する。本研究では、この工夫のことを**動的サンプル割り当て**と呼ぶことにする。

以上、既存のウェブサイト最適化手法を一般的な組合せ最適化問題に対する解法および工夫として整理してきた。実際、第 2.6.2 項で述べた多くのウェブサイト最適化ツールでは、この単純な局所探索に相当する A/B テストもしくは総当たり実験が利用可能な探索方法として提供されている。これらの既存のウェブサイト最適化手法に対して、より高速な最適化手法を構築することが本研究の狙いである。

3.2 提案手法

3.2.1 局所探索法を用いた解法

最適化の対象となるウェブページが要素の組み合わせによって表される場合、ウェブサイト最適化問題は組合せ最適化問題として表現できるため、組合せ最適化問題に対する一般的な解法を導入することができる。また、少ないサンプルサイズで最適解を探索したい場合には、観

測回数に対して強い制約が与えられているため、最適性の保証は無いが高速に近似解を得ることができるヒューリスティクスを用いた探索手法が相性が良いと考えられる。そこで、ここでは組合せ最適化に対する近似解法の中でも特に単純な局所探索法を用いた場合について説明する。これは単純な A/B テストを繰り返すことに相当するものである。

局所探索法のアルゴリズムをウェブサイト最適化問題に適用する際の手続きを Algorithm 1 に示す。一般的な組合せ最適化問題と異なり、ウェブサイト最適化では解に対する評価値が確定的に与えられないため、 t 検定による期待値の差の評価を行っている点が特徴的である。

探索が始まると、まず与えられた有意水準 α 、検定力 $1 - \beta$ 、期待する効果量 Δ から t 検定を行うために必要なサンプルサイズ N_{T-TEST} を算出し、 N_1 とする（行 2）。有意水準 α は帰無仮説を棄却する正確さを表す。検出力 $1 - \beta$ は比較する解の評価値の差を検出することができる確率を表す。効果量 Δ は解の評価値の差を標準偏差を用いて標準化したものである。ただしサンプルサイズの算出には [Cohen 88] の方法を用いるものとする。その後、無作為に解を選択することで初期解 $x \in X$ を設定する（行 3）。この初期解を暫定解 x^* とし、暫定解の要素の一部を書き換えることで近傍解 $x' \in X'$ を得る（行 5）。サンプルサイズ N を割いて暫定解と近傍解に対する観測値を得た後、 t 検定を用いてお互いの評価値の期待値を比較し、近傍解の期待値のほうが暫定解よりも良ければ、近傍解で暫定解を更新する（行 6）。このとき、この探索は N_1 個のサンプルを消費したことになる（行 7）。局所探索法ではこの行 5,6,7 の手続きで表される**近傍解の生成と暫定解の移動**を繰り返すことで最適解を求める。この繰り返しは、実験に与えられたサンプルサイズの上限 N に累計消費サンプル n が到達するまで行われる。

3.2.2 線形性仮定を導入した解法

もし解候補の数が小さく、かつ得られるユーザ数すなわちサンプルサイズが十分大きいならば、総当たり探索を導入もしくは局所探索法を導入することで最適解を発見することができると考えられる。しかし、小規模のウェブサイトではこの仮定が成立するとは考えにくく、少ないサンプルサイズから最適解を推定できるような手法が望まれている。そこで、既存のウェブサイト最適化手法から抽出された線形性仮定と動的サンプル割り当ての二つの工夫を導入することで、より高速な探索が可能になることが期待される。そこで、これらの工夫を局所探索法に

Algorithm 1 局所探索法のアルゴリズム

Require: α as the significance level.

Require: $1 - \beta$ as the power.

Require: Δ as the effect size.

Require: N as the sample size bound.

Require: X as the set of solutions.

- 1: Set $n \leftarrow 0$ as the number of consumed samples.
- 2: Set $N_1 \leftarrow N_{T-TEST}(\alpha, \beta, \Delta)$
- 3: $\mathbf{x}^* \leftarrow RandomChoice(X)$
- 4: **while** $n < N$ **do**
 - 5: $\mathbf{x}' \leftarrow Neighbor(\mathbf{x}^*, X)$ ▷ 近傍解の生成
 - 6: $\mathbf{x}^* \leftarrow Compare(\mathbf{x}^*, \mathbf{x}', N_1)$ ▷ 暫定解の移動
 - 7: $n \leftarrow n + N_1$
- 8: **return** \mathbf{x}^* as the optimal solution.

導入した場合のアルゴリズムの修正について説明する。

本項では、まず線形性仮定の導入について検討する。この工夫を導入することで、高次で影響の小さい交互作用をモデルから排除し、評価する解候補の数を絞り込むことができる。ここでは暫定解と近傍解の一対一の比較を繰り返すことによる局所探索を想定しているため、暫定解の移動部分に線形性仮定を導入する余地は小さい。しかし、初期解の決定部分に線形性仮定を導入した探索を行えば、一定量のサンプルを利用することにはなるが、無作為に抽出した場合に比べて良い解を初期解として設定して探索を始められると考えられる。そこで、探索の初期解の決定に線形性仮定を導入することで、より良い解から探索を開始することができることを検討する。

初期解の決定に線形性仮定を導入した手法を、ここでは **LALS** (Linear Assumption – Local Search) アルゴリズムと呼ぶことにする。概要是図 3.1 に示したとおりである。LALS アルゴリズムは初期解決定フェーズと局所探索フェーズの二つのフェーズによって成り立っている。初期解決定フェーズでは、解空間からまんべんなく観測を行って全体の傾向を把握した上で線形モデルを適用して最適解を推定する。局所探索フェーズでは、線形性を仮定することによって見過ごされてしまった最適解を近傍探索によって発見することを期待している。

Algorithm 2 に手続きの概要を示す。局所探索法 (Algorithm 1) から修正を加えた部分は赤字で示している。LALS アルゴリズムでは、暫定解の移動に用いる t 検定のためのサンプルサイズ N_2 に加えて、初期解決定に必要なサンプルサイズ N_1 を算出する (行 2, 3)。線形性仮定によって最適解を予測するのに要するサンプルサイズ N_1 には、各変数がとる変数値によって評価値が変化することを検出するのに十分な大きさが求められる。ここでは一元配置分散分析に必要なサンプルサイズ N_{ANOVA} を用いることとする。ただし、予測のためには各変数のすべての値について観測値を得られればいいので、群の数 $k = \sum_{i=1}^m l_i$ として算出するものとする。ここでもサンプルサイズの算出には [Cohen 88] の方法を用いるものとする。

Algorithm 2 LALS アルゴリズム

Require: α as the significance level.

Require: $1 - \beta$ as the power.

Require: Δ as the effect size.

Require: N as the sample size bound.

Require: X as the set of solutions.

- 1: Set $n \leftarrow 0$ as the number of consumed samples.
 - 2: Set $N_1 \leftarrow N_{T-TEST}(\alpha, \beta, \Delta)$
 - 3: Set $N_2 \leftarrow N_{ANOVA}(\alpha, \beta, \Delta, X)$
 - 4: $\mathbf{x}^* \leftarrow LinearAssumption(X, N_2)$ ▷ 線形性仮定による初期解決定
 - 5: $n \leftarrow n + N_2$
 - 6: **while** $n < N$ **do**
 - 7: $\mathbf{x}' \leftarrow Neighbor(\mathbf{x}^*, X)$
 - 8: $\mathbf{x}^* \leftarrow Compare(\mathbf{x}^*, \mathbf{x}', N_1)$
 - 9: $n \leftarrow n + N_1$
 - 10: **return** \mathbf{x}^* as the optimal solution.
-

LALS アルゴリズムでは、初期解を無作為に選択する代わりに N_1 のサンプルを費やして各解候補の評価値を収集する (行 4, 5)。このとき、解空間 X 全体から解を N_1 回無作為に抽出して観測値を収集するものとする。 N_1 のサンプルが集まった後に各要素について期待値の大小を評価し、各要素について最も期待値が大きい要素を組み合わせることで最適解を推定する。つまりこの操作は、各要素の効果に線形性が成り立つことを仮定して最適解を推定して

いる。

3.2.3 動的サンプル割り当てを導入した解法

LALS アルゴリズムの初期解決定フェーズおよび局所探索フェーズに動的サンプル割り当てる工夫を導入することによって、さらに探索を高速化できると考えられる。ここではバンディットアルゴリズム、なかでもレーシングアルゴリズムによる各フェーズへの動的サンプル割り当てる適用を検討する。動的サンプル割り当てるによってサンプルサイズを節約するにはレーシングアルゴリズム以外のバンディットアルゴリズムも有効であるが、レーシングアルゴリズムは勝者決定のメカニズムを持っているため、比較評価の終了時点がわかりやすい。このような特徴が提案手法のアルゴリズムにおける近似解の評価と相性が良いと考え、ここではレーシングアルゴリズムを用いることにする。

初期解決定フェーズでは、各要素の値について期待値の大小が比較される。このとき、他の値の下側信頼限界よりも低い上側信頼限界を持つ値は敗者値として、その要素についてその敗者値を持つ解は解候補から外すことができる。また、すべての要素について勝者値が求めれば、その勝者値を組み合わせることで線形モデルにおける最適解を推定することができる。以上の操作によって、初期解決定フェーズに動的サンプル割り当てる工夫を導入することができる。局所探索フェーズに動的サンプル割り当てる適用すれば、暫定解と近傍解のいずれかの下側信頼限界が他方の解の上側信頼限界を上回った時点で、即時その解を勝者解として確定して暫定解の移動を行い、サンプルの消費を抑えることができる。

以上のようにして初期解決定フェーズおよび局所探索フェーズに動的サンプル割り当てる導入したものを **LALS+** アルゴリズムと呼ぶことにする。LALS+ アルゴリズムの手続きを Algorithm 3 に示す。LALS (Algorithm 2) から修正を加えた部分は赤字で示している。

LALS+ アルゴリズムでも LALS アルゴリズムと同様に二種類のサンプルサイズ N_1, N_2 の算出を行う（行 2, 3）。LALS ではサンプル N_1 を割いて線形性を仮定した最適解の推定を行っていたところに、LALS では動的サンプル割り当てる導入する（行 4）。このようにすることで、問題によっては勝者決定によって N_1 を消費する前に最適解を推定することができる。したがって、初期解決定に用いるサンプルサイズを $n' < N_1$ に節約することができる可能性がある（行 5）。暫定解の移動においても、敗者解の除去および勝者決定の影響で、サンプル N_2

Algorithm 3 LALS+ アルゴリズム

Require: α as the significance level.

Require: $1 - \beta$ as the power.

Require: Δ as the effect size.

Require: N as the sample size bound.

Require: X as the set of solutions.

- 1: Set $n \leftarrow 0$ as the number of consumed samples.
- 2: Set $N_1 \leftarrow N_{T-TEST}(\alpha, \beta, \Delta)$
- 3: Set $N_2 \leftarrow N_{ANOVA}(\alpha, \beta, \Delta, X)$
- 4: $\mathbf{x}^*, n' \leftarrow DynamicLinearAssumption(X, N_2)$
- 5: $n \leftarrow n + n'$ ▷ レーシングアルゴリズムによるサンプル節約 ($n' \leq N_2$).
- 6: **while** $n < N$ **do**
- 7: $\mathbf{x}' \leftarrow Neighbor(\mathbf{x}^*, X)$
- 8: $\mathbf{x}^*, n' \leftarrow DynamicCompare(\mathbf{x}^*, \mathbf{x}', N_1)$
- 9: $n \leftarrow n + n'$ ▷ レーシングアルゴリズムによるサンプル節約 ($n' \leq N_1$).
- 10: **return** \mathbf{x}^* as the optimal solution.

を消費すること無く近傍解と暫定解を比較することができる可能性がある（行 8）。

3.3 評価実験

ここでは、提案手法によってウェブサイトのユーザ数の大小に関わらずウェブサイト最適化ができる事を検証する。まず様々なウェブサイトの状況を想定したシミュレーション実験を行う。次に実際の大規模ウェブサイトと小規模ウェブサイトに提案手法を適用することで、ユーザ数の大小に関わらず提案手法が有効であることを示す。

3.3.1 比較検討するアルゴリズム

今回の実験で比較検討するアルゴリズムを表 3.2 にまとめ。BF (Brute Force) は従来の総当たり実験に相当する最適化手法であり、解候補から無作為に解を選択して観測を行い、最も期待値が高いものを最適解として推定する。LA は従来の直交計画実験に相当する最適化手法であり、解候補から無作為に解を選択して観測を行うが、最適解は線形モデルに基いて推定す

表 3.2: 比較検討するアルゴリズム

アルゴリズム	初期解決定	局所探索
BF	無作為抽出	N/A
LA	線形性仮定	N/A
LS	無作為抽出	局所探索
LALS	線形性仮定	局所探索
LALS+	線形性仮定 + 動的サンプル割当	局所探索 + 動的サンプル割当

る。実際のウェブサイトでは起こり難いが、各要素の効果が完全に線形である場合には、この手法が理想的な探索手法となる。LS は従来の A/B テストに相当する最適化手法であり、無作為に選択した解から局所探索法による探索を行う。LS の近傍解の評価には t 検定に要するサンプルサイズ N_{T-TEST} の観測数を割くものとする。LALS, LALS+ については第 3.2 節で述べたとおりである。

3.3.2 仮想の評価関数によるシミュレーション実験

仮想状況におけるシミュレーション実験では、様々なウェブサイトの状況を想定して表 3.3 に記す問題を独自に設定し、それぞれの問題に対してベースラインアルゴリズムと提案アルゴリズムを適用した。評価関数は線形関数 $f_1(\mathbf{x})$ のときと非線形関数 $f_2(\mathbf{x})$ のときがあり、それ下式のように定義した。

$$\begin{aligned} f_1(\mathbf{x}) &= x_1 + x_2 + x_3 - x_4 - x_5 - x_6 + N(0, 1) \\ f_2(\mathbf{x}) &= x_1 + x_2 + x_3 - x_4 - x_5 - x_6 - x_1 x_2 + N(0, 1) \end{aligned}$$

ここでは変数の数 $m = 6$ 、それぞれの変数 x_i が $V = \{0, 1, 2\}$ のいずれかの値を取るものとして解空間および評価関数を設定した。 $N(0, 1)$ は平均 $\mu = 0$ 、標準偏差 $\sigma = 1$ の正規分布に従う確率変数である。 $f_1(\mathbf{x})$ では各変数にかかる符号が同回数現れるように工夫し、 $x_i = 0$ が最適解となる変数と $x_i = 2$ が最適解となる変数を同数含むようにしている。 $f_2(\mathbf{x})$ では同じ符号を持つ変数をふたつ取り出して掛けあわせて負の符号をつけた項 $x_1 x_2$ を加えることで、要素間の負の交互作用をもたらす非線形項を表現した。これによって、 $f_1(\mathbf{x})$ では最適解に含

表 3.3: シミュレーションの問題設定

問題	評価関数	限界観測数 N
1	線形関数 $f_1(\mathbf{x})$	500 ($N < N_1$)
2	線形関数 $f_1(\mathbf{x})$	2000 ($N > N_1$)
3	非線形関数 $f_2(\mathbf{x})$	500 ($N < N_1$)
4	非線形関数 $f_2(\mathbf{x})$	2000 ($N > N_1$)

まれた $(x_1, x_2) = (2, 2)$ が $f_2(\mathbf{x})$ では最適な値の組み合わせでなくなっている。ここでいう非線形性とは、 $g_1(x_1)g_2(x_2)$ のように複数の変数の交互作用をもたらす非線形項が評価関数に含まれることを指すものとする。

さらに、限界観測数 N が線形モデルによる最適解の予測に要するサンプルサイズ N_1 より大きいか否かで場合分けをした。 $N \leq N_1$ のとき、LALS は局所探索フェーズに進むことができない。しかし、 $N > N_1$ のときには局所探索フェーズに進んで、線形性仮定で見過ごしてしまった最適解を探索することができる。解候補の数は $3^6 (= 729)$ であり、この中から限界観測数 N の中で最適解 \mathbf{x}^* を探索することが解くべき問題となる。統計的検定にまつわるパラメータは $\alpha = 0.05, 1 - \beta = 0.8, \Delta = 0.2$ と設定してサンプルサイズを算出し、 $N_1 = 550, N_2 = 400$ を得た。

最適化手法の評価には最適解からの平均誤差、暫定解が最適解である確率（**正確度**と呼ぶ）や損失の総和などが用いられることが多い [Auer 02]。今回の実験では各アルゴリズムが限界観測数 N の時点での最適解に到達できていることを評価するために、正確度を用いて各アルゴリズムのパフォーマンスを比較した。

各問題に対して比較検討するアルゴリズムを適用した結果を表 3.4 に示す。問題 1 では BF は観測値にばらつきがあるために正確度を上昇させることができず、LS も十分な解の移動を行うことができないため低い正確度にとどまった。それに対し LA と提案アルゴリズム (LALS, LALS+) では線形モデルを仮定して最適解の予測を行なうため、高い精度で最適解を予測している。問題 2 についても問題 1 と同様の傾向が見られ、評価関数に非線形性が無い限りは線形性仮定によって高い正確度で探索できることがわかる。

一方、評価関数に非線形性が含まれる問題 3 では、線形モデルを仮定した最適解の予測の精

表 3.4: シミュレーション実験における各アルゴリズムの正確度

問題	比較手法			提案手法	
	BF	LA	LS	LALS	LALS+
1	0.24	1.00	0.00	1.00	1.00
2	0.54	1.00	0.01	1.00	1.00
3	0.26	0.14	0.01	0.22	0.22
4	0.46	0.26	0.02	0.33	0.68

度が落ちてしまうため、提案アルゴリズムの正確度は比較手法と同程度またはそれ以下まで落ちてしまっている。しかし、評価関数に非線形性が含まれる場合でも問題 4 のように大きな限界観測数 N が与えられる場合には、その後局所探索を行うことで正確度を向上できている。特に LALS+ では動的サンプル割り当て工夫を導入しているため、高い正確度で最適解に到達している。

3.3.3 大規模ウェブサイトでのシミュレーション実験

次に、実際の大規模ウェブサイトで得られたデータを元にシミュレーションを行い、提案手法が有効であることを検証した。今回は一日のユーザ数が数万規模の大規模な人物検索サイト「あのひと検索スパイシー^{*1}（以下ウェブサイト A と呼ぶ）」で得たログデータをもとに評価関数を設定し、シミュレーションを行なった。ウェブサイト A は人物のプロフィールを紹介する「プロフィールページ」と人物同士のつながりを紹介する「相関図ページ」から構成されるシンプルなウェブサイトである。そのため評価指標が設定しやすいと判断し、本サイトを採用した。相関図ページのスクリーンショットを図 3.2 に示す。

今回の実験では、相関図ページにおける広告のクリック率を評価指標として設定した。2013 年 5 月 14 日から 18 日にかけてウェブサイト A で行なった実験で、ある施策 A を相関図ページに施すことによって広告のクリック率を 1.17% 引き上げることに成功した。同時期に他に施策 B, C も行なっていたが、これらの施策は逆にクリック率を減少させる方向に働いた。各

^{*1} あのひと検索スパイシー <http://spysee.jp/>



図 3.2: ウェブサイト A の相関図ページのスクリーンショット

施策による効果を 3.5 にまとめる。

施策 A は人物の相関図を「コ」の字のように取り囲むようにしてバナー広告を配置する施策である。バナー広告の配置を工夫した単純な施策であるが、大きくクリック率を向上することが確かめられた。施策 B は相関図内に表示される人物をカテゴリ別にフィルタリングできる機能を実装した施策である。表示される情報の整理ができるようになることで使いやすくなり、よりユーザの利用度合いが増え、広告収益も向上することを狙った施策であったが、大きなクリック率の向上は見られなかった。施策 C は時間経過する毎に相関図内に表示される人物の数が増えるというものである。提供する情報の量を段階的に増やすことで、ユーザの飽きを防ぐ狙いであったが、こちらの大きな改善は見られなかった。オリジナルのバリエーションと各施策を施したバリエーションの間でクリック率のカイ二乗検定を行なった結果、有意水準 0.01 で有意差があることが認められた。

ここで、施策 i を行うか否かの二値 (0, 1) をとる変数 x_i を用いると、ある解 \mathbf{x} を訪問者に

表 3.5: ウェブサイト A における各施策の効果

施策名	表示回数	クリック率	(95% 信頼区間)
施策 A	9,739	7.57%	(7.04%, 8.09%)
施策 B	14,923	5.73%	(5.36%, 6.10%)
施策 C	5,869	5.06%	(4.50%, 5.62%)
オリジナル	71,457	6.40%	(6.22%, 6.58%)

表示した時に広告がクリックされる確率は

$$q(\mathbf{x}) = 0.0640 + 0.0117x_A - 0.0067x_B - 0.0134x_C$$

と表すことができる。今回の実験では実際のユーザの反応によるデータを収集しているうえに、大規模ウェブサイトの場合は施策の成否がウェブサイト全体の収益に大きな影響を与えるため、実験を繰り返し行なうことが難しい。そのため、ここでは各施策が線形に効果を表すものと仮定する。上述したように、各施策は異なるコンポーネントについて適用しているものであるため、独立に実施可能なものであり、実施の有無を独立変数として扱うことは妥当であると考えられる。評価関数 $f(\mathbf{x})$ は解 \mathbf{x} に対して確率 $q(\mathbf{x})$ で 1 を、確率 $1 - q(\mathbf{x})$ で 0 を返すものとする。統計的検定にまつわる各パラメータは $\alpha = 0.05, 1 - \beta = 0.8, \Delta = 0.05$ と設定した。ここから算出される各サンプルサイズは $N_1 = 5500, N_2 = 6500$ であった。

それぞれのアルゴリズムを適用した結果を図 3.3 に示す。BF は観測回数を経るごとに観測データが増え、着実に正確度を向上している。今回は評価関数を線形関数として設定したため、線形性仮定によって LA が最も良いパフォーマンスを示している。LS は解の比較を繰り返すには与えられた限界観測数が不十分であり、他のアルゴリズムに比べると正確度が低くなっている。提案手法は LA と同様に初期解決定フェーズで高い正確度を示している。これは初期解決定フェーズに線形性仮定を導入したことによる。局所探索フェーズでは、局所探索を行うことによって LALS は BF や LS と比較して高い正確度に到達している。また、動的サンプル割り当てによって、LALS+ は LALS よりも高速に最適解に達していることがわかる。

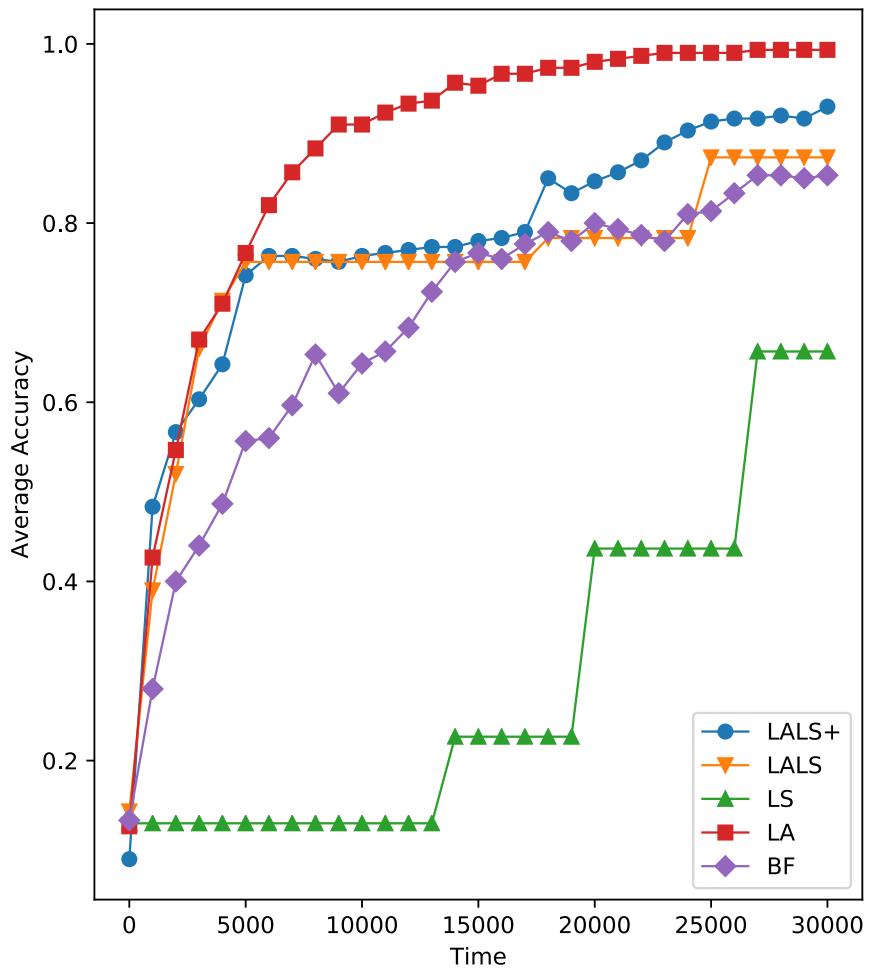


図 3.3: ウェブサイト A から得た評価関数における各アルゴリズムの正確度の推移

3.3.4 小規模ウェブサイトにおける導入実験

一日のユーザ数が数百と少ない小規模ウェブサイトにおいても提案アルゴリズムが有効であることを評価するために、壁紙画像検索サービス「Imagerous^{*2}（以下ウェブサイト B と呼ぶ）」を対象に実験を行なった。本実験では提案手法を実装した最適化プログラムをウェブサ

^{*2} Imagerous <http://imagero.us/>

表 3.6: ウェブサイト B を構成する変数と値

変数	対応する要素	取りうる値
x_1	画像の枠線の太さ	0px, 5px
x_2	画像の間の間隔	0px, 5px, 10px
x_3	画像のサイズ	100px, 200px, 300px
x_4	画像の切り抜き	正方形, 正円

イトに導入して有効性を評価した。ウェブサイト B はパソコンやスマートフォンの壁紙に使える画像を検索したり、アイドルや女優のグラビア画像を検索したりして楽しむことを目的としたウェブサイトである。写真一覧ページと写真詳細ページからなるシンプルなウェブサイトであるため、評価指標の設定および測定が容易と判断して採用した。今回は訪問あたり閲覧ページ数を評価指標として設定した。ユーザの中には一回の訪問で数百ものページを閲覧する、ロボットとみられる動きをするものもあったため、評価指標に上限値を設定した。

今回はこのページを構成する要素として表 3.6 に示す変数と値を設定し、これらの組み合わせを解候補とした。ここでは各変数の値を 0 以上の整数で表すこととし、整数の組み合わせによって解を表現することにする。たとえば、 $x = (0, 2, 1, 0)$ は

{

画像の枠線の太さ: 0px,

画像の間の間隔: 10px,

画像のサイズ: 200px,

画像の切り抜き: 正方形

}

という設定を表している。具体的なバリエーションの表示は付録 A に掲載したスクリーンショットを参照されたい。

今回の実験では LS と LALS の 2 つのアルゴリズムを適用した。小規模サイトでは最適化に用いることができるユーザ数が少數であるため、多くのアルゴリズムを同時に試そうとすると時間がかかり、時間変化による外的要因が実験結果に入り込んでしまう。そのため、今回は提

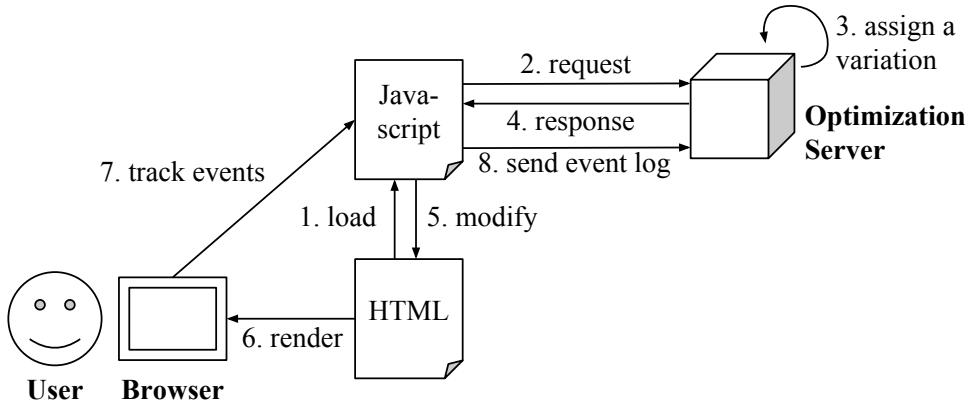


図 3.4: 最適化システムの概要

案アルゴリズムのうち高速化の工夫を導入していない LALS のみを取り上げ、同じ期間で一般的な A/B テストに相当する LS よりも良い解を見つけることができる事を示す。LALS+ は高速化のための工夫を導入しているため、LALS 以上のパフォーマンスを示すことが予想される。今回の実験では有意水準 $\alpha = 0.05$ 、検出力 $1 - \beta = 0.8$ 、効果量 $\Delta = 0.3$ とした。各サンプルサイズは $N_1 = 120, N_2 = 240$ と算出された。

図 3.4 に、最適化システムの概要を示す。ユーザがウェブサイト B を訪問すると、ブラウザは HTML ファイルを通じて Javascript で記述されたプログラムが読み込まれ、実行される。Javascript プログラムはウェブサイト最適化のためのサーバ（**最適化サーバ**とよぶ）にリクエストを送信する。最適化サーバはユーザをあるバリエーションに割り当て、そのバリエーションを表示するために必要な変更を記述したデータを返送する。このデータは変更の対象となる DOM 要素の CSS セレクタとその要素のスタイル属性のペアによって記述されている。Javascript プログラムはこの情報にもとづいて HTML 内の対象の要素に変更を及ぼし、対象のバリエーションをユーザに表示する。割り当てられたバリエーションの情報はブラウザのクッキーとして保持されており、同じユーザが再訪問した際にも同じバリエーションを表示するようになっており、ユーザ体験の一貫性が保たれている。Javascript によるクライアントサイドでの表示切り替えを行っているため、この割当方法は第 2.6.1 項で述べたクライアントサイド方式に分類される。

また、この Javascript プログラムはユーザの振る舞いを追跡するようになっており、ユーザの遷移やクリックなどの重要なイベントが発生した場合にはそのログを最適化サーバに送信す

表 3.7: 暫定解と期待値の推移

手法	観測数	暫定解	期待値	標準誤差
LS	0	(1, 1, 2, 1)	N/A	N/A
	288	(1, 2, 2, 1)	2.560	0.188
	593	(1, 2, 2, 1)	2.470	0.136
LALS	0	N/A	N/A	N/A
	122	(1, 0, 0, 0)	7.000	Inf.
	376	(0, 0, 0, 0)	3.760	0.300
	610	(0, 0, 0, 0)	3.873	0.214

る。最適化サーバは 30 分毎に各バリエーションの期待値計算および解の移動を行うプログラムを実行する。新しいログが送信されるたびに再計算することも可能だが、計算の遅れに起因する表示の遅れを防ぐために一定期間毎に計算を行うようにしている。

2014 年 2 月 4 日から 14 日にかけてウェブサイト B で行なった実験の結果を表 3.7 に示す。LALS が到達した最適解の評価値の期待値は LS のそれを上回った。 t 検定の結果、二つの期待値の間には有意水準 0.01 で有意な差が見られた。LS ではランダムに選ばれた初期解から大きく評価値を改善することができていないのに対して、LALS は有望な初期解から局所探索を開始し、評価値の期待値が高い解に到達している。

3.4 考察

3.4.1 提案手法の適用可能性と限界

ウェブサイトによっては、得られるサンプルサイズに比べて非常に小さい限界観測数 N の中で最適化を行わなければならない状況もありうるが、提案手法は少ない観測数でも最適化を行うことができる。解空間のサイズ $|X| = \prod_{i=1}^m l_i$ は変数の数 m に対して指数オーダーで増加するのに対し、線形性の仮定による最適解の予測を行うのに必要なサンプルサイズ $N_2 = \sum_{i=1}^m l_i$ は線形オーダーで増加する。したがって、提案手法は得られるサンプルサイズよりも解空間が大きい場合でも適用することが可能であり、サンプルサイズの制約に強い最適

化手法だということができる。

変数間の交互作用が大きく、線形モデルによる予測では評価値の高い解から探索を開始できない可能性もあるが、提案手法はその後局所探索を行うことで最終的に評価値の高い解に到達することができる。提案手法の発展として、焼きなまし法や遺伝的アルゴリズムなどのメタヒューリスティクスを用いて大域的に最適解を探索する手法も考えられる。

解が多数のカテゴリカル変数によって構成される場合でも、線形性仮定による最適解の推定は行うことができる。単純に各要素が取りうるそれぞれの値について期待値を計算し、最も期待値が大きいものの組み合わせを採用すれば良い。一方局所探索フェーズでは、近傍解を定義するための工夫が必要になる。何らかの順序を導入することで順序尺度に修正するか、変更された要素の数（ハミング距離）による近傍の定義などが考えられる。この近傍の定義の違いによるパフォーマンスの変化は今後の研究課題である。

逐次的に評価値が与えられる環境下での最適化問題に対する解法として、他にも強化学習やメタヒューリスティクスを用いた探索などが考えられる。他の最適化手法と比較して提案手法が有利な点の一つは、パラメータを設定する必要がないことである。これらの手法ではパラメータによってパフォーマンスが大きく変化することが多く、何度か実行して試行錯誤する中で最適なパラメータを探し出す必要がある。それに対して、提案手法で必要なパラメータはサンプルサイズの算出に要する有意水準、検定力、効果量のみであり、[Cohen 88] で目安となる値も示されている。このことから、提案手法は未知のウェブサイトに対して適用しても安定したパフォーマンスを発揮することができる手法であると考えられる。基本的な動作は局所探索法であるため大域的最適解ではない局所最適解に落ち込む可能性はあるが、今回抽出したウェブページの特徴については、線形性の仮定が性能の良い局所解への到達を助ける初期解の決定に有効に働くことが示された。第 1.1.1 節のオバマ氏のウェブサイトの例でも示したように、あるバリエーションをウェブページを構成する視覚要素の組合せとして表現することは一般的であるため、この工夫はウェブサイト最適化の広い範囲で有効に働くものと考えられる。

本研究では大規模ウェブサイト A、小規模ウェブサイト B の 2 つを取り上げ、ユーザ数に関係なく提案手法が有効であることを示した。また、ウェブサイト A ではクリック率を評価関数に設定したのに対し、ウェブサイト B では訪問あたりのページビュー数を評価関数として実験を行なった。このことから、様々な確率分布の評価関数について提案手法が有効である

ことが示されたと考えている。

3.4.2 実験計画法との関係

実験計画法にもとづいて行われる直交計画実験から線形性仮定の工夫を抽出したが、ここで改めて実験計画法と線形性仮定の関係について議論してみたい。実験計画法は、パラメータの変更が大きなコストを伴う産業分野において、評価しなければならないパラメータの組み合わせを減らすために活用されてきた手法である。たとえば製造業において、製造ラインの室温や回転数などのパラメータが製品の品質に大きな影響を及ぼすが、それらのパラメータは一旦変更すると、安定するまでに長い時間がかかる [大村 13]。このような理由から、事前に評価すべき解を計画して絞っておくことは重要な意味を持っていた。直交計画実験を行う際には直交表を用いることで、できるだけそれぞれの要素の値を同じ回数計測し、サンプリングの偏りが発生しないように配慮するのが一般的である。

しかし、ウェブサイトの場合は解を構成するパラメータの変更にかかるコストは極端に小さい。なぜなら、ウェブサイトはウェブサーバから提供されるソースコードによって表現されるため、ウェブサーバ上のソースコードが修正されれば即座に正確に解の変更が反映されるためである。このような場合、事前に評価すべき解を絞っておく必要はなく、解候補の中から一様に解を抽出して評価すれば、それぞれの要素の値について均等に計測することができる。計測後、直交計画実験を行う場合と同様に分散分析を適用して、それぞれの要素の効果を算出すれば良い。

直交表は設定できるパラメータの数や値の種類に制約があるが、パラメータの変更にかかるコストが無いのであれば直交表を使う必要はなく、解空間から一様分布で無作為に抽出・観測すればよい。すなわち直交表を用いた直交計画は、パラメータの変更に大きなコストがかかる環境下で線形性の仮定による最適解の推定を行うための工夫だとみなすことができる。

3.4.3 文脈付きバンディット問題との関係

提案手法の局所探索フェーズは、組合せ最適化問題に対する解法としての局所探索を発展させ、評価値の観測値にばらつきがある場合にも対応できるようにしたものである。ここでは、暫定解の近傍解をそれぞれ独立の選択肢とみなして等しい確率で近傍解を選択しているが、こ

の近傍解の選択に工夫を導入することで探索を高速化することも可能だと考えられる。たとえば、提案手法の初期解決定フェーズで得られた線形モデルを用いて近傍解の期待値を予測し、より有望な近傍解を選択する工夫が考えられる。局所探索フェーズで得られた観測値を用いて逐次的に線形モデルを更新すれば、より期待値の予測が精緻になると考えられる。このように発展させた手法は、第2.3.2項にて述べた文脈付きバンディット問題に対する解法であるLinUCBに、近傍解を選択する制約を付与したものに相当する。つまり、初期解決定フェーズでは近傍の制約なしに線形モデルによって最適と推定される解を選択し、局所探索フェーズではそこに近傍の制約を加えることで、より局所的な最適解を探索しようとするものである。ベイズ最適化を用いた一解法として記述すれば、前半は線形カーネル関数を用いた探索を行い、後半は解の間の距離に着目するRBFカーネルを用いた探索に相当すると考えられる。本研究では単純な手法で線形モデルの有効性を確かめるために二つのフェーズに分かれた提案手法を提示したが、より統一された形で提案手法を記述することを今後の研究課題としたい。

3.4.4 実用化に向けて

考察の最後に、提案手法をウェブサイト最適化ツールとしての実用化について考えてみたい。本提案手法では、事前にある程度のサンプル数を割いてまんべんなく解の評価を行い、目的関数の線形性を仮定することで初期解を推定するものである。すなわち、これはA/Bテストを繰り返す局所探索を行う際に、有望な初期解を特定するためのテクニックである。したがって、予備実験ツールとしてこの手法を導入することによって、より有望なバリエーションの組からA/Bテストを始めることができるようになると考えられる。

一方で、第2.6項で紹介したGoogle Optimizeのように、単純なA/Bテストに加え、バンディットアルゴリズムによるバリエーションの選択をサポートしているツールもある。このようなツールに対する本手法の貢献の一例として、バンディットアルゴリズムの獲得関数に目的関数の線形性を仮定したボーナスを付与する工夫が考えられる。提案手法を文脈的バンディット問題に対するバンディットアルゴリズムの視点で見てみると、前半は期待値分布に線形性を仮定したLinUCBに相当する振る舞いを示し、後半は期待値分布の連続性を仮定したGP-UCBに相当する振る舞いを示した探索を行っていると捉えることができる。提案手法はこの振る舞いを特定のサンプルが得られた時点で断続的に切り替えるものになっているが、初

期では大きい線形性ボーナスを獲得関数に加え、サンプルが増えるにしたがってボーナスを小さくしていくような GP-UCB をベースにした手法を採用することで、連続的に振る舞いを変化させることができ可能になるかもしれない。このようにして、サンプルが少ない場合には線形性を仮定しながらも高速に性能の良い解を特定し、サンプルが得られるとともに線形性の仮定を緩めながら、より厳密に性能の良い解を特定する振る舞いを持たせることが狙いである。

3.5 まとめ

本章では、ウェブサイト最適化を組合せ最適化問題として捉え、既存のウェブサイト最適化手法を整理することで探索高速化のための工夫を抽出した。抽出した工夫を組み合わせることで、小規模ウェブサイトでも導入可能な高速なウェブサイト最適化手法を提案し、評価実験によって評価した。具体的には、各要素について最も期待値の高い値を組み合わせることで最適解を推定する線形性仮定の工夫と、より有望な解へサンプルを割り当てる動的サンプル割り当ての工夫を導入することによって、高速かつ非線形性も考慮するウェブサイト最適化手法を提案した。このことは、視覚的要素によって最適化する特徴を切り出した場合には特徴間の交互作用が小さく、線形性を仮定した初期解設定が有効に働くことを示している。

第4章

ユーザからのフィードバックを活用した評価関数の設計手法

4.1 本章の背景と目的

本章では第二研究として、ウェブサイト最適化を高速化するための評価指標の設計問題に取り組む。第2.4節で見たように、ウェブサイト最適化の高速化を妨げる評価指標の特徴としてノイズが大きいこと、観測に時間がかかるることを取り上げた。そして、それぞれの問題について、いくつかの解法が提示されていることを説明した。

評価指標のノイズが大きい問題に対処する方法として、分散低減法を用いる解法が提案されている。Dengらは分散低減法の中でも、評価指標と大きい相関を持つ指標を組み合わせることでより分散の小さい指標を設計する制御変量法をウェブサイト最適化に応用する手法を提案している[Deng 13]。評価指標に対してより分散の小さい指標を設計してウェブサイト最適化を高速化する上では、評価指標と相関の大きい指標を特定することは重要な課題である。

この研究ではユーザの属性を評価指標と相関の高い制御変量として用いている。たしかに、Bingのようにユーザ登録機能があり、ひとりのユーザに繰り返し利用される蓋然性の高いウェブサイトでは、このようなユーザの属性を特定することが可能かもしれないが、ウェブサイトによってはそもそもユーザの属性を特定することが難しい場合もある。たとえば、ウェブ上の情報を収集・分類した記事を提供するキュレーションメディアは、検索エンジン経由の流入が主になるため、ユーザが繰り返し訪問するような性質のウェブサイトではない。他にも、

インターネット広告からたどり着くような商品紹介ページ（ランディングページとも呼ばれる）は、ほとんどのユーザが新規ユーザと見られ、ユーザに関する属性情報を得られるとは考えにくい。このように、訪問ユーザの多くが新規ユーザであるようなウェブサイトの場合、ユーザの属性を用いて指標を設計することが難しい。そのため、ウェブサイトの性質に関わらず適用可能な、汎用性の高い手法が求められている。

一方、指標の観測に時間がかかる問題に対しては、過去の実験データから長期的な効果を推定するモデルを構築する手法が提案されている。Hohnhold らは、過去に行われた長期間に及ぶウェブサイト最適化の実験結果を用いて、バリエーションの特徴量から長期的に収束した後の評価指標の値を推定する手法を提案している。バリエーションの特徴量は表示された広告の数、広告と検索クエリの関連度、広告のランディングページの質の 3 つ、モデルは線形回帰を用いており手法自体はシンプルでは有るもの、短期的にはよく見えるが長期的に見ると利益を棄損する恐れがあるバリエーションを棄却するのに有用だったことが報告されている [Hohnhold 15]。

この手法では各バリエーションの特徴表現が即座に得られることを前提としているが、この仮定は一般的にウェブサイトに成立するとは考えにくい。たしかに、Google のように大手検索エンジンの検索結果ページでは、広告の質や検索クエリとの関連度を算出する仕組みやアルゴリズムが確立しているため、あるバリエーションからの特徴抽出が容易にできるかもしれない。しかし、リリースされて間もないウェブサービスやテストをはじめて間もないウェブサイトの場合にもこの前提が成り立つとは考えにくい。また、新しい機能のテストを行う場合には、既存の特徴表現が有用でない可能性もある。したがって、あるバリエーションを表す特徴が自明でない状況を想定する方が一般的であり、そのような状況下でも適用可能な手法が求められている。

以上をまとめると、評価指標の分散が大きい問題に対しては、評価指標と相関関係にある指標を利用する事が有効であり、その指標を用いて代替的な評価指標を設計することでウェブサイト最適化を高速化することができる。一方、評価指標の観測に時間がかかる問題に対しては、バリエーションに特徴表現を与えることが有効であり、過去の実験データを用いてその特徴量から長期的指標を予測するモデルを構築することで、長期的効果を予測してウェブサイト最適化を高速化することができる。この特徴表現を与えるような指標を発見することが有効な

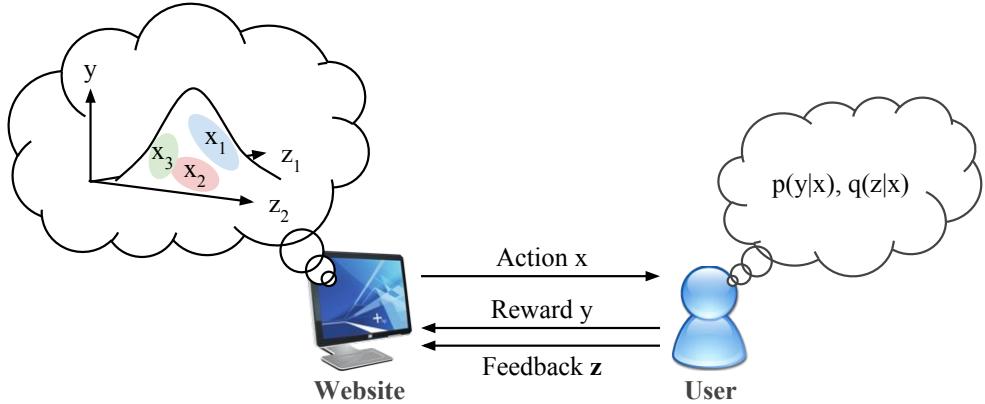


図 4.1: 提案手法の概観

解決法となる。これらの条件を満たし、かつウェブサイトの種類に関わらず利用可能な汎用的な指標を発見することが、ウェブサイト最適化の評価関数設計にまつわるこれらの問題を解決する上で有効であると考えられる。

そこで本研究では、ユーザにバリエーションを表示したときに即座に観測できるフィードバックを制御変量およびバリエーションを表現する特徴量として活用する手法を提案する。ここでいうフィードバックとは、あるウェブサイトにおける滞在時間や直帰率といった、あるユーザの訪問に対して即座に計測ができる、ユーザの行動に関する指標のことを指すものとする。このフィードバック指標を用いて、目的となる評価指標よりも分散が小さい指標を設計することができれば、ウェブサイト最適化を高速化することができる。また、これらの指標を用いて任意のバリエーションの特徴表現を獲得することができれば、これらの特徴量と長期的な評価指標の値をひも付けるモデルを構築し、長期的指標に対しても高速なウェブサイト最適化を実現できる。

図 4.1 に、提案手法の概観を示す。提案手法は、まずウェブサイト最適化によって得られるフィードバック指標を定義し、それらを特徴量とする特徴空間（**フィードバック空間**と呼ぶ）を設計する。その後、ウェブサイト最適化の過程でフィードバック空間から目的指標を推定するガウス過程による回帰分析を行うことで、フィードバック空間上における目的指標の分布を得る。推定された分布の上で信頼上限を最大とする特徴ベクトルに対応するバリエーションを表示する GP-UCB アルゴリズム [Srinivas 10] を応用することで、高速なウェブサイト最適化を実現する手法である。

評価実験では、実際のウェブサイトで得られたログデータにもとづいてシミュレーションを行い、提案手法によって最適なバリエーションの探索を高速化できること、また未知のバリエーション集合に対しても最適なバリエーションを推定できることを評価する。前者はノイズが大きい評価指標に対しても、フィードバック指標を多面的に活用することでノイズを小さくし、より高速な最適化を実現できることを示すものである。後者は、未知のバリエーションに対して即座に目的指標の観測値が得られない状況でも、過去の実験で得られたモデルを用いることで最適なバリエーションの推定が可能になることを示すものである。

本研究の貢献は以下のとおりである。

- 即時的に得られるフィードバックによって、ウェブサイト最適化におけるバリエーションに特徴表現を与え、探索を高速化する手法を提案した。
- 実際のウェブサイトのログデータを用いた評価実験によって、提案手法がバラつきの大きい目的指標に対しても高速に最適バリエーションの探索が可能であることを示した。
- 実際のウェブサイトのログデータを用いた評価実験によって、提案手法によって得られたモデルが、未知のバリエーションに対して最適バリエーションを推定するのにも有効であることを示した。

本章の構成は以下のとおりである。第4.2節で関連研究を説明し、第4.3節で提案手法を説明する。第4.4節で評価実験を行う。第4.5節で考察、最後に第4.6節をまとめとする。

4.2 関連研究

4.2.1 分散低減法

Dengらはウェブサイト最適化の目的指標に対して分散低減法を用いることで、より分散の小さい指標を設計し、ウェブサイト最適化の高速化を実現する方法を提案した[Deng 13]。この研究では、ユーザあたりの検索回数や利用開始日などの属性を制御変量として用いた分散低減法を利用することで、対象ウェブサイトであるBingにおける広告クリック率の変化をより高速に捉えることに取り組んでいる。実験の結果、分散低減法を用いることで今までの約半数のユーザでバリエーションの評価が可能になったことが報告されている。目的指標と相関関係にある制御変量を探索するという新しい問題を設定することにはなるものの、適切な制御変量

が見つかれば大きな効果を得ることができる。

層化サンプリング

ここでは、まず分散低減法の最も単純な例として層化サンプリングを取り上げる。層化サンプリングは、ある推定量を算出する対象となるサンプルを、あらかじめ推定量と相関関係がある属性によって層別することによって、より分散の小さい指標を設計する手法である。たとえばある集団の平均身長を求めるときには、年齢や性別など身長と相関関係がありそうな属性によって集団を層分けし、各層の平均値の重み付け和として推定値を算出したほうが分散を小さくできる。

数式を用いて以上のこととを説明する。ある指標 Y に興味があり、求めたい推定量としてその期待値 $\bar{Y} = \mathbb{E}[Y]$ を考えると、その分散は $\text{Var}[\bar{Y}] = \text{Var}[Y]/n$ として表される。ただし、 n はサンプルサイズを表すものとする。ここで、サンプルを K 個のグループに分けることができるとすると、新たな推定量として各グループ k の平均 \bar{Y}_k の重み付け和 $\hat{Y} = \sum_{k=1}^K w_k \bar{Y}_k$ を定義することができる。ただし、 w_k はあるサンプルがグループ k に属する確率を表しており、グループ k に属するサンプルの数を n_k とすると、 $w_k = n_k/n$ と計算される。ここで目的とする推定量の分散を考えると、

$$\text{Var}[\bar{Y}] = \sum_{k=1}^K \frac{w_k}{n} \sigma_k^2 + \sum_{k=1}^K \frac{w_k}{n} (\mu_k - \bar{Y})^2 \geq \sum_{k=1}^K \frac{w_k}{n} \sigma_k^2 = \text{Var}[\hat{Y}]$$

となり、 $\mathbb{E}[\hat{Y}]$ を推定量とすることで分散削減を実現できることがわかる。ここで、 μ_k, σ_k^2 はグループ k 内のサンプルの平均および分散を示す。このことは、層化サンプリングを用いた分散削減によって群間変動を消去できることを意味している。したがって、群間変動が大きいほど得られる分散低減効果も大きい。

制御変量法

層化サンプリングでは離散的なグループにサンプルを分割するが、離散的なグループを仮定しない一般化を施したもののが制御変量法である [Deng 13]。制御変量法では、期待値を推定したい指標 Y と何らかの相関関係がある変量 Z を用いることで、より分散の小さい変量を設計する手法である。以下では、評価指標と相関のある変量が分散の小さい指標の設計に有効であることを示す。

値 y がある試行を繰り返すごとに得られるとき、その期待値 $\mu = \mathbb{E}[y]$ が私たちが推定したい統計量だとする。ここで仮に、 y とは別にある制御変量 z が得られ、かつその期待値 $\mathbb{E}[z]$ が既知であるものとする。ここで、値 y に対してある代替変量 $y^* = y + c(\mathbb{E}[z] - z)$ を設計することを考える。ただし、 c はある定数である。

ここで、この代替変量 y^* の分散を計算すると、

$$\text{Var}[y^*] = \text{Var}[y] + c^2\text{Var}[z] - 2c\text{Cov}[y, z] \quad (4.1)$$

と表される。ただし、 $\text{Var}[y]$ は y の分散、 $\text{Cov}[y, z]$ は y と z の共分散とする。ここで、式 (4.1) を c に関する二次式とみなして $\text{Var}[y^*]$ を最小にする c を考えると、 $c = \text{Cov}[y, z]/\text{Var}[z]$ となる。このとき、 $\text{Var}[y^*]$ の値は

$$\text{Var}[y^*] = \text{Var}[y] \left(1 - \frac{\text{Cov}[y, z]^2}{\text{Var}[y]\text{Var}[z]} \right) = \text{Var}[y](1 - \rho^2)$$

と表される。ただし、 ρ は y と z の相関係数である。この式から分かるように、値 y との相関 ρ が大きい何らかの制御変量 z が見つかれば、それを用いて y よりも小さい分散を実現する代替変量 y^* を設計することができる。

このように、ある変量 y の分散を小さくする上で、相関の大きい制御変量 z が重要な役割を果たしている。Deng らはユーザに紐付づく属性を制御変量として用いることで、ウェブサイト最適化の目的となる指標の分散を低減し、より少ないユーザ数で最適化を行うことを可能にした。しかしウェブサイトによっては、ログイン機能がなかつたり、クッキーが無かつたりするためにユーザ属性を用いることが難しい場合もある。またクッキー情報が得られる場合でも、クッキーはブラウザ単位で管理されているため、ユーザの識別子として用いることには困難が伴う。クッキーをユーザの識別子として扱うことの困難さは [Dmitriev 16] に詳しい。本研究はこの制御変量として、ユーザとの相互作用の中で生じるフィードバック指標を用いることで、ユーザの属性に依らないより汎用的な手法を構築することを目指す。

4.2.2 予測モデルによる目的指標の予測

2.4 節では、ウェブサイト最適化を遅延する目的指標の特徴の二つ目として、観測に時間がかかるなどを挙げた。この問題に対しては、バリエーションを表す特徴量を説明変数とした予測モデルを構築する手法が提案されている。ここでは、過去の実験データを用いて予測モデル

を構築し、観測に時間要する目的指標に対するウェブサイト最適化を高速化した関連研究[Hohnhold 15]を詳しく説明する。

Hohnhold らは、Google の検索結果画面における長期的なクリック率を目的指標としてウェブサイト最適化を試みた事例を報告している。Google の検索結果画面には検索クエリと関連する広告が表示される仕組みになっており、同社の大きな収入源のひとつになっている。この広告クリック率を向上することは収益向上に直結する重要な活動であるため、同社は広告の表示数を変えたり、リンクの文字色を変えたりするなどして、様々なバリエーションをテストしている。

しかし、短期的には広告のクリック率を向上するようなバリエーションを見つけることができたとしても、それが長期的に広告のクリック率を向上するとは限らない。たとえば、表示する広告の数を増やしたり、ユーザがクリックまたはタップしやすい位置に広告を配置すれば、短期的な収益は容易に向上するであろう。しかし、その結果としてウェブサイトが使いにくくなり、ユーザに提供する体験が劣悪なものになれば、結局はサービスを利用するユーザ数が減少し、長期的に見ると収益性を棄損してしまうかもしれない。したがって、企業活動が継続するという前提を置く限り、長期的な目的指標に対してウェブサイト最適化を行うことが肝要である。

Hohnhold らの試みでは各バリエーションを特徴量によって表し、過去の実験データから予測モデルを構築することで長期的な目的指標を予測している。この研究では、各バリエーションを

- 広告の表示数 ϕ_1
- 広告と検索クエリの関連度 ϕ_2
- 広告のランディングページの質 ϕ_3

の3つの特徴量で表している。ただし、特徴量 ϕ_2 と ϕ_3 については Google 独自のアルゴリズムによって求められるものとする。過去にテストされたバリエーションをこれらの特徴量によって表現し、これらの特徴量から各バリエーションが収束する長期的なクリック率を予測するモデルを線形回帰によって構築することで、これらの特徴量さえ得られれば長期的なクリック率を予測できるようになる。

100 を超える長期の実験データから予測モデルを構築した結果、広告と検索クエリの関連度

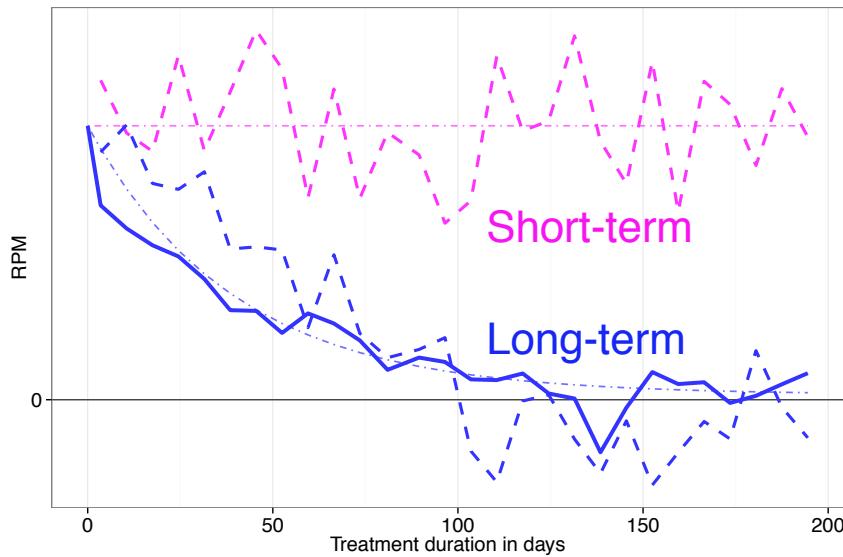


図 4.2: 長期的なクリック率に対する予測モデルの動作例（図は [Hohnhold 15] より引用）

ϕ_2 と広告のランディングページの質 ϕ_3 について正の相関があるモデルが得られたことが報告されている。得られた予測モデルを活用することで、短期的にクリック率を向上するが長期的に見るとクリック率を棄損するバリエーションの採用を退けることができるようになったことが報告されている。図 4.2 に、あるバリエーションがもたらした短期的なクリック率の変化と長期的なクリック率の変化を図示したものを見た。このバリエーションは、ピンクで示された短期的な収益性 (RPM^{*1}) に着目すると改善しているが、青で示された長期的な収益性に着目すると改悪となっていることがわかる。予測モデルを利用することで、このように長期的に見ると改悪となるバリエーションを棄却できるようになる。

このように、観測に時間要する目的指標に対してウェブサイト最適化を行う上で、過去データを用いた予測モデルの構築が有効であることを見てきた。しかし、バリエーションを表すこれらの特徴量が常に得られるとは限らず、また個々のウェブサイトの特性に大きく左右される。たとえば Hohnhold らの実験では広告とのランディングページの質を特徴量のひとつとして用いているが、このような品質を定義すること、そしてそれを定量化するためのアルゴリズムを構築することは、ウェブサイトの特性に大きく依存する上に容易なことではない。予測

^{*1} RPM は Revenue Per Mille の略で、1000 回の表示あたりの収益を表す指標。Mille はフランス語で 1000 を表す。

モデルの構築を様々なウェブサイトにも適用可能なものにするには、より汎用的な指標によって予測モデルを構築できる手法が求められていると考えられる。

4.3 提案手法

ウェブサイト最適化の高速化の阻害要因となる目的指標の特徴として、ノイズが大きいこと、そして観測に時間を要することを挙げた。また、それらの問題に対して、分散低減法および予測モデルを用いた解法が提案されていることを関連研究として述べた。しかし、いずれの解法についても、ウェブサイトの特性に依らない汎用的な手法を提供する点では課題を抱えていることを述べた。本研究では、ウェブサイトの特性に依らない汎用的な特徴量によって目的指標の削減および予測モデルの構築を可能にする手法を提案する。

ウェブサイト最適化はウェブサイトとユーザの相互作用の中で行われ、あるバリエーションに対するユーザの反応を計測することで仮説検証を行う。ユーザに紐づく属性やウェブサイトに紐づく属性を用いることは、汎用性を確保する上で困難であることはこれまでに述べてきたりである。しかし、この相互作用そのものから観測される特性はウェブサイトやユーザの特性に依らず利用できるかもしれない。

たとえば、ユーザがあるウェブサイトを熱心に読んでいるときには、そうでないユーザに比べるとページ滞在時間が長くなることが予想される。また、ウェブページを最後まで読もうとすればページをスクロールする量も増加するので、スクロール量からもユーザの反応の変化を計測することができるかもしれない。このようなウェブサイトとユーザの相互作用の中で生まれる特性は、ユーザの属性が特定できない場合にも計測することができる。また、テストするバリエーションの特徴量が定義できない場合であっても、このような指標を計測する仕組みさえできていれば、計測することができる。そこで本研究では、こういったウェブサイトとユーザの相互作用の中で計測することができる指標を**フィードバック指標**とし、このフィードバック指標を用いたウェブサイト最適化手法を提案する。フィードバック指標と最適化する目的の指標の間になんらかの相関関係があれば、その相関関係を用いることで分散を低減し、ウェブサイト最適化を高速化できると考えられる。また、このフィードバック指標から目的指標を予測するモデルを構築することができれば、観測に時間がかかる指標の問題にも対応できると考えられる。

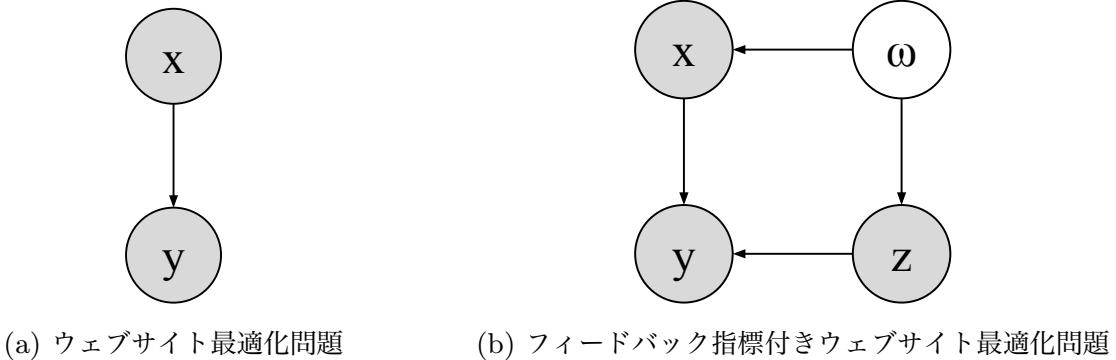


図 4.3: 各ウェブサイト最適化問題において仮定する確率モデル

4.3.1 フィードバック付きウェブサイト最適化問題の定式化

まず、ユーザからのフィードバックを考慮した**フィードバック付きウェブサイト最適化**の定式化を行うことにする。一般的なウェブサイト最適化では、ウェブサイトがユーザ $u \in U$ にバリエーション x を表示すると、ユーザから目的指標の観測値 $y \sim p(y | x)$ が得られる。ただし、 $p(y | x)$ は観測値を発生する条件付き分布である。この状況下で、観測値の期待値 $\mathbb{E}[y | x]$ を最大にするバリエーション \mathbb{E} を探索するのが式 2.1 に示したウェブサイト最適化問題である。図 4.3a に、この問題で仮定する確率モデルのグラフィカルモデルを示す。

一方、フィードバック付きウェブサイト最適化では、ユーザ u から目的指標の観測値 y に加えて、フィードバック指標ベクトル z も観測されるものとする。このとき、表示されたバリエーション x の訴求力や魅力に応じてユーザの反応が変化し、その反応がフィードバック指標 z に現れるものと考えられる。ここでは、このバリエーションが持つ訴求力や魅力を表す潜在変数を ω とする。つまり、バリエーションはユーザを引きつける訴求力や魅力を体現したものであり、 $x \sim p(x | \omega)$ として出力されるものと考えられる。また、フィードバック指標もこの魅力によって変化するため、 ω を条件とした確率分布によって出力され、 $z \sim p(z | \omega)$ と表されると考えられる。最後に、このバリエーション x およびフィードバック指標 z に応じて目的指標が観測され、 $y \sim p(y | x, z)$ と表される。図 4.3b に以上をまとめたグラフィカルモデルを示す。

ユーザを引きつける訴求力 ω はユーザに表示されるバリエーション x およびユーザから得

られる反応 z に現れ、これらの要素が最適化したい目的指標 y に影響を与えることをモデル化したものである。たとえば、ある商品を販売するサイトにおいてユーザの興味を引きつける魅力は、商品の利益を的確に伝えるバリエーション x 、そしてウェブページの滞在時間の増加もしくはウェブサイト内でのクリック数の増加といったフィードバック z として現れるかもしれない。そして、これらの変数が最終的な購買率 y といった目的指標に対して影響を与えるものと考えられる。

以上より、フィードバック指標も含めたフィードバック付きウェブサイト最適化問題は、下記のように表すことができる。

フィードバック付きウェブサイト最適化問題

解 $x \in X$ とある変量 z が潜在変数 ω を条件とする条件付き分布 $p(x | \omega)$, $p(z | \omega)$ によって観測され、 x および z に対する観測値 y が条件付き分布 $p(y | x, z)$ に従って発生する。このとき、下式を満たす解 x^* を求めよ。

$$x^* = \arg \max_{x \in X} \mathbb{E}[y | x, z] \quad s.t. \quad x \sim p(x | \omega), z \sim p(z | \omega), y \sim p(y | x, z)$$

4.3.2 フィードバック指標に対するベイズ最適化の利用

では、このフィードバック指標 z を分散低減および予測モデル構築の目的で利用するには、どのように探索手法を構築すればよいだろうか。たとえば、バリエーション x とフィードバック指標 z をひとつの特徴空間に表して局所探索や遺伝的アルゴリズムをはじめとするメタヒューリスティクスを導入する方法が考えられる。目的指標と相関関係にあるフィードバック指標が埋め込まれた特徴空間を用いることで、探索を高速化できることが期待できる。しかし、確率分布によるモデリングを用いない場合、予測モデルとしての再利用が難しくなることが考えられる。探索の過程で得られる予測モデルを、観測に時間がかかる目的指標に対する予測の目的で利用することを考えると、確率分布によるモデリングを行う手法が望ましい。

そこで本研究では、第 2.3.2 項にて連続腕バンディット問題に対する解法として述べたベイズ最適化をフィードバック指標によって構成される空間に対して適用する手法を提案する。ベイズ最適化を用いることで、有望かつ不確実性の高い解に効率的にサンプルを割り当てて高速に探索を行うことができるように加え、非線形性のある期待値の分布も探索の過程で得ることが

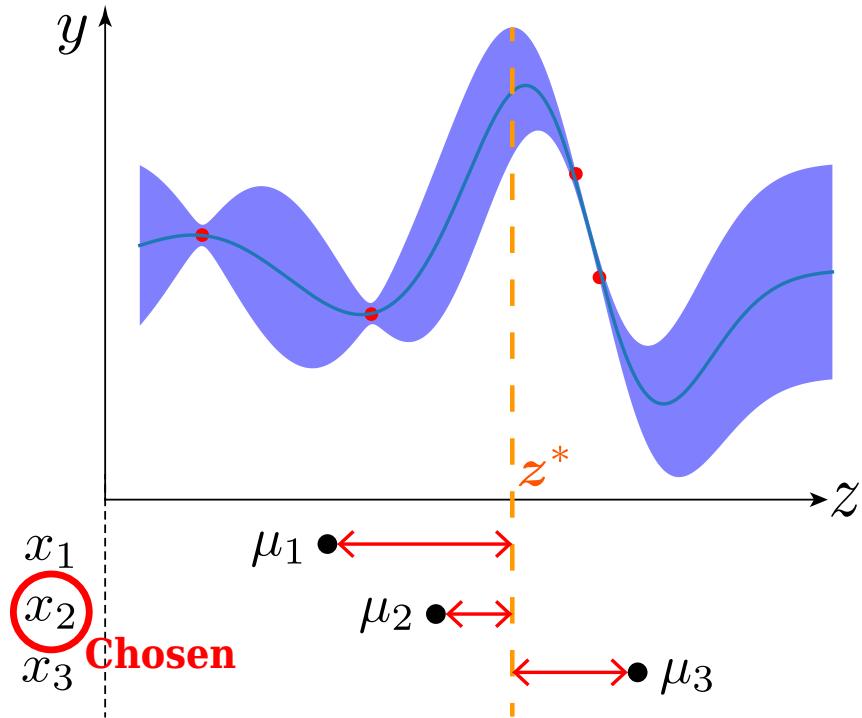


図 4.4: 提案手法の概観

できるため、予測モデルとしての再利用が可能になる。ここでは、ベイズ最適化の実装の中でも直感的にわかりやすく、高いパフォーマンスを示すことが知られている GP-UCB を用いることにする [Brochu 10].

提案手法の概観を図 4.4 に、アルゴリズムを Algorithm 4 に示す。あるバリエーション x_t をユーザに表示すると、ウェブサイト w はユーザから観測値 y_t とフィードバック z_t を受け取る。提案手法では、これらを受け取るたびにフィードバック空間 Z における観測値 y の分布をガウス過程を用いて求める。このようにして推定された観測値の平均 $\mu(z)$ と標準偏差 $\sigma(z)$ から各フィードバック $z \in Z$ の UCB 値を算出し、UCB 値を最大化する最適フィードバック z^* を求める。最後に、最適フィードバック z^* と最も近いフィードバック期待値を出力するバリエーション $x^* = \arg \min_{x \in X} (z^* - \mathbb{E}[z | x])^2$ が次に表示するバリエーション x_{t+1} となる。

たとえば、あるウェブサイト w が 3 種類のバリエーション $X = \{x_A, x_B, x_C\}$ を持つており、ここからユーザの広告のクリック率 $\mathbb{E}[y | x]$ を最大にするようなバリエーション x^* を求めたいとする。ただし、それぞれのバリエーションはある要素の組み合わせとして表現するこ

Algorithm 4 提案手法のアルゴリズム

Require: X as the set of variations.

Require: Z as the input space.

Require: α as the GP prior parameter.

Require: β as the confidence parameter.

1: Set $\mu_0(z) \leftarrow 0, \forall z \in Z$.

2: Set $\sigma_0(z) \leftarrow \mathcal{N}(\mu_0(z), \alpha^{-1}I)$.

3: **for** $t = 1, 2, \dots$ **do**

4: Choose $z^* = \arg \max_{z \in Z} \mu_{t-1}(z) + \sqrt{\beta} \sigma_{t-1}(z)$

5: Choose $x_t = \arg \min_{x \in X} (z^* - \mathbb{E}[z | x])^2$

6: Sample y_t and z_t by showing the variation x_t to user u_t .

7: Update μ_t and σ_t using Gaussian Process with parameter α .

8: **return** x_t as the optimal solution.

とが困難であるものとする。このとき、ウェブサイト w は訪問するユーザ u を無作為に各バリエーションに割り当てて表示する。ウェブサイト w はクリックの有無 y だけではなく、ユーザがウェブサイトに滞在した時間 z も測定しているものとする。提案手法を取り入れたウェブサイト w は、あるバリエーション x_t をユーザ u_t に表示したときのクリック y_t および滞在時間 z_t が観測されるとベイズ推定を行い、潜在時間に対するクリック率の分布 $\mathcal{N}(\mu(z), \sigma(z))$ を更新する。分布を観察した結果、観測値の上側信頼限界を最大化する滞在時間は z^* 付近であることがわかったとする。過去の履歴から z^* に最も近いフィードバックが得られると期待されるバリエーションを算出した結果 $x_B = \arg \min_{x \in X} (z^* - \mathbb{E}[z | x])^2$ であったため、次のユーザ u_{t+1} にはバリエーション x_B を表示する。以上が、提案手法を用いたときのウェブサイト最適化の手続きである。

提案手法を実行するためには、バリエーション集合 X とフィードバック空間 Z の他にガウス過程において学習する目的指標の事前分布の分散の逆数 α と信頼区間の精度 β という二つの超パラメータを設定する必要がある。 α は大きいほど事前分布の分散が小さくなり、ガウス過程によって求められる分布が 0 付近に抑えられるようになる。そのため過学習は抑えられるものの、大きすぎるとデータを説明する分布を得ることが難しくなる。 β は UCB の大きさを司るパラメータであり、UCB における「好奇心」を表すものである。 β が大きい値を取るほ

ど、期待値の高い解よりも未探索の解を優先して探索するようになる。これらの超パラメータはデータの特性を踏まえて選択する必要があるが、 α は 0 付近の小さな値、 β は 1 以上の値が取られることが多い。

4.4 評価実験

ここでは実際のウェブサイトのログデータを用いたシミュレーション実験を行い、提案手法の有効性を評価する。実際にウェブサイト最適化を実施したウェブサイトのログデータをもとに、各バリエーションを表示したときに得られる観測値およびフィードバックを再現する。比較手法と提案手法の最適化の速度を比較するとともに、提案手法が未知のバリエーションに対しても最適なバリエーションを推定できることを評価する。

評価実験では、フィードバックを考慮しない UCB アルゴリズムを比較手法として設定する。UCB アルゴリズムのアルゴリズムを Algorithm 5 に示す。

Algorithm 5 UCB アルゴリズム

Require: X as the set of variations.

- 1: Set $N_x \leftarrow 0$, $\forall x \in X$ as the number of observations.
 - 2: **for** $t = 1, 2, \dots$ **do**
 - 3: Choose $x_t = \arg \max_{x \in X} \mathbb{E}[y | x] + \sqrt{\frac{2 \log \sum_{x \in X} N_x}{N_x}}$
 - 4: Sample y_t by showing the variation x_t to user u_t .
 - 5: $N_{x_t} \leftarrow N_{x_t} + 1$
 - 6: **return** x_t as the optimal solution.
-

ここでは、実際のウェブサイトにおいて広告のクリック率を最大化することを想定したウェブサイト最適化のシミュレーションによって提案手法の有効性を評価する。あるウェブサイトで過去にウェブサイト最適化を行なっていたときのログデータから、各バリエーションを表示したときの目的指標の観測値およびユーザからのフィードバック指標を抽出する。その後、観測値およびフィードバック指標それについて分布推定を行い、得られた分布から乱数を発生させることで、各バリエーションをユーザに表示したときに得られる値を再現する。この環境の元で、比較手法および提案手法によるウェブサイト最適化を行い、それぞれのパフォーマンスを比較することにする。

本実験では、第3章でも用いたウェブサイトAを対象とし、相関図ページに表示された広告のクリック率を最適化する目的の指標 y と設定する。ウェブサイトAにおいてバナー広告は主な事業収入源となっており、最適化へのニーズが高い指標である。ユーザから得られるフィードバック指標 z としては、下記の指標を用いることとする。

■プロフィールページからの遷移の有無 z_1 対象の人物の相関図ページに、その人物のプロフィールが掲載されたプロフィールページからの遷移であったことを表す指標である。相関図ページに検索エンジンから直接訪問するよりも、プロフィールページからの遷移であるほうが、より強い関心を示すものと考えられる。ユーザの属性と捉えることもできる指標であるが、ここではフィードバック指標として扱うこととする。このウェブページの特徴に依存した指標であるが、このようにリンクに結びつけた指標はこの他のウェブサイトでも汎用的に設計可能だと考えられる。

■滞在時間（秒） z_2 対象の人物の相関図ページに滞在する時間を表すものである。訪問ユーザが対象のウェブページに興味がない場合は即座に直帰することを考えると、この滞在時間はそのウェブページに対する興味の深さを表すものと考えられる。ただし、この滞在時間が長い方が好ましいか否かは対象のウェブページの性質に依存する。たとえば、検索エンジンのようなウェブアプリケーションを提供している場合には、できるだけ短い時間でユーザがタスクを完了することが好ましいと考えると、この滞在時間も短いほうが好ましいことになる。

ウェブサイトAでは、定期的にウェブサイト最適化を行なっており、各バリエーションを表示したときのそれぞれの指標が記録されている。ここでは、2013年5月16日に行われたウェブサイト最適化のログデータを用いて分布の推定を行うこととする。この期間、ウェブサイトAでは3種類のバリエーション $X = \{x_1, x_2, x_3\}$ がテストされていた。 x_1 はユーザが相関図ページに表示された円グラフをクリックすると爆発するアニメーションを施したものである。ユーザにゲーム感覚を持ってもらうことでサイト上の操作を増やし、ウェブサイトからの離脱を減らすことで広告クリック率の上昇を狙ったものである。 x_2 は広告の配置レイアウトを、相関図を囲むように配置したものである。 x_3 はユーザが何も操作せずとも相関図が自動で更新されていくものである。自動で相関図が更新されることで、ウェブサイトAで可能な操作のチュートリアルの役割を果たすことでウェブサイトからの離脱を減らし、広告のクリック率を上昇させることを狙ったものである。相関図の概観については図3.2を参照されたい。

表 4.1: 2013 年 5 月 16 日にウェブサイト A においてテストされたバリエーションに対する目的指標およびフィードバック指標の推定分布

X	クリック率 y	プロフィールからの遷移 z_1	滞在時間 z_2
x_1	$Bernouli(0.0534)$	$Bernouli(0.403)$	$Gamma(1.46, 21.6)$
x_2	$Bernouli(0.0716)$	$Bernouli(0.417)$	$Gamma(1.24, 22.9)$
x_3	$Bernouli(0.0397)$	$Bernouli(0.412)$	$Gamma(1.48, 21.0)$

表 4.1 に各バリエーションを表示したときに得られた目的指標の観測値 y およびフィードバック指標 z_1, z_2 の分布を推定したものを示す。広告クリック率 y およびプロフィールからの遷移 z_1 は発生する・しないの二値で表されるため、ある確率 p で発生するベルヌーイ分布 $Bernouli(p)$ より発生する乱数としている。一方、滞在時間 z_2 は 0 以上の連続値をとる。そのためここではガンマ分布による推定を行い、形状尺度 k と尺度母数 θ のガンマ分布 $Gamma(k, \theta)$ より発生する乱数としている。ここではバリエーション x_2 の広告クリック率が最も高いため、ユーザとの相互作用を介して x_2 を最適解として発見することがウェブサイト最適化の目的となる。

評価実験では、最適解を特定することができる正確度および累積クリック数によって評価するものとする。また、提案手法における超パラメータはそれぞれ $\alpha = 10, \beta = 100$ と設定した。上記の設定のもとで 500 回シミュレーションを繰り返した平均の結果を表示するものとする。計算量の都合上、最適バリエーションの更新は 10 回サンプルを得るごとに行うものとする。

4.4.1 ウェブサイト最適化の高速化の評価

図 4.5 に、それぞれの指標を適用したときの正確度の推移を示す。最適化を開始した当初は各解の上側信頼限界が大きいため、評価値の高い解を特定することができずに正確度が大きくばらつく。これは UCB アルゴリズム全般に見られる特性である。1000 サンプルまでは提案手法と比較手法の間に大きな差が見られないが、1000 サンプルを超えたあたりから提案手法が比較手法を上回る正確度を見せている。このことは、フィードバック指標を活用することで、より高い確率でクリックを発生するフィードバックを推定することができ、そのような

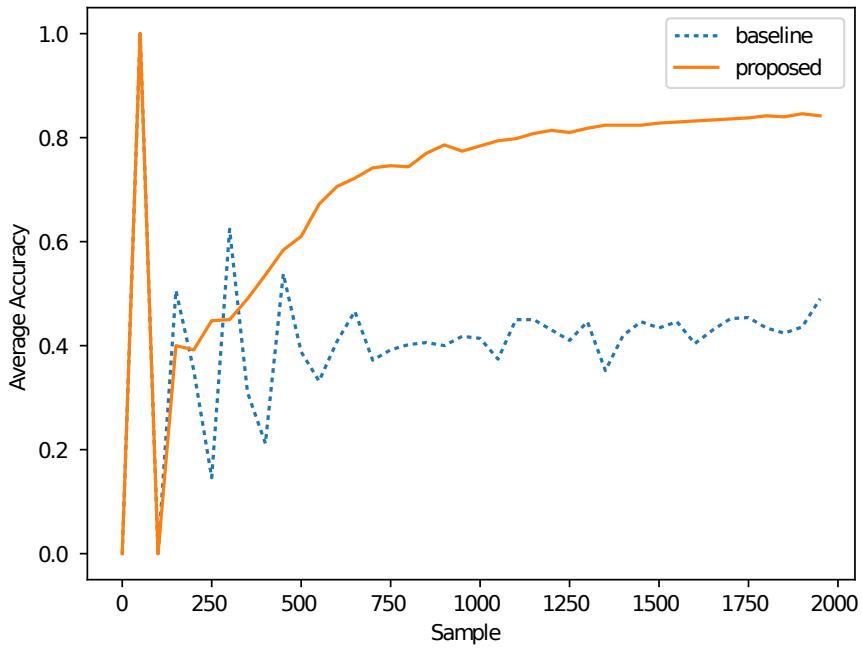


図 4.5: 正確度の推移

フィードバックを生み出すような解を積極的に提示することでより高速に最適化が実現できることを示している。図 4.6 に累積クリック数の推移を示す。こちらでも、提案手法を用いることで比較手法より多くのクリックを得ることができることが示されている。

提案手法の特徴のひとつは、フィードバック空間における目的指標の分布を推定できる点である。図 4.7 に、提案手法によって推定されたフィードバック空間 Z におけるクリック発生 y の分布の一例を示す。Profile 軸はプロフィールページからの遷移 z_1 、Time on page はページ上での滞在時間 z_2 をそれぞれ表している。Click-through rate 軸はクリック率 $\mathbb{E}[y]$ を表している。中央の曲面は z_1, z_2 からなるフィードバック空間におけるクリック率の分布を示しており、高いクリック率を示す部分は赤く、反対に低いクリック率を示す部分は青く色付けされている。500 回のシミュレーションの中の 1 エピソードについて抽出して図示している。

目的指標の分布に着目すると、(Profile, Time on page) = (1, 0) 付近で大きな値を示していることがわかる。ここで表 4.1 で示された各指標の分布を見ると、最適バリエーションである x_2 は他のバリエーションに比べて大きいプロフィールからの遷移率 ($0.417 >$

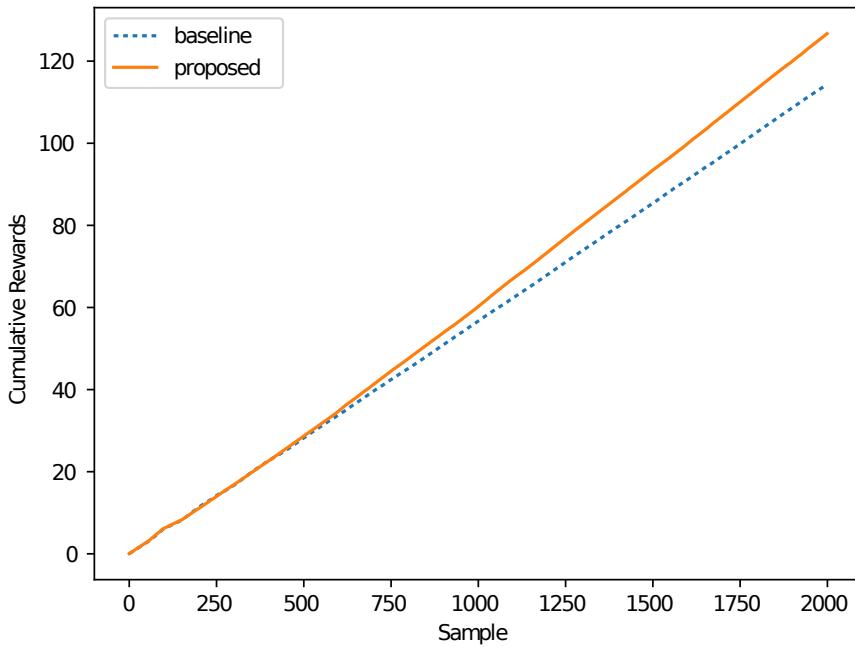


図 4.6: 累積クリック数の推移

$\max(0.403, 0.412)$), 小さい平均滞在時間 ($1.24 < \min(1.46, 1.48)$) を持っていることがわかる。このことから、提案手法はバリエーション x で条件付けられたフィードバック指標の分布 $p(z | x)$ を推定し、高速なウェブサイト最適化に活用できていることがわかる。

4.4.2 未知のバリエーションに対する推定

次に、フィードバック空間で推定された観測値の期待値分布を用いることで、未知のバリエーションについてもパフォーマンスを推定できることを評価する。これが可能になれば、観測に時間がかかる評価関数についても予測ができるようになり、ウェブサイト最適化の高速化ができるようになる。提案手法は高速なウェブサイト最適化手法を提供するだけでなく、フィードバック空間におけるクリック率の分布を与える。この特徴は**コールドスタート問題**に対するひとつの解法として使うことができると考えられる。コールドスタート問題とは推薦システムの構築において頻繁に議論される問題であり、新しいユーザや商品に対しては十分なデータが無いために推薦を行うまでに時間を要する問題のことである。ウェブサイト最適化は

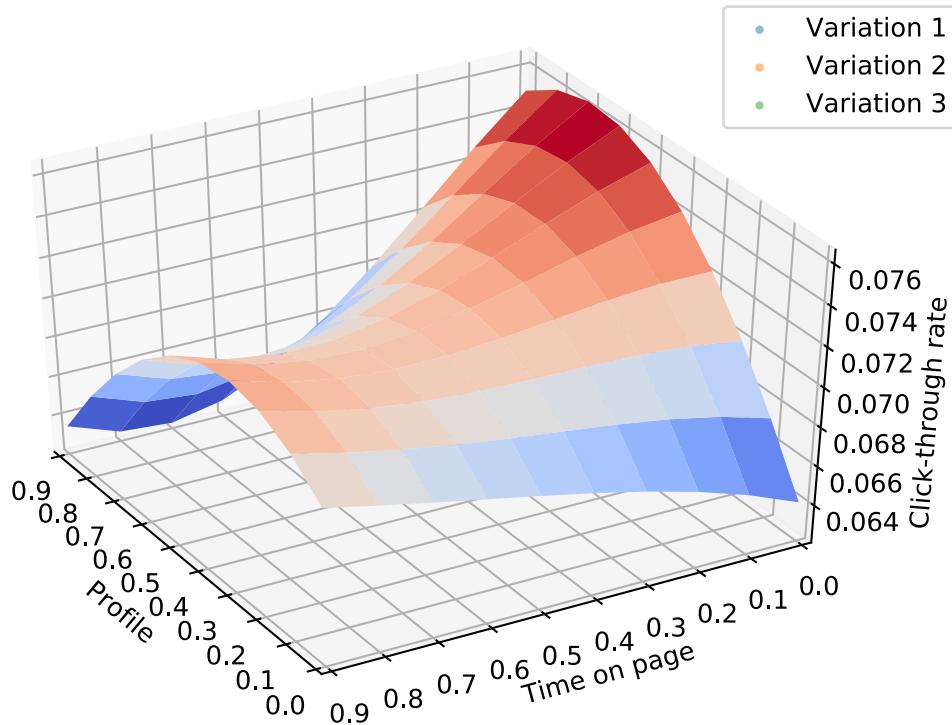


図 4.7: フィードバック空間 Z におけるクリック率の分布

ユーザの特徴を一定とした上で、最も望ましい結果を及ぼす商品 (=バリエーション) の推薦を行う推薦システムのひとつであるとみなすこともできる。したがって、コールドスタート問題はウェブサイト最適化にも共通する問題であり、未知のバリエーションから最適解を得るには時間要する。もし提案手法によって過去にウェブサイト最適化を行なった履歴があり、フィードバック空間におけるクリック率の分布が得られていれば、未知のバリエーションに対してもフィードバック指標さえ得られれば、高速にクリック率を予測することができると考えられる。

ここでは、提案手法が 2013 年 5 月 16 日のデータにもとづいて学習した期待値の分布を用いることで、未知のバリエーションに対しても高い正確度で最適なバリエーションを推定できることを評価する。ウェブサイト A では定期的に広告のクリック率を最適化する目的でウェブサイト最適化を行なっており、2013 年 6 月 6 日にも同じ目的指標に対して最適化を行い、同一のフィードバック指標を計測していた。そこで、ここでは 2013 年 6 月 6 日にテストされたバリエーションの中から最適なバリエーションを、推定された期待値の分布を用いない場合

表 4.2: 2013 年 6 月 6 日にウェブサイト A においてテストされたバリエーションに対する目的指標およびフィードバック指標の推定分布

X'	クリック率 y	プロフィールからの遷移 z_1	滞在時間 z_2
x_4	$Bernouli(0.0551)$	$Bernouli(0.4113)$	$Gamma(1.511, 20.659)$
x_5	$Bernouli(0.0683)$	$Bernouli(0.3764)$	$Gamma(1.341, 21.622)$
x_6	$Bernouli(0.0594)$	$Bernouli(0.3910)$	$Gamma(1.189, 24.738)$
x_7	$Bernouli(0.0656)$	$Bernouli(0.3858)$	$Gamma(1.318, 20.656)$
x_8	$Bernouli(0.0846)$	$Bernouli(0.3917)$	$Gamma(1.345, 20.990)$

に比べて良く推定できることを評価する。

表 4.2 に、2013 年 6 月 6 日にテストされたバリエーション $X' = \{x_4, x_5, x_6, x_7, x_8\}$ およびそれぞれに対して推定された目的指標 y およびフィードバック指標 z_1, z_2 の分布を示す。この期間にテストされていた 5 種類のバリエーションについて簡単に説明する。この期間のテストでは、主に相関図に表示するネットワークの構造を表すパラメータを調整することによるユーザの振る舞いの変化を観測していた。相関図ページの中心に表示されている人物を中心ノードと呼ぶことになると、中心ノードに直接つながりがあるノードを 1 次ノード、中心ノードと 1 次ノードを介してつながっているノードを 2 次ノードということができる。3 次ノードも同様である。ここで、相関図に表示されるネットワークの構造を (1 次ノードの表示数, 2 次ノードの表示数, 3 次ノードの表示数) というパラメータの組によって表すことになると、各バリエーションは $x_4 = (10, 2, 0), x_5 = (3, 3, 3), x_6 = (8, 3, 0), x_7 = (6, 4, 0)$ として表されるものであった。一方、バリエーション x_8 はネットワークの構造に関するバリエーションではなく、相関図につながりのカテゴリ（夫婦、友人、共演者など）を表示する新しい機能を備えたバリエーションである。目的指標であるクリック率に着目して表 4.2 を見ると、このバリエーションが最適バリエーションであったことがわかる。

この評価実験では、分布の初期値を持たない最適化エージェント A と 2013 年 5 月 16 日に学習した期待値の分布を初期値として持つ最適化エージェント B の二つを用意する。ここで言う最適化エージェントとは、ウェブサイトの中でユーザとの相互作用を介して最適なバリエーションを決定する存在のこととする。このように考えると、前項の実験は、UCB アルゴ

リズムを方策として持つ最適化エージェントと、フィードバック空間 Z における GP-UCB アルゴリズムを方策を持つ最適化エージェントの比較であったと言うことができる。各最適化エージェントに各バリエーション $x \in X'$ を 100 回ずつ試させ、計 500 個の目的指標の観測値 y およびフィードバック指標の観測値 z_1, z_2 を記録させる。その後、各エージェントに GP-UCB 方策にもとづいて最適なバリエーションを提示させることで、初期値の有無による推定のパフォーマンスの差を評価する。

評価指標として最適バリエーションを推定する正確度や、推定された最適バリエーションを引き続けた場合に得られる目的指標の期待値などが考えられる。ここでは、この二つの指標を用いて比較を行うこととする。以下では前項と同様に、500 回のシミュレーションを行った結果を元に説明を行う。

まず、最適バリエーションを推定する正確度を評価する。500 回のシミュレーションを行ったうち、初期分布を持たない最適化エージェント A が最適なバリエーションを推定できた正確度は 0.21 (105 回)、初期分布を持つ最適化エージェント B の正確度は 0.22 (110 回) であった。無作為に最適バリエーションを決定する場合でも正確度は $1/|X'| = 0.2$ を達成できることを考えると、有意に良い結果は得られなかった。

ウェブサイト最適化の状況によっては、最適なバリエーションではなくとも確実に目的指標の期待値を向上させることが重要な場合もある。そこで、ここでは最適解と推定されたバリエーションがもたらす目的指標の期待値による比較も行うこととする。図 4.8 に各最適化エージェントが推定する最適バリエーションの目的指標の期待値を比較したものを示す。中央値に着目すると最適化エージェント B が良い性能を示していることがわかる。分布の裾に着目しても、最適化エージェント A が上に裾が広い分布を示しているのに対し、最適化エージェント B の上方の裾は狭い。このことから、最適化エージェント B は最適化エージェント A に比べて安定して良い結果を与えることがわかる。各期待値の平均はそれぞれ 0.0655, 0.0676 であり、 t 検定の結果、有意水準 0.05 で有意な結果が得られた。最適化エージェント A は初期の 500 回の観測のみを上方として最適なバリエーションを推定しているため、最適化エージェント B に比べると期待値を上げることができていないことがわかる。したがって、各エージェントによって推定されるバリエーションの期待値に着目すると、初期値として目的指標の分布を持っている方が、有意に良い推定ができることが示された。

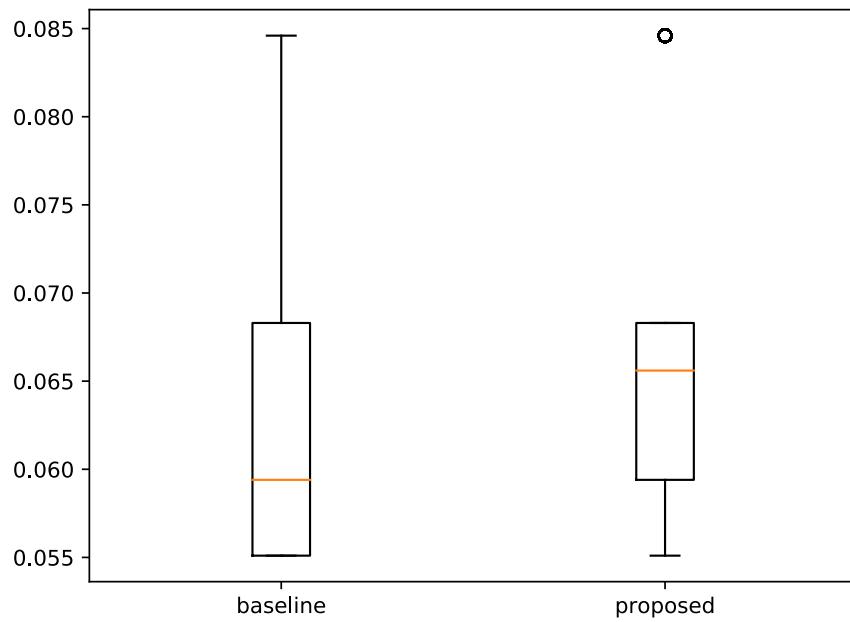


図 4.8: 各最適化エージェントが推定する最適バリエーションがもたらす目的指標の期待値比較

4.5 考察

評価実験の結果、提案手法を用いることで比較手法よりも高速に最適なバリエーションを見できることがわかった。このことは、目的となる評価指標に加えて、ユーザとの相互作用の中で得られる即時的なフィードバックも活用することで、より高速なウェブサイト最適化を実現できることを示している。

未知のバリエーションに対しても、過去の実験データから評価指標を予測するモデルを構築することで、比較手法に比べて高い正確度でより性能の良いバリエーションを推定できることが確かめられた。これは即時的に得られるフィードバックという短期的な指標から、目的な指標を予測することが可能であることを示している。したがって、ここで評価指標として観測に時間がかかる評価指標を設定すれば、提案手法を用いることで短期的な指標から長期的な効果を予測できるようになると考えられる。

評価指標と相関のある指標を用いてウェブサイト最適化の高速化を図るアイデア、および特徴空間における評価指標の期待値分布を過去データから推定することで長期的な指標の予測を行うアイデア自体は新しいものではない。しかし、あらゆるウェブサイトで測定できると考えられる即時的なフィードバック指標からこれらを実現する手法を提案したこと、またこれらの異なる問題の関連性を見直し、バンディットアルゴリズムを基本とした統一的な解法を提案したことにより本研究の貢献があると考えている。

提案手法をウェブサイトに適用するには、即時的なフィードバックを観測できる状況が整っている必要がある。本研究で用いたフィードバック指標は Google Analytics を用いて取得されたものであるが、このようにウェブサイト上のユーザ行動を記録するアクセス解析ツールは無料のものも多く、広範にウェブサイト制作において用いられている。したがって、ウェブサイトにおいてフィードバック指標を計測できる状況が整っている蓋然性は高いものと考えられる。

効率的な探索を実現するためには、評価指標との相関の大きいフィードバック指標を用いることが有効である。そのためには、過去データを用いた事前実験によって評価指標と相関関係の大きいフィードバック指標を特定する工夫を考えられる。また、ウェブサイトとユーザの相互作用を想定したシナリオを設定することで、評価指標と相関関係が大きいと予測される指標を想定することも有効だと考えられる。たとえば、ある商品を販売するウェブサイトならば、ユーザあたりの閲覧ページ数を向上できた方が、より多くの情報をユーザに提供することが出来て購買率にも正の効果を与えることができると考えられる。その場合、購買という発生頻度が低い事象のみに着目するよりも、ユーザあたりの閲覧ページ数というフィードバック指標も利用したほうが、より高速なウェブサイト最適化が実現できると考えられる。こういったユーザとウェブサイトの相互作用をシナリオの形で記述することは、ウェブサイト開発に限らずサービスの開発においては一般的な作業工程の一つである [下村 08]。あくまで評価指標とフィードバック指標の関連性はそのウェブサイトの性質に依存するものだが、このようなユーザがウェブサイトと関わるシナリオを想定することが、有用なフィードバック指標の特定に有用であると考えられる。

提案手法によって構築されたモデルはフィードバック指標によって構成される特徴空間上の期待値分布として表現されるため、その構造を直感的に読み取りやすい利点がある。たとえ

ば、滞在時間が長いほうが期待値が高いということが分かれば、よりユーザの滞在時間を長くするような施策を考え始めることができるようになる。このように、提案手法の探索の過程で得られたモデルは、未知のバリエーションに対する最適なバリエーションの推定機能を提供するだけではなく、ウェブサイト制作者の意思決定に役立つ情報を提供することができる。

一方でここで獲得される関係は、あくまで相関関係であり、因果関係で無いことに注意する必要がある。たとえば、今回の評価実験では滞在時間と広告のクリック率の間に負の相関関係が見られた。しかし、この相関関係から「滞在時間が短くなると、広告のクリック率が増加する」という因果関係が導かれるわけではない。むしろ「広告がよくクリックされるバリエーションでは、ユーザがいち早く広告先のページに遷移するため滞在時間が減少する」という逆の因果関係が成立している可能性があるため、設計された代替 KPI の解釈には注意が必要である。

本研究では、ウェブサイト最適化における長期的指標の予測に着目したが、同様の手法はウェブサイト最適化以外にも効果の測定に時間がかかる分野に適用できる可能性がある。たとえば、サービスに対するユーザの満足度やブランド価値など、本来長時間かけて醸成する必要がある指標について予測したい場合には、ソーシャルメディアでのユーザの反応や、ブログやレビューサイトにおける口コミ情報などが即時性のあるフィードバックとして使えるかもしれない。また、学校教育における新しいカリキュラムや行政における新たな政策立案など、今まで効果の測定に数年かかった分野においても、提案手法を応用することで高速に改善することが可能になると考えられる。

4.6 まとめ

本章では、ウェブサイト最適化における評価指標の設計を工夫することによるウェブサイト最適化の高速化に取り組んだ。高速なウェブサイト最適化を阻む評価指標の特徴として、分散が大きいことと観測に時間がかかるなどを挙げた上で、目的となる評価指標と相関の大きい制御変量を特定することとバリエーションに特徴表現を与えることがそれらの問題を解決する上で肝要であることを述べた。ユーザにバリエーションを表示したときに得られる即時的なフィードバックが評価指標と相関の高い制御変量として、そしてバリエーションに特徴表現を与える指標として汎用的に利用できることに着目し、フィードバック指標を活用したウェブサ

イト最適化手法を提案した。実際のウェブサイトのログデータを用いてシミュレーションを行なった結果、フィードバック指標を用いない比較手法に比べて、提案手法はフィードバック指標を活用することで高速に最適な指標の探索ができることが示された。また、探索の過程で構築されたモデルは、未知のバリエーションに対しても期待値の高いバリエーションを推定するのに有効であることが示された。このことは、観測に時間がかかる指標を短期的指標から予測することができる可能性を示している。提案手法はウェブサイト最適化に限らず、教育カリキュラムの策定や政策立案など、施策の効果測定に時間がかかる領域にも応用できる可能性がある。

第5章

ウェブページの文脈を用いた有望な解候補の生成方法

5.1 本章の背景と目的

本章では第三研究として、高速なウェブサイト最適化を実現するための有望な解候補の推定に取り組む。一般的なウェブサイト最適化問題では、候補となるバリエーションすなわち解候補は所与として扱うことが一般的である。ウェブサイト最適化におけるバリエーションは、ウェブデザイナやウェブエンジニアの勘と経験によって制作されることが多い。しかし、ウェブサイト最適化の解候補の生成に人手を介する必要があることは、ウェブサイト最適化の大規模化に人手がボトルネックになることを意味するため、ウェブサイト最適化の高速化の障壁となりうる問題である。もし有望な解候補の推定を自動化することができれば、あらかじめ探索手法と目的指標を与えるのみでウェブサイト最適化による仮説検証のサイクルを全自动で回すことができるようになると考えられる。そこで本章では、ウェブサイト最適化を目的とした有望な解候補の生成の問題を取り上げることにする。

一般的な数理最適化問題では、解を表す変数は一意に定まる。そのため、その変数が満たすべき制約が与えられれば、すなわち解空間が規定される。あとは、対象となる目的関数の特徴に適した解法を適用することで、最適解を求めることができる。しかし人工物をデザインする問題では、ひとつの解を表す変数は一意ではなく、様々な表現方法が考えられる。そのため人工物のデザインを考える場合には、解きたい問題に適した解の表現方法を選択することから考

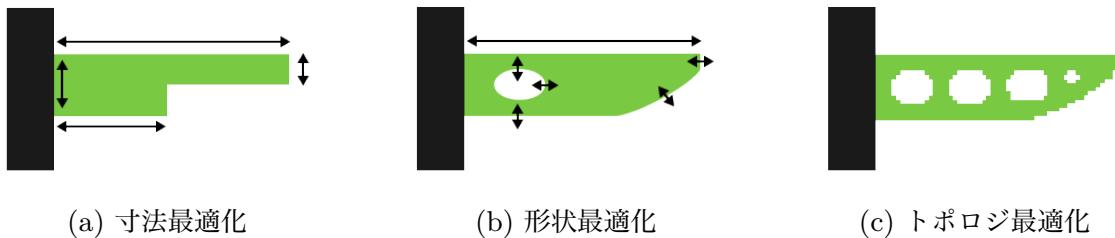


図 5.1: 構造最適化における解の表現方法の違い

えることが必要になる [松岡 08].

たとえば、最適化を用いて人工物のデザインを行う試みに構造最適化がある。構造最適化は、力学的観点と数理計画法に基づき、構造物の最適な形態および形状を得る方法である。構造最適化はその解の表現方法によって寸法最適化、形状最適化、トポロジ最適化の三つに分けられる [山田 09]。図 5.1 に各表現方法のイメージを示す。寸法最適化では、人工物の寸法を変数として扱うことで、最適な機能を提供する人工物を獲得することを目指す。形状最適化では、人工物の形状の境界をも変数と扱うことで、より良く機能を満たす人工物を獲得することを目指す。トポロジ最適化はこの中で最も自由度の高い方法であり、解をピクセル^{*1}の集まりとして扱う。穴の個数や形状を指定する必要が無いため、人間の試行錯誤では得られないような設計案が得られるという特徴がある [西脇 13]。

一方で、より表現力の高い解空間を採用するということは、本来の目的にはそぐわない解が生成される余地が生まれるということでもある。たとえば、片持ち梁の設計を考える問題の場合、寸法最適化であれば寸法が取る値に関わらず梁の形状が保たれることが期待される。しかし、トポロジ最適化を行うと梁としての形状を持たない解も生成される可能性がある。もちろん力学モデルを用いて梁としての機能を評価するため、既存の梁の形状を持たなくとも梁としての機能を持つ解が出力されることが期待されるが、解候補は膨大になるために一般に最適化の難易度は上昇する。実際、トポロジ最適化を用いた梁の設計において、格子状に体積を持つ解が生成されてしまう問題が報告されており [Diaz 95]、有望な解を獲得するためには最適化上の工夫が必要であるのが現状である。

したがって、ウェブサイト最適化におけるバリエーション生成においても、ウェブエンジニ

^{*1} 3 次元の場合は体積 (volume) を表すピクセル (pixel) であるため、ボクセル (voxel) と呼ばれる。

アやデザイナの思いつきに限らない多様な解を生成するためには、膨大な解候補の中から効率的に有望な解空間に絞り込む工夫が求められると考える。そのため本研究では、多様な解を生成する余地のある表現力の高い解空間を採用した際に、目的関数の期待値が高い有望な解の部分集合を出力する関数を構築することを目的とする。

解候補の中から有望な解の部分集合を出力するような関数を構築する手法としては様々な方法が考えられる。たとえば、事例データを入力層および出力層としたニューラルネットワークすなわち自己符号化器を用いる方法が考えられる。画像データを対象とする場合ならば、各ピクセルが次元に相当する高次元空間の中に強い偏りを持ちながら複雑に広がっている訓練データ集合を捉えることに相当する [岡谷 15]。

しかし、ここでは特に、ウェブサイトとユーザのインタラクションの特徴を活かした方法の有効性を検証したい。それは、バリエーションを生成する対象のウェブサイトの内容が事前に観測可能であるということである。一般に、ウェブサイトのバリエーションはウェブページの一部の視覚要素を変更したものであることが多く、ウェブページ全体のトピックや意図に沿ったバリエーションが生成されることが望ましい。ウェブデザイナやウェブエンジニアがバリエーションを考える際にも、対象のウェブページの内容が直感的に解候補を絞り込む上で大きな手がかりになっていると考えられる。

そこで本研究では、対象となるウェブサイトのコンテンツに着目することで、ユーザに表示するバリエーションを絞り込み、高速なウェブサイト最適化を実現する手法を提案する。図 5.2 に提案手法の概観を示す。提案手法では、まずウェブページからコンテンツを抽出するコンテンツ抽出器と、バリエーションを生成する対象となるコンポーネントの値を抽出するコンポーネント抽出器をウェブ上から収集した事例となるウェブページに適用する。抽出されたコンテンツとコンポーネントの対を事例として保持することで、事例ベースを構築する。ただし、コンポーネントは商品画像や購入ボタンなど、ウェブページに配置された要素のことを指すものとする。推論時には、バリエーションを生成したいウェブページに対してコンテンツ抽出器を適用し、抽出されたコンテンツと類似度が高いコンテンツを持つ事例を事例ベースから検索し、その事例に対応するコンポーネントを出力することで、対象のコンポーネントの解候補すなわちバリエーションを出力する。

評価実験では、アクセス解析ツール「AI アナリスト」を利用しているウェブサイトの一部

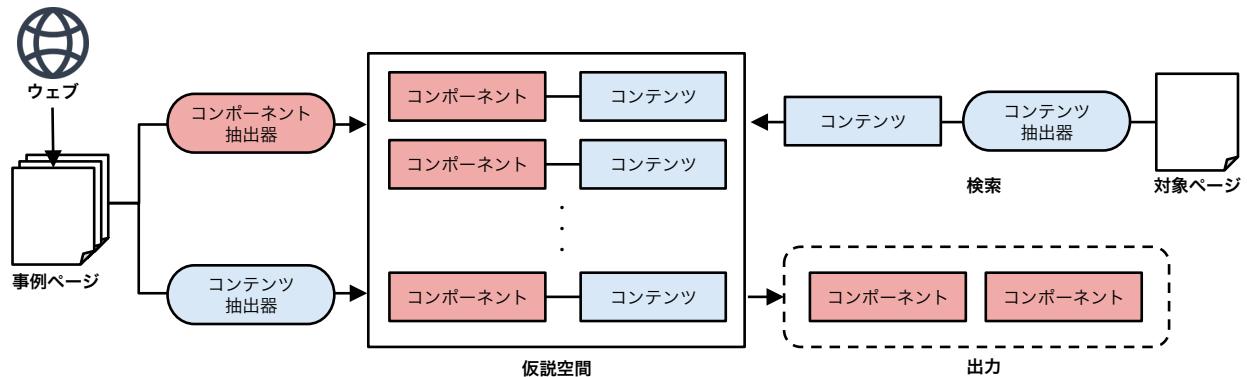


図 5.2: 提案手法の概観

を事例ベースとして用いた。また本研究では、あらゆるウェブページに共通して見られる蓋然性が高いコンポーネントとして Call-To-Action (CTA) ボタンのラベルを取り上げてバリエーションを生成する。CTA ボタンとは、前述したオバマ氏のウェブサイトにおける登録ボタンのように、ウェブサイトの目的となるユーザ行動を喚起するボタンのことである。E コマースサイトにおける商品の購入ボタンや、イベント告知サイトでの参加登録ボタンなどに相当するものであり、ウェブサイト最適化で対象となることが多いコンポーネントのひとつである。本研究ではこの単一のコンポーネントに着目するが、より汎用的なコンポーネントに対するバリエーション生成については第 5.5 節で議論する。

提案手法によって未知のウェブページの CTA ボタンのバリエーションを生成した結果、ウェブページの特徴に応じたバリエーションの生成ができることが確かめられた。また交差検証による評価実験の結果、無作為に事例ベースから値を出力する比較手法に比べて、提案手法は有意に高い再現率で元のラベルの値を推定できることがわかった。アンケート調査による評価実験の結果、提案手法は比較手法に比べて対象のウェブページに適したバリエーションを生成できることができることが確かめられた。本研究では CTA ボタンのラベル生成に着目したが、様々なウェブサイトから事例を集めることができるコンポーネントであれば、ヒーロー画像^{*2}やキャッチコピーなど CTA ボタンのラベル以外の要素にも適用可能な手法であると考えられる。

本研究の貢献は以下のとおりである。

- ウェブサイト最適化研究の中でも、これまで取り組まれてこなかったバリエーション生

^{*2} ウェブページの最も目につきやすいところに配置される画像のこと。

成の問題に取り組んだ。これはウェブサイト最適化に関する研究コミュニティに対して、新たな研究領域を提示するものである。

- 問題の類似性に基づいた事例ベース推論によってウェブサイト最適化のためのバリエーションを生成する手法を提案した。機械学習研究者にとっては、今後より高度な手法を導入できる余地が残されている。
- 評価実験を通して提案手法の有効性を明らかにした。ウェブサイト運営者は本手法を導入することでウェブサイト最適化の一部を自動化し、コスト削減を実現できると考えられる。

本論文の構成は以下のとおりである。第 5.2 節で関連研究、第 5.3 節で提案手法を説明する。第 5.4 節では定性的および定量的実験の結果を説明する。第 5.5 節を考察、第 5.6 節を本論文のまとめとする。

5.2 関連研究

本研究では特に CTA ボタンのラベルのバリエーション生成に着目して分析を行うが、これはあるタスクに対して適切な文字列を生成するという意味で、自然言語生成タスクとして捉えることができる。そこで、ここでは簡単に自然言語生成にまつわる関連研究を説明する。既存の自然言語生成手法は、構造化データをテンプレートに流し込むアプローチ、候補文集合から出力するアプローチ、そして Recurrent Neural Network (RNN) を用いたアプローチの大きく 3 つに分けられる。

構造化データをテンプレートに流し込むアプローチは、文章を生成したい対象を構造化データで表し、その構造データに対応するテンプレートを検索、利用することで文章を生成する。画像のキャプショニング [Farhadi 10] や手順書生成 [山崎 16] など、ドメインが限定的でテンプレートの記述さえ可能であれば有効な手法である。

候補文集合から出力するアプローチは対話システムの分野で活発に研究が進められており、ウェブ上から収集した候補文に基づいて発話するシステムが開発されている [柴田 09, 稲葉 14]。テンプレートを用いたアプローチに比べると扱うべきデータの量は増えるが、学習データによっては定型的でない多様な言い回しを生成できる利点がある。

近年では深層学習の一手法である RNN を用いた手法も登場しており、機械翻訳 [Sutskever 14]、画像キャプション生成 [Vinyals 15] などで高い成果を残している。テンプレートを必要としない多様な言い回しの出力が可能であり、候補文アプローチとは異なり候補文集合には存在しない文章の生成も可能になる。ただし、文法的に正しい文章を生成するためには十分な量のデータと学習時間が必要になる。

提案手法は候補文集合から出力するアプローチに属しており、定型的でない文章の作成が可能であり、学習が容易という特徴を持っている。

5.3 提案手法

提案手法の概要は図 5.2 で示したとおりである。提案手法は、まず事例となるウェブページの集合（**事例ページ集合**とよぶ）を収集し、コンテンツを抽出するコンテンツ抽出器と最適化したい対象のコンポーネントの値を抽出するコンポーネント抽出器を適用する。ただし、コンテンツ抽出器およびコンポーネント抽出器の具体的な実装は対象のコンポーネントに依るものとする。推論時には、バリエーションを生成したい対象のウェブページに対してコンテンツ抽出器を適用してコンテンツを抽出する。事例ベースの中で対象となるコンテンツと類似度が高いコンテンツに対応するコンポーネント集合を出力することで、対象のコンポーネントに対する解候補すなわちバリエーションを生成する。

ウェブサイト最適化においてバリエーションを生成する対象となるコンポーネントは様々であるが、本研究では特に CTA ボタンのラベル生成に着目して提案手法の説明および分析を進める。CTA ボタンはウェブサイト最適化でバリエーション生成の対象となるコンポーネントの中でも代表的なものであり、第 5.1 節で上げた例をはじめ様々な最適化事例がある [Kohavi 14, Siroker 13]。また、CTA ボタンはウェブサイトの目的となる行動に直接結びつくリンクであるため、目的を持ったウェブサイトである以上存在する蓋然性が高く、事例を集めやすいコンポーネントであるといえる。したがって、CTA ボタンについてバリエーションを生成することができれば、多くのウェブサイトが利益を享受できると考えられる。

CTA ボタンだけでもサイズや色などバリエーションを生成する変数は複数考えられる。その中でもサイズや色などの要素は有限の順序尺度の組み合わせで表すことができるため、あらかじめ解空間を定義することが可能であり、バリエーションはその中の解を用いることで容易

に生成できる。そのため、これらの本研究で提案するようなバリエーション生成手法を用いる必要がない。一方で、CTA ボタンのラベルはユーザに与えるインパクトが大きく最適化の対象となることが多い要素だが [Siroker 13]、非固定長の文字のシーケンスとして表されるため、あらかじめ解空間を定義することが難しい。提案手法は事例ベース推論を用いることで、解空間を定義することが難しいコンポーネントに対しても適用可能なものになっている。そこで、以下では CTA ボタンのラベルを例にとって提案手法の適用方法を説明する。

図 5.3 に提案手法を CTA ボタンのラベル生成に用いた場合の概要を示す。まず、各事例ページ $w \in W$ は CTA ボタンのラベルとその周りのコンテンツ情報から構成されるものとし、ウェブページからコンテンツを抽出するコンテンツ抽出器 *Contents* および CTA ボタンのラベルを抽出するコンポーネント抽出器 *Component* を適用する。コンテンツ抽出器 *Contents* はウェブページの本文に対してわかつ書きを行い、ウェブページに含まれる単語からなる Bag-of-Word ベクトルを抽出する関数である。コンポーネント抽出器 *Component* は、ウェブページの CTA ボタンのラベルを抽出する関数である。このようにして得られたコンテンツ x とラベル y を対として保持し、事例ベース $D = (X, Y)$ を構築する。ただし、ラベルが抽出できなかった場合は事例として含めないこととする。また、 X は事例ページ-単語次元からなるコンテンツ行列であり、 Y は対応するラベルのベクトルである。次に、コンテンツ行列 X に対して次元削減関数 f を適用することで次元削減を行い、 k 次元に削減した次元削減後コンテンツ行列 X_k を算出する。バリエーションの生成時には、対象ページ w' にコンテンツ抽出器 *Contents* および次元削減関数 f を適用することで、次元削減後コンテンツ x' を算出し、類似度の高い事例を検索後、対応するラベル y を出力することで、バリエーションの生成を行う。

ここで、CTA ボタンのラベル生成のためのコンテンツ抽出器 *Contents* として、ウェブページに含まれる単語に注目する理由を説明する。CTA ボタンのラベルは対象のウェブサイトの目的と関連が深いものであり、対象のウェブサイトに記述された内容に影響されていると考えられる。たとえば、商品を販売する目的を持ったウェブサイトであれば、「セール」や「商品」といった E コマースサイト特有の単語が多く記載されているはずであり、そういったウェブサイトには「購入する」「カートに入れる」といったラベルが望ましいと考えられる。一方で無形のサービスを提供するウェブサイトであれば、「コース」や「予約」といった単語が多く

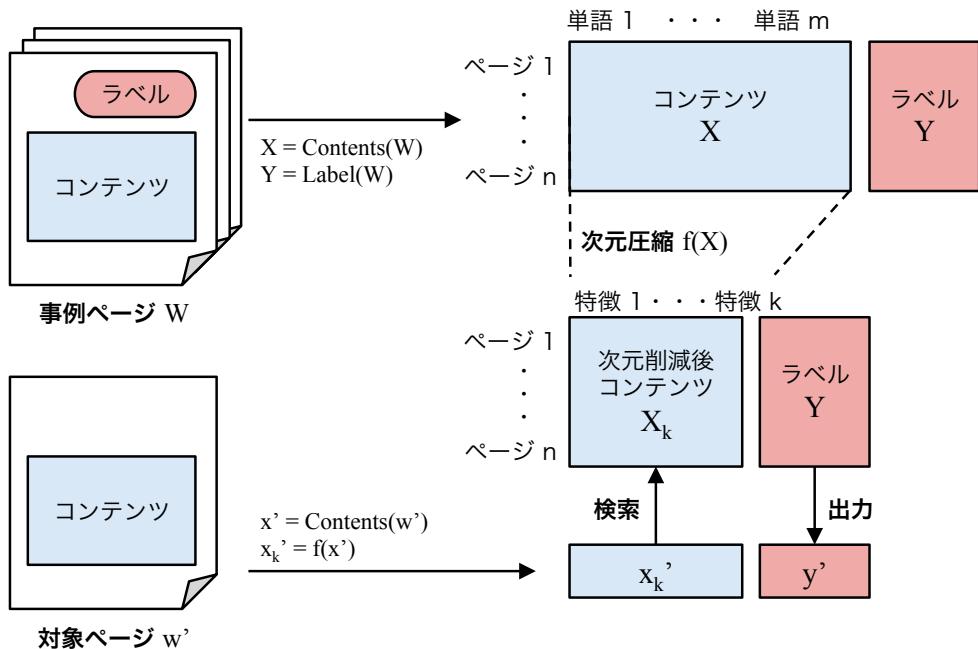


図 5.3: CTA ボタンのラベルに提案手法を適用する場合の概要

記載されているはずであり、そこには「資料請求する」や「申し込み」といったラベルが望ましいと考えられる。そこで本研究では、ウェブページ本文が含む単語からウェブサイトの目的を推定することが可能であり、その目的に応じて CTA ボタンのラベルが設計されているという仮説に基づき、コンテンツ抽出器 *Contents* として単語のわかつ書きを行う関数を用いることにする。

次に、コンテンツ抽出器 *Contents* の具体的な実装について述べる。コンテンツ抽出器 *Contents* は、事例ページ w に含まれる文章に分かつ書きを施し、単語集合 T_w を生成する。ただし、単語集合には自立語のみを含むものとする。さらに、各単語の出現の有無を 0, 1 の二値で表す Bag-of-Word 表現を用いることで、ウェブサイト w を m 次元のベクトル \mathbf{x} として表す。ただし、 m は事例ウェブサイトに含まれる全単語数 $|\bigcup_{w \in W} T_w|$ を表すものとする。最後に、コンテンツベクトル \mathbf{x} を n 個の事例ページ $w \in W$ すべてについて合わせることで、 n 行 m 列のコンテンツ行列 X を生成する。

ここで、コンテンツ行列 X は各単語を次元としたスペースな行列になるため、事例ウェブサイトの数が大きくなった際に、類似度計算が困難になる。また、ここではウェブサイトの内容が持つ潜在トピックに着目するために、類義語や同義語など類似した頻度で出現する単語を同

様に扱いたい。以上の要件を満たすために、ここではコンテンツ行列 X に Latent Semantic Analysis (LSA)[Landauer 98] を用いた次元削減およびトピック抽出を施すこととする。

LSA では、与えられた n 行 m 列の文章–単語行列 M を特異値分解を用いて $M = U\Sigma V^T$ なる三つの行列の積に変換する。ただし、行列 M の行が各文章、列が各単語を表しており、行列 Σ の対角成分は行列 M の特異値を大きいものから並べたものになっているものとする。このとき、行列 U および V の各列ベクトルが潜在トピックに対応しており、その寄与度の大きさの順で並んでいる。つまり、行列 U に着目することで、各文章が持っている潜在トピックを、行列 V に着目することで、各単語が持っている潜在トピックを確認することができる。

また、特異値分解によって得られた各行列 U, Σ, V の $k+1$ 列以降を削除して得られる行列 U_k, Σ_k, V_k を考えると、最初の二つの行列の積 $M_k = U_k \Sigma_k$ によって、 n 行 k 列の文章–トピック行列を得ることができる。本提案手法では、コンテンツ行列 X に対して同様の次元削減を施し、特異値分解の結果得られた行列 U, Σ, V を用いて次元削減後コンテンツ行列 X_k を生成する。

推論時には CTA ボタンのラベル候補を生成したいウェブサイト w' にコンテンツ抽出器 *Contents* を適用して Bag-of-Word ベクトル x' を生成する。さらに、LSA によって得られた行列 V を用いることで $x'_k = V_k^T x'$ として k 次元に削減し、次元削減後コンテンツ行列 X_k の各行との類似度を計算する。また、ベクトル同士の類似度としてコサイン類似度 $\cos(x_k, x'_k)$ を用いるものとする。

5.4 実験結果

本章では定性的および定量的評価を通して、提案手法が対象のウェブサイトに対して適切なバリエーションを生成できることを評価する。定性的評価では、三種類のウェブサイトに対してバリエーションを生成し、ウェブサイトの特徴に応じたバリエーションの生成ができる事を確認する。 K 分割交差検定による評価では、ラベル候補に含まれる文字集合の比較を通して、あらゆるウェブサイトに対して元のラベルと意味が大きく異なることがないラベル候補が生成されていることを確かめる。アンケート調査による評価では、ある特定のウェブサイトに対して生成したラベル候補を用いてスクリーンショットを撮影し、被験者が抱く印象を通して適切なラベル候補が出力されていることを評価する。

ウェブサイト 上位推定 CTA ボタン		
ウェブサイト A	お問い合わせ	(0.083)
	サインアップ	(0.090)
	サービスに関するお問い合わせ	(0.096)
	無料会員登録はこちら	(0.099)
	無料登録はこちら	(0.100)
ウェブサイト B	会員登録 (無料)	(0.103)
	ログイン	(0.110)
	お問い合わせ	(0.114)
	無料おためし体験	(0.116)
ウェブサイト C	資料請求	(0.125)
	カート	(0.092)
	お問い合わせ	(0.118)
	新規登録・ログイン	(0.118)
	ログイン	(0.126)
	オーダーフォーム	(0.127)

表 5.1: 提案手法によって生成されたウェブサイト A, B, C の CTA ボタン候補（括弧内はコサイン距離を表す）

5.4.1 実装方法

本実験では事例ページ集合として、アクセス解析ツール「AI アナリスト」を利用するウェブサイトのうち、十分なデータが得られた数百ウェブサイトを用いた。本ツールは国内の多岐にわたるウェブサイトによって導入されており、Google Analytics によって収集されたデータを解析することで、ウェブサイトのパフォーマンスを向上するためのアドバイスを提供するサービスを開発している。本ツールでは各ウェブサイトの運営者が、ウェブサイトの目的に相当するウェブページを登録しており、ユーザが実際にそのウェブページを訪問すると成果として計測される仕組みになっている。たとえば、会員制のサービスを開発しているウェブサイトならば、会員登録が完了した際に表示されるウェブページが目的のウェブページであり、ユー

ザが訪れた時点での成果として計測される。

一般的にウェブページには複数のリンクが含まれており、その中から CTA ボタンに相当するリンクを特定することは単純なタスクではない。しかし、本ツールを使っているウェブサイトならば、ウェブサイトの目的にたどり着くまでにユーザが辿ったリンクを遡ることができるので、ユーザがその過程を開始したリンクとして CTA ボタンを特定することができる。したがって、本ツールを使うことによって数百規模のウェブサイトについて CTA ボタンを特定することが可能になるため、本ツールに登録されたウェブサイトをデータセットとして採用した。

コンテンツ行列の生成にあたっては、事例ページ集合 W に含まれるテキストを収集し、形態素解析器 Mecab^{*3}を用いた形態素解析を行った。自立語以外は単語集合 T_w から除外した。また、ウェブページによっては CTA ボタンがナビゲーションバーやフッターに配置されており、同一の CTA ボタンを複数のウェブページが共有していることもある。このように、ひとつの CTA ボタンに複数のウェブページがひも付いている場合には、それらのウェブページに含まれる単語をまとめたものをひとつの事例として扱うこととする。また、ひとつのウェブページが異なる複数の CTA ボタンを持っている場合には、同じコンテンツを持った異なる事例として扱うこととする。以下では十分に高速に事例検索ができるよう、トピック数 $k = 30$ として LSA による次元削減を行うものとする。

5.4.2 定性的評価

定性的評価では、インターネット広告を出稿するツールの申し込みサイト（ウェブサイト A）、家事代行サービスの申し込みサイト（ウェブサイト B）、ペット用品に特化した E コーマスサイト（ウェブサイト C）を分析対象のウェブサイトとした。それぞれのサイトのスクリーンショットを図 5.4 に示す。出来る限り幅広い種類のウェブサイトを押さえるために、ウェブサービス、非ウェブサービス、形のある商品を扱ったサービスというように、お互い性質の異なるウェブサイトを選択するよう考慮した。各ウェブサイトのホームページに提案手法を適用して出力された CTA ボタンのラベル候補上位 5 個を表 5.1 に示す。

ウェブサイト A で取り扱われているツールはウェブブラウザ上で無料で利用することができます。

^{*3} Mecab <http://taku910.github.io/mecab/>



図 5.4: 実験対象のウェブサイトのスクリーンショット

きるウェブサービスであり、アカウントの登録が主な目的である。提案手法を用いることによって、「サインアップ」や「無料会員登録はこちら」、「無料登録はこちら」など、目的との親和性が高いラベルが候補として生成されている。

ウェブサイト B は家事代行サービスは家事代行サービスであり、お問い合わせや資料請求が主な目的となっている。「会員登録」や「ログイン」など、サービスの申し込みとは関係のないラベル候補も生成されてしまっているが、それに続く候補として、「お問い合わせ」「資料請求」といった、ウェブサイトの目的に適ったラベルを生成している。また「無料おためし体験」といった、訴求力が高いと考えられるラベルの生成にも成功している。なお、ここでは特定のサービス名が特定できるラベルは省略している。

ウェブサイト C はペットにまつわる商品に特化した E コマースサイトであり、ログインやアカウントの作成、さらにカートの閲覧が主な目的として設定されている。これまでのウェブサイトとは異なり「カート」や「オーダーフォーム」といった、購買行動に関する候補が並んでいる。このことから、提案手法が E コマースサイトという特性を捉えてラベルを出し分けていることが伺える。

5.4.3 交差検証による定量的評価

交差検証による評価では、事例ウェブサイトを $K = 100$ 個に分割して訓練データおよびテストデータを生成した。大きな割合をテストデータに分けると学習したモデルのパフォーマンスが落ちてしまうため、ある程度 K が大きい分割方法を採用した。

評価指標には、生成されたラベル候補上位 5 個に含まれる文字を予測集合、元のラベルに含まれる文字を正解集合とした場合の再現率を用いた。上位複数候補に含まれる文字の和集合を用いる理由は、評価するラベル候補の幅を持たせることで、表現は異なるが意味が類似するラベルを取りこぼすこと無く評価するためである。たとえば「無料おためし体験」と「無料トライアル」というラベルのように、意味が似ているにも関わらず表現が異なるラベル候補が出力される可能性があるが、1 位の候補にしか着目しない場合、このようなラベル候補を低く評価してしまう恐れがある。以上の理由で、本実験では評価する候補に幅を持たせて評価した。単語の分散表現を用いることで表現に依らない意味の類似度評価ができる可能性もあるが、ここでは分散表現獲得のためのコーパスや学習方法などの影響を取り除くために、極力単純な手法を用いて評価した。

次に、再現率を用いた理由を述べる。様々なバリエーションをユーザに表示して反応の違いを比較するウェブサイト最適化の目的を考えると、元のラベルと意味は似ていて表現のバリエーションに富んだラベル候補が输出されることが望ましい。ここで適合率に着目すると、元のラベルの一部を切り出してきた候補や单一的な候補生成が高く評価されてしまう可能性がある。そのため、本実験では適合率ではなく再現率を評価指標として採用することにした。

比較手法には、事例ベースからラベル候補を無作為に抽出する手法を採用する。対象となるウェブページのトピックを考慮しない単純な手法だが、事例ベースに保持されたラベルは他サイトで CTA ボタンのラベルとして利用されているものであるため、少なくとも CTA ボタンのラベルとして適したラベルを出力することはできる。他にも文章の分散表現 [Le 14] を用いた類似度計算による評価も考えられるが、ここでは単純に事例同士の類似度を利用したことによる改善度を評価するために、この比較手法を用いることとする。実験の結果、比較手法の再現率は 0.27、提案手法の再現率は 0.48 であり、 t 検定の結果、有意水準 $\alpha = 0.01$ で有意な結果が得られた。

5.4.4 アンケート調査による定量的評価

次にアンケート調査によって、提案手法によって生成されたラベル候補が対象ウェブページに適していることを評価した。まず、対象のウェブページからコンテンツを抽出してラベル候補を出力し、そのラベルを用いた CTA ボタンを埋め込んだスクリーンショットを撮影した。

その後、比較手法および提案手法によって生成されたスクリーンショットをアンケート被験者に見せ、抱いた印象を回答してもらうことで、それぞれの印象の違いを定量的に評価した。比較手法には、第5.4.3項と同様に事例ベースから無作為にラベル候補を出力する手法を用いた。

今回の実験では、東京大学グローバル消費インテリジェンス寄附講座^{*4}のウェブサイトを対象とした。ある講座に申し込むという目的が明確なCTAボタンが存在し、かつ構造がシンプルであるため本ウェブサイトを実験対象とした。提案手法および比較手法によって上位3位のラベル候補を生成し、合計6つのバリエーションを用意した。

アンケート調査では、クラウドソーシングを用いて300人の被験者を集め、3つの二択問題を各バリエーションに対して答えてもらった。被験者に尋ねた質問は

1. 「ボタンに書かれていることは、このウェブサイトに対して自然だと思いますか？」
2. 「ボタンをクリックした後に、どのような情報が表示されるか予想できますか？」
3. 「もしあなたがこのウェブサイトの利用者だとしたら、ボタンをクリックしてみたいと思いませんか？」

の3つである。アンケート実施期間は2016年3月22日から2016年3月24日の3日間であった。評価指標には各質問に対して肯定した被験者の割合を用いることにし、各手法が対象ページにとって適切なラベル候補を生成できることを評価した。

アンケート調査の結果を表5.2に示す。各手法によって生成された上位3位のラベル候補に対して肯定した割合の平均に着目すると、いずれの質問においても提案手法が比較手法に対して有意に多い肯定意見を獲得していた。すべての質問について合算した平均で比較すると、提案手法を用いることによって比較手法に比べて約58%多くの肯定意見を集めることができた。このことは、提案手法によってウェブサイト最適化のためのバリエーションとして適したラベル候補の生成が可能であることを示している。

^{*4} 東京大学グローバル消費インテリジェンス寄附講座 <http://gci.t.u-tokyo.ac.jp/>

手法	CTA ボタン	質問 1	質問 2	質問 3
比較手法	オーダーフォーム	38.7%	34.7%	17.7%
	お見積り	21.0%	46.7%	15.0%
	お問い合わせ	86.3%	89.0%	62.3%
	平均	48.7%	56.8%	31.7%
提案手法	入学説明会の受付	85.0%	89.3%	67.0%
	お問合せはこちらから	85.0%	90.3%	64.3%
	購読お申込み	63.7%	70.0%	36.0%
	平均	77.9%	83.2%	55.8%

表 5.2: 評価実験において生成されたラベル候補および獲得した肯定意見の割合 ($n = 300$)

5.5 考察

5.5.1 提案手法の適用可能性

今回の評価実験では、ウェブページを構成するコンポーネントの中でも特に CTA ボタンのラベルのバリエーション生成に着目した。対象ウェブサイトに対して実際にバリエーションを生成する定性評価実験では、取り扱う商品の性質が異なるウェブサイトでバリエーション生成を行うことによって、ウェブサイトの特徴に応じてバリエーションを出し分けることができる可能性を示した。交差検定による評価実験では、ラベル候補に含まれる文字集合の比較というナイーブな方法ではあるものの、事例ページ集合に含まれるすべてのページに対して、比較手法より良く元のバリエーションを推定できることがわかった。このことから、提案手法によって元のバリエーションと大きく意味が異なることのないバリエーションが生成されていることが示唆される。最後にアンケート調査による評価実験では、ひとつのウェブサイトに対象を絞ったものの、ユーザが抱く印象の面でも提案手法によって適切なバリエーションが生成できることを示した。

本提案手法は事例となるウェブサイトから適切な解を探索する手法であるため、事例が増えほど対応できるウェブサイトのトピックの種類が増加し、より広範のウェブサイトに対して

適切なバリエーション生成が可能になると考えられる。一方で、一般に事例ベース内の事例数が増えると類似する事例の探索に時間がかかるため、次元圧縮の方法や事例の探索方法に新たな工夫が必要になると考えられる。

逆に、入手できる事例ウェブサイトの数が少ない場合には、対象のウェブサイトに近い事例を探索できずに適したバリエーションを生成できない可能性がある。本研究では事例の可用性を担保するために、AI アナリストに登録されているウェブページおよび対応する CTA ボタンのラベルを用いたが、いつでもこのようなデータセットを用いることができるとは限らない。AI アナリストのようなデータセットがない場合には、ウェブページにおける CTA ボタンの特定が困難になる。そのような場合には、今後 HTML タグ情報やレンダリングされた視覚情報に着目することで、ツールに頼らない事例ベースの構築が可能にすることで、事例を増やすことができる可能性がある。

バリエーションを生成するコンポーネントに対して汎用的なコンテンツ抽出器が設計できれば、提案手法を用いることで CTA ボタンのラベルだけではなくウェブページのヒーロー画像やキャッチコピーといったコンポーネントに対してもバリエーション生成ができると考えられる。ただし、対象のコンポーネントと適切なコンテンツ抽出器の実装の関係は自明ではない。たとえば、今回の CTA ボタンのラベル生成では本文の単語に着目するコンテンツ抽出器を用いたが、CTA ボタンの背景色のバリエーションを生成したい場合に単語に着目する方法が妥当とは考えにくい。むしろ、ウェブページに使われている色の種類やヒストグラムに着目したほうが妥当だと考えられる。コンポーネントに応じたコンテンツ抽出器の設計方法は、今後の研究課題である。

また、提案手法によって生成されたラベルの中には、対象のウェブページとの関係は自然だが元のラベルと意味するところが変わってしまっているものも見られた。たとえば、「レジに進む」も「会員登録」も E コマースサイトに設置される CTA ボタンとしては自然ではあるが、CTA ボタンが意味するところは異なる。提案手法は適切なラベル候補が生成される確率を高めており、デザイン支援ツールとしては実用的であると考えられる。しかし、ウェブサイト最適化の完全自動化に向けてはリンク元とリンク先の両方のウェブページの内容を考慮してラベルを生成するような更なる改善が必要になると考えられる。

5.5.2 より汎用的なバリエーション生成に向けて

本章では CTA ボタンという特定のコンポーネントに絞って議論してきたが、CTA ボタン以外のコンポーネントに対するバリエーション生成も提案手法によって可能だろうか？ここではより汎用的なバリエーション生成について議論する。

本研究の提案手法は、ウェブデザイナやウェブエンジニアによる勘や経験によって選択された解空間ではなく、事例データの中から有望な解を高速に絞り込む特徴を対象のウェブサイトのコンテンツから抽出するものであった。したがって、事例を収集することができ、ウェブサイトのコンテンツが事例を分類するラベルとして機能するという仮定が成り立つのであれば、本手法を転用することができると考えられる。例えば、ウェブサイトのアイキャッチ画像やキャッチコピー等のコンポーネントはウェブサイトのコンテンツを反映したものであることが多いため、本手法を転用することが可能であると考えられる。

一方で、この仮定が成り立たないコンポーネントに対しては直接本手法を適用することは難しいと考えられる。たとえば、ウェブページのレイアウトはウェブサイトのコンテンツではなく、むしろその構造によって制約されるものである。したがって、ウェブサイトのコンテンツに含まれる単語のトピックに着目するようなアプローチでは最適なレイアウトを判断することは難しい。

また、ウェブサイトの機能についても、ウェブサイトのコンテンツから生成することは難しいと考えられる。たとえば宿泊施設予約サイトの運営者ならば、施設予約のコンバージョン率を上げるための施策として、同じ時刻に同じ宿を閲覧しているユーザの数を表示する施策を想起することは自然であろう。なぜならば Expedia^{*5}や Agoda^{*6}をはじめとする様々な宿泊施設予約サイトがこの工夫を導入しており、これらはもはや業界の常套手段だからである。しかし、提案手法を用いてこのような機能をもつバリエーションを自動生成するためには、この機能があらかじめ事例として仮説空間に含まれている必要がある。

ウェブサイトは HTML や CSS, Javascript によって記述されたプログラムの相互作用によって記述される。したがって、ウェブサイトを構築するあらゆるソースコードの集合をバリ

^{*5} Expedia <https://www.expedia.com>

^{*6} Agoda <https://www.agoda.com/>

エーションの表現として持てば、ソースコードのあらゆる文字列を最適化すべきパラメータとすることで、このような機能を発現することが可能になるかもしれない。しかし、それはコーディングの規約も含めてシステムが学習しなければならないことを意味し、学習の難易度は飛躍的に向上することが予想される。これを実現するためには、高度なパターン学習技術が必要になる。つまり、熟練したエンジニアがソースコード全部を読まずとも修正に必要な箇所を抜き出して修正を施すことができるよう、ソースコードからある機能が発現する箇所を特定する知能を実現することである。ソースコードを入力として特定の機能を発現する部分を特定する研究は Feature Location と呼ばれ、主にソフトウェアエンジニアの生産性を向上することを目的に研究が進められている [Dit 13]。新たな機能や視覚要素を発現できるようなバリエーション生成システムを構築するには、目的にかなう部分のみをうまく抜き出し、それ以外の部分を無視できるような学習システムが必要になるだろう。

5.6 まとめ

本研究では、ウェブサイト最適化におけるバリエーションの自動生成を取り上げ、事例ベース推論を用いた手法を提案した。分析および評価実験では特に CTA ボタンのラベル生成に着目して、ウェブページ本文に含まれる単語を問題記述とする方法でバリエーション生成を行った。複数のウェブサイトに対して提案手法を適用した結果、ウェブサイトの種類に応じたラベル候補を出力できる可能性が示唆された。また、交差検定およびアンケート調査による評価実験の結果、提案手法によってウェブサイトに適したラベル候補を出力できることが示された。本研究では CTA ボタンのラベル生成に着目したが、様々なウェブサイトから事例を集めることができるコンポーネントであれば、CTA ボタンのラベル以外の要素にも適用可能な手法であると考えられる。

第6章

考察

本章では各論で述べたことを整理し、提案手法の有用性および応用可能性を明らかにする。第6.1節では各論を振り返り、ウェブサイト最適化の高速化に対する各手法の貢献を整理する。第6.2節では、ウェブサイト最適化のシステム全体における各提案手法の位置づけを整理する。第6.3節では提案手法の適用範囲について議論し、ウェブサイト最適化にまつわる諸問題に対して本研究が解決できたところ、および解決できなかつたところを整理する。最後に第6.4節では、提案手法がウェブサイトに限らず一般のサービスについても応用できる可能性について議論する。

6.1 各論の総括

本研究では、第1章で我々の日常生活を取り巻くウェブサービスの状況について整理し、高速なウェブサイト最適化手法への要請を確認した。ウェブサイト最適化を様々なバリエーションの中からサービスの目的となる指標を最適化する解を探索する最適化問題として捉えると、その最適化問題の特性を捉えることが高速化の上で重要な課題となる。各論では高速なウェブサイト最適化手法の構築という大きな問題を探索方法の改善、評価指標の設計、有望な解候補の推定というサブ問題に落とし込み、ウェブサイト最適化問題の特性を活用した高速化に取り組んだ。

第3章では、ウェブページを構成する一部の要素の間の交互作用は無視できるという特性に着目して探索手法の設計を行なった。これは、ユーザがウェブページを目にしたときに、視覚

的に離れた要素間の交互作用は認知に影響を与えないという特性を仮定したものである。この特性を活用するため、はじめは各要素の影響の独立性を仮定して探索を開始し、途中から交互作用も考慮した局所探索によって最適解を探索する手法を提案した。

第4章では、ユーザがあるバリエーションに対して反応したときに得られるフィードバック指標と目的指標の間には何らかの関係があるという特性を活用して、より高速なウェブサイト最適化を実現する探索手法の設計を行なった。これは、ユーザがあるバリエーションに反応したときの行動にはなんらかのパターンがあり、多面的に見ることでよりその反応の変化をロバストに評価できることを仮定したものである。この特性を活用するため、目的指標だけではなくその他のフィードバック指標によって定義される特徴空間に各バリエーションの期待値分布を構成する手法を提案した。

第5章では、ユーザの行動を引き出すバリエーションに共通して存在するトピックの存在に着目して解候補の設計を行なった。これは、ウェブデザイナやエンジニアがバリエーションを制作するときには、できるだけ多様な選択肢を提示しようとするものの、伝えるべき内容や扱うコンテンツのテーマといったトピックを念頭に置いていることを仮定したものである。この特性を利用するため、バリエーションを利用されるコンテキストに則して特徴ベクトル化することで、効率的な解空間の絞り込みを可能にする手法を提案した。

上記のいずれの手法についても、実際のウェブサイトおよびそのログデータを利用することで評価を行なった。ウェブサイトとユーザの相互作用から生じるこれらの特性を仮定し、機械学習技術を用いてそれらを活用することで、より高速なウェブサイト最適化を実現できることを示すことができた。

6.2 ウェブサイト最適化システム全体における各論の位置づけ

第2.3節で述べたように、ウェブサイト最適化を探索問題として捉える方法は様々なものがあり、それぞれ異なる特徴を持つことを述べてきた。その中でも、離散的および連続的な特徴量を持った解すなわちバリエーションを扱うことができ、あるブラックボックスの期待値分布に従って評価値が与えられる環境下での最適化を扱うことができる枠組みとして、ベイズ最適化がある。ここでは、ベイズ最適化を使って様々なウェブサイト最適化問題をひとつのシステムとして統一的に記述し、その中における各論の提案手法の位置づけを整理したいと思う。

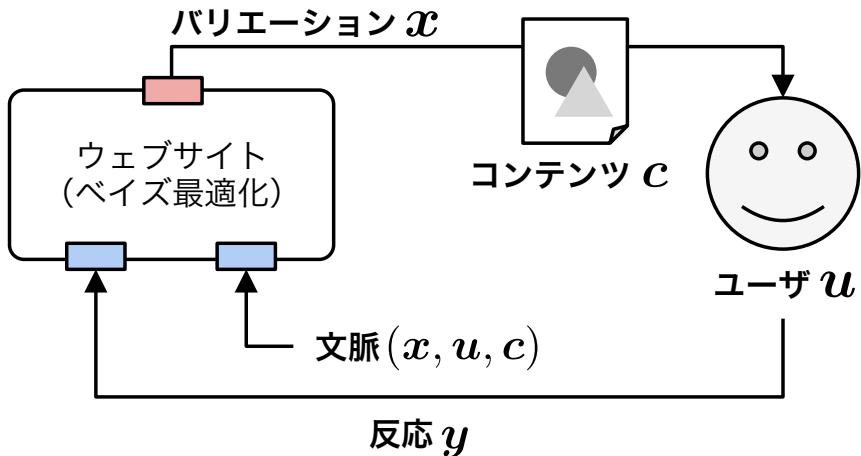


図 6.1: ウェブサイト最適化システムの全体像

提案するウェブサイト最適化システムの概要を図 6.1 に示す。ウェブサイトは表示するバリエーション x を決定してユーザに表示し、その反応として反応 y を得る。ウェブサイトは表示されたバリエーションの特徴 x とユーザからの反応 y を入力としてベイズ最適化を施すことで、探索と活用のバランスを取りながら逐次的に表示すべきバリエーションを選択し、ユーザの望ましい行動を引き出すバリエーションを探査する。

このとき、ベイズ最適化に入力する文脈は表示されたバリエーション x だけとは限らない。もしユーザの属性情報 u が手に入るのならば、第 2.3.2 項で述べた文脈付きバンディット問題に対する解法を用いることで、パーソナライゼーションも考慮した最適化を実現できる。また、バリエーションがウェブページを構成する特定のコンポーネントであるならば、その対象となるウェブページのコンテンツ c も考慮することで、コンテンツに即した最適なバリエーションの探索が可能になる。ここでは、このような付随情報を含めた文脈情報 $x' = (x, u, c)$ をベイズ最適化に対する入力としている。

もし、ウェブページにアクセスする時間が最適なバリエーションに大きな影響を与えるのならば、それを文脈に加えても良い。そのときの天気が重要ならば、天気を文脈に加えることも可能である。このように考慮する文脈を拡張することで、さらに粒度の細かい状況に応じた最適解を求めるようになると考えられる。たとえば、Google ではユーザのデモグラフィック特徴 u に加えて、天気や降水量などのデータを考慮して表示するバナー広告を切

り替える技術としてリアルタイム・データドリブン・クリエイティブを発表している^{*1}。これらの情報を利用することでクリック率を大きく向上できたことが報告されており、文脈を拡張することの有効性が示唆される。

ユーザから得られる反応 y についても、それは単一の目的指標からなるスカラー量である必要はなく、その他の反応も計測できるのならば反応の一要素として含めることができる。基本的には、反応を構成する素性のうちひとつを最終的な目標となる指標として定める必要があるが、もしその指標と他の素性に相関関係がある場合には、他の素性が探索を高速化するための制御変量として機能させることができる。第4章にて述べたフィードバック指標の利用は、反応 y を活用した高速化手法の一例である。また、複数の目的指標を最適化することを可能にする多目的最適化問題も活発に研究されている分野であり、ベイズ最適化に応用する試みも現れ始めている [Feliot 17]。このような手法を応用することで、より自由に目的指標を設定することができるようになると考えられる。

最後に、各論で提案した手法がこの提案システムにおいて果たす役割を整理したいと思う。第3章では、ウェブページを構成する要素の効果の線形性を仮定することで、高速に有望な初期解を推定し、局所探索によって交互作用つまり非線形性も考慮して最適解を探索する手法を提案した。この手法をベイズ最適化の文脈で見直してみると、はじめに線形カーネル関数を用いた探索を行い、次に二つの点の間の距離に基づくカーネル関数（RBF カーネル関数やマターンカーネル関数もこれに含まれる）を用いた探索を行ったことに相当する。つまり、前半は各特徴による効果の線形性を仮定し、後半は反応曲面は滑らかであることを仮定した探索を行ったことになる。本研究ではベイズ最適化を用いず、線形回帰と局所探索という決定論的なアルゴリズムの組み合わせを用いたが、今後ベイズ最適化の枠組みでより一般的な形で表現できるかもしれない。交互作用が強い要素とそうでない要素を特定し、交互作用が強い要素間には非線形の関係を、弱い要素間には線形の関係を仮定できるようなカーネル関数を設計することが今後の課題である。

第4章では、目的指標以外に与えられるユーザのフィードバック指標を活用することでウェブサイト最適化を高速化する手法を提案した。これはユーザからの反応がベクトル量として表

^{*1} どうしたらバナー広告の価値を上げられると思う？Googleの解は、外部データ連携のバナー自動生成だ — Web担当者 Forum <http://web-tan.forum.impressrd.jp/e/2016/11/16/24153>

されるときに、より高速な探索を実現するための手法について提案したことに相当する。本研究では、フィードバック空間において次に評価したい点を決定した後に、表示するバリエーションを決定する方法として平均との距離の評価を採用した。しかし、これはバリエーションの特徴空間を考慮しなかったから適用可能な手法であり、もしバリエーションがなんらかの特徴空間から生成されているのならば、フィードバック空間とバリエーション空間をより一般的に結びつける方法が必要になる。

第5章では、対象のウェブページのコンテンツを特徴として各バリエーションに付与することで、高速な有望な解候補の絞り込みを実現する方法を提案した。これはベイズ最適化の枠組みでいうと、文脈情報としてウェブページのコンテンツ c を含めたことに相当する。特微量が自明でない解候補に対して、ウェブページのコンテンツのトピックを Bag-of-Word 表現によって表したもの c をベイズ最適化の文脈情報に用いることで、有望な解への絞り込みの高速化を実現している。これは、解の特徴表現 x を直接求めるのではなく、その周辺の特徴 z によって代替し、ウェブサイト最適化を高速化する工夫だと捉えることができる。解の特徴表現 x そのものを求めるためには、第5.5節でも述べた通り、深層生成モデルの利用が有効であると考えられる。

6.3 提案手法の適用可能性とその限界

ここまででは主に单一のウェブページについての最適化を中心に取り扱ってきたが、その中では取り扱うことができなかつた問題も存在する。ここでは、各論で取り扱わなかつたウェブサイト最適化の諸問題について議論し、本提案手法の適用可能性およびその限界を議論する。

6.3.1 複数のウェブページにまたぐ最適化

まず、各論で取り扱わなかつた領域として、複数のウェブページにまたぐウェブサイト最適化がある。ここまででは主に单一のウェブページに対して様々なバリエーションを用意し、その中から最適なバリエーションを探索する手法について議論をしてきた。しかし、ウェブサイトは一般的に複数のウェブページから構成されており、それらはハイパーリンクによって接続されている。したがって、それらのハイパーリンクをユーザが辿る中で得られる経験こそがそのウェブサイトにおけるユーザ体験であり、複数のウェブページをまたいだウェブサイト最適化

も重要なテーマである。

提案手法では単一のウェブページについてバリエーションを生成し、評価を行なってきたので、そのまま提案手法をこの問題に適用することは難しい。しかし、第5章でコンテキストによってバリエーションを表現したように、何らかの方法で経路に含まれるウェブページのバリエーションに特徴表現を与えることができれば、それらを何らかの方法で特徴ベクトルに埋め込むことで提案手法を導入できるようになるかもしれない。

そこで著者らは、経路に含まれるウェブページの各特徴を組み合わせることで経路自体に特徴を与える試みを行った。これは、ウェブページに含まれる単語および平均滞在時間や離脱率といったユーザからのフィードバック指標を各ウェブページの特徴量とし、ユーザが辿ったウェブページの特徴量の重み付け線形和によって経路の特徴表現を得るものである [龍野 16]。

この潜在特徴空間における特徴量の示す意味、そして低コンバージョン率経路から高コンバージョン率経路へ向かうベクトルの意味を解釈することができれば、よりコンバージョン率の高い経路を設計するための手がかりとして活用することができるかもしれない。そのためにはもちろん実際のウェブサイトとこの結果を見比べることが有効だと考えられるが、各行列分解で得られた潜在特徴-経路特徴行列 V に着目することも有効であると考えられる。なぜなら、そちらの行列に各経路を表す特徴と各潜在特徴の間の関係が記述されているからである。また、各ウェブページの表現方法および経路への埋め込み方法も今回はナープな方法を用いたが、今後より精緻な手法を用いることで、より説明力の高いコンバージョン要因を特定できるようになるかもしれない。

ウェブサイトにおいて複数のウェブページにまたがるユーザ体験を最適化しようとすると、経路の表現獲得という新たな課題が立ち上ってくる。ここではウェブページの特徴を組み合わせることで経路の特徴を獲得する手法を提案したが、この有効性の評価は今後の研究課題である。もし経路の特徴量を掴むことができれば、特徴空間における探索問題に落とし込むことができるので、本提案手法を適用できるようになると考えられる。

6.3.2 数値化が困難な評価指標

ウェブサイトによっては、最適化の目的を数値化しにくい場合もある。たとえば、ウェブサイトの目的が製品やブランドのブランド価値を向上することだったり、特に明確な目的となる

行動は無いものの認知を広めることだったりすると、その効果を即座に測定することが難しくなる。この場合、その目的を数値化する方法から議論を始めなければならない。

ブランディングに限って言えば、対象のウェブサイトに対する反応をソーシャルメディア上で観測することができるのなら、それらの発言を解析することで代替的に測定可能な指標を設計することが可能になるかもしれない。主に Twitter を対象としてソーシャルメディアからのブランド価値の測定の試みは古くから行われており、たとえば、ブランドに対して抱く印象の極性分析の分析 [Jansen 09] や強み・弱点の分析 [Chamlertwat 12] が行われている。

企業によっては定期的に消費者に対するアンケートを行っており、独自のブランド価値調査資料を持っていることも考えられる。その場合は調査の頻度が問題になるが、この調査結果から定義されるブランド指標を観測に時間がかかる目的指標とみなし、第 4 章で提案した長期的指標に対する最適化方法を導入することも考えられる。しかし、いずれにしても最適化すべき指標の設計は、機械学習システムの利用者に委ねられる本質的な問題である。

6.3.3 様々な種類のウェブサイトに対する最適化

本研究ではあるウェブサイトにおけるバナー広告のクリック率の最大化や、E コマースサイトにおける購買率の最大化というように、目的とする指標が直接収益に結びつきやすく、測定もしやすい例を中心に取り扱ってきた。しかし、ウェブサイトの種類は様々であり、特定のボタンのクリックを目的としないウェブサイトや、ユーザ行動の促進よりも情報提供が主な目的となっているウェブサイトも存在する。ここでは、そういったウェブサイトにもウェブサイト最適化を導入可能であることを議論する。

まず、ウェブサイトをその収益モデルによって分類することから始めたい。一つ目として、トランザクションモデルが挙げられる [Moore 02]。これは E コマースや音楽や書籍をはじめとする電子データの購入のように、ユーザが直接対価を払うことで、商品を受け取る形態である。これはウェブサイト最適化を導入しやすい形態のひとつであり、ユーザが商品を購入するのを促進するために写真の表示方法を変更する、レイアウトを変更するなど様々な施策が考えられる。また、購入ボタンをクリックするという明確なアクションもあるため、最適化する指

標の設定も容易である。ここでは、Google Music^{*2}やApple Music^{*3}をはじめとする定額音楽配信サービスやGoogle Cloud Platform^{*4}やAmazon Web Services^{*5}をはじめとするクラウドサービスもユーザから直接対価を得るという意味ではこの分類に属するものとする^{*6}。

二つ目に、広告収益モデルが挙げられる。これは検索サービスやソーシャルメディアそして動画配信サービスなど、様々な大手のウェブサービスがこの収益モデルに属する。このモデルはユーザはサービスを無料で利用できる一方で、広告主がサービスに対して広告が表示された、もしくはクリックされた対価を支払う。トランザクションモデルとはお金の動きが異なるものの、ユーザがより特定の要素をクリックするように行動を最適化するという点では変わりない。また、トランザクションモデルと同様に、最適化する指標の設定もしやすいため、ウェブサイト最適化の導入は容易であると考えられる。

三つ目に、手数料モデルがある。これは、オークションサイトやクラウドファンディングサイトのように、プラットフォームを利用した商品のやり取りに対して手数料を課すモデルである。手数料モデルにおいても商品のやり取りが発生するため、そのやり取りを促すようにウェブサイト最適化を導入していくべきだ。

四つ目は、フリーミアムモデルである。これは、基本的なサービスは無料でユーザに提供し、より高度な機能には使用料金を課金するビジネスモデルである。有料機能の申込みを行うウェブページに関して言えば、トランザクションモデルと同様に購買率に対してウェブサイト最適化を導入できると考えられる。しかし、フリーミアムモデルにおいてその購買率を大きく左右するのは有料会員への申し込みを行うウェブページではなく、提供するサービスそのものの使いやすさから生まれるユーザ体験である。ウェブサービスの価値が大きく、さらに多くの機能を使いたいとユーザが感じることが、フリーミアムモデルにおいて収益を向上させる要因である。したがって、フリーミアムモデルにおいては単純なトランザクションモデルとは異なり、サービスにおけるユーザ体験を測定する指標を設定して最適化を行うことが肝要になる。

ユーザ体験を測定するための指標は自明ではないが、たとえば動画視聴サイトであれば一人

^{*2} Google Music <https://play.google.com/music/>

^{*3} Apple Music <https://www.apple.com/music/>

^{*4} Google Cloud Platform <https://cloud.google.com/>

^{*5} Amazon Web Services <https://aws.amazon.com>

^{*6} このように、利用期間および利用料に応じてユーザが料金を支払うモデルをサブスクリプションモデルと呼ぶこともある

あたりの視聴動画数や視聴時間を用いることで、サービスの利用度合いを測定することができる。他にも、メールサービスであれば一週間のアクセス頻度や、クラウドサービスであればアップロードしたファイル数などの指標によって利用の度合いを測ることができるかもしれない。したがって、フリーミアムモデルを取るウェブサービスでは、特定要素のクリックではなく、サービスの利用度合いを表す指標を定義して最適化を行うことが有効である。

一方で、サービスの利用度合いを表す指標は自明ではなく、サービスの特性の深い理解が必要とされる。例として、検索サービスにおける利用度合いを示す指標としてユーザあたりの入力クエリ数を設定する場合を考えてみる。ユーザあたりの入力クエリ数は、サービスが提供するユーザ体験が向上してユーザがより頻繁にウェブサービスを利用するようになった場合に向ふると考えられる。したがって、一見ユーザあたりの入力クエリ数が向上することは好ましい。しかし一方で、この指標は検索サービスの検索結果が芳しくなく、ユーザが欲しい情報を得るまでに様々なクエリを試すことを余儀なくされた場合にも向上してしまう指標である。実際、大手の検索サービス Bingにおいても、プログラムに埋め込まれたバグが彼らの評価指標を大きく向上する結果になったことが報告されている [Kohavi 12].

この事例では、ビジネスの視点で明らかに間違った施策によって向上できるような評価指標を設定しないこと、提供するサービスの深い理解を以て評価指標を設定することが肝要であると結論付けられており、一般化した解法は示されていないのが現状である。しかし、もしビジネスの目的上健全に評価指標が向上した場合と、バグによって評価指標が向上した場合の違いがあるユーザ行動に現れるとするならば、そのユーザ行動にまつわる指標を用いることでその違いを特定できるようになるかもしれない。検索サービスの例で言えば、検索結果のバグによって利用頻度が増えている場合には、検索結果を最後まで検討するスクロール量やページ滞在時間が減少することが予想される。本稿の第二研究では様々なユーザ行動の指標をウェブサイト最適化の高速化のために活用する手法を説明したが、評価指標に対して健全な最適化を行う頑強な手法として利用できるかもしれない。この性質の検証は今後の研究課題としていきたい。

最後の分類として、コーポレートサイトや個人のホームページのように、特にウェブサイトの目的となる明確なユーザ行動はないものの、情報提供のためのウェブサイトがある。このようなウェブサイトの目的は情報をユーザに提供することであり、訪問前後のユーザが保持する

情報の量が本来測定したいものである。訪問によってユーザが得た情報量を直接測定することは難しいが、ウェブサイトにおける滞在時間や訪問ページ数といった指標を用いることで、近似的にユーザが閲覧した情報の量を推定することができるかもしれない。また、情報提供を行うことが結果的に仕事の依頼や詳細についての問合せに繋がるものと考えれば、そういった行動を起こすためのリンクのクリック率を測定するという方法もあるだろう。

6.4 ウェブサイト以外への応用可能性

最後に本節では、ウェブサイト最適化が一般的なサービスに応用できることを考察したい。ウェブサービス以外にもウェブサイト最適化手法を取り入れることができれば、仮説検証によるサービス改善を実現できるようになり、サービス運営者は着実に利益を伸ばすことができるようになることが期待される。ここでは、ウェブサイト最適化手法を導入することができるサービスや製品の特徴、そしてウェブサイト最適化手法を導入するために必要な条件について説明する。

6.4.1 仮説検証のための条件

本稿で取り扱った狭義のウェブサイト最適化とは、異なるウェブサイトのバリエーションをユーザに提供して、その反応を比較することで確実にユーザの望ましい反応を引き出す方を選択しながらウェブサイトを改善させる手法のことであった。ウェブサービス以外への応用可能性を考えるには、このように顧客の反応を用いた仮説検証を行うための条件が担保できるか否かが重要である。ウェブサイト以外でも、その提供するサービスの状態を変更して顧客に提供することができ、かつそれに対する顧客の反応の違いを計測できるのであれば、A/B テストをはじめとするウェブサイト最適化手法を導入することができると考えられる。

仮説検証を行うための条件としては、以下のものが挙げられる。

- サービスに対する任意の修正を即座に反映できること。
- その修正に対する顧客の反応を計測できること。

これらの条件が満たされていれば、ウェブサイト以外にもウェブサイト最適化手法の導入は可能だと考えられる。

これらの条件を満たすためには、サービスを提供する主体とサービスを運営する主体が何らかの方法でつながっていることが必要となる。ここで言うサービスを提供する主体とは、顧客に直接サービスを提供する従業員やそのような機構のことを指すものであり、ウェブサービスで言えばウェブサイトである。サービスを運営する主体とは、サービスを提供する従業員や機構を管理するマネージャーのことを指すものであり、ウェブサービスで言えばウェブサイトの運営者である。この二者間がつながっていなければ、仮説検証のためにサービスを提供する主体に施すべき修正を伝えることも、その後計測された反応を集約することもできない。逆に言えば、この条件さえ満たされていればインターネットによって接続されていることは必要条件ではない。

たとえばある飲食サービスを考えたときに、サービスを提供する主体（ここでは従業員とする）とサービスを運営する主体（ここでは店長とする）が口頭のコミュニケーションなり何らかの手段を介してつながっていれば、簡単なウェブサイト最適化手法の導入はできる。例として、従業員グループAには顧客の注文を取る前に新製品を勧めるよう、他の従業員グループBには顧客の注文を取った後に勧めるよう店長が指示した場合を考えてみる。このとき、それぞれのグループで新製品が購入に結びついた率を計測すれば、どちらの施策に効果があるのかを評価できるようになる。

もし新しい製品が顧客に受け入れられるかどうかを知りたいのならば、その製品を作る前にまずメニューに載せてしまって、顧客に選択されるかどうかを計測するというテストが行われることもある⁷。これも一般的なサービスにおける仮説検証方法のひとつと言うことができるだろう。

このように、サービスを提供する主体と運営する主体が何らかの方法で接続されていれば、ウェブサービス以外のサービスでも様々な形で仮説検証をサービス改善に取り入れることは可能である。またサービスの規模によっては、個人経営店やフリーランサーのように、サービスを提供する主体と運営する主体が同一であることもあるだろう。

しかし、人間がサービスを提供する主体である場合には、高度なウェブサイト最適化手法を導入することは難しい。たとえば、第4章では、顧客の複数の種類のフィードバックから最適なバリエーションを検討する手法を紹介したが、これを人間の知覚からアノログで収集された

⁷ 実際の製品を作る前に重要を計測する方法として、pr“e”totype という造語で呼ばれることもある。

情報に対して同様の手法を適用することは難しいと考えられる。なぜなら、そのためには逐次的な統計的計算や様々な種類の反応の計測が必要になるからである。サービスを提供する主体が人間である場合にはその認知的および身体的な限界が、高度なウェブサイト最適化手法を導入する上での障壁となる。

それでは、もしサービスを提供する主体が製品であれば、高度なウェブサイト最適化手法の導入が可能になるのだろうか？たとえば、マッサージチェアを例に考えてみることにする。マッサージチェアにあらゆるセンサーを取り付ければ、ある作用に対する顧客の反応を計測することは可能になると考えられる。様々な計算を行うためのプログラムを導入することも可能である。しかし製品の場合には、逆にサービス運営者との接続の確立が問題になる。一般的に、製品は顧客が購入した後はその顧客が所有するものであり、その製品の製造者の手から離れる。そのため、基本的にはサービス運営者または製造者と製品の接続は切断され、より良い顧客の反応を引き出すための仮説検証を行う条件は担保されなくなる。

6.4.2 製品とサービスの性質の違い

それでは、ウェブ以外のサービスや製品において、ウェブサイト最適化手法が導入可能になるための特性は何だろうか。ここではまず、製品とサービスの違いについて整理して見通しを良くするところから始めたい。

製品とサービスの違いについては、経営学や工学など様々な学術分野で研究が進められてきた [住田 12]。サービスの特性を表す性質として IHIP 特性^{*8}が有名だが、この特性が当てはまらないサービスも存在するため、サービスと製品の違いを捉えることができないことが指摘されている [Edvardsson 05]。そこで住田らはこれまでに提案してきたサービスの特性をメタ分析し、新たにサービスと製品を分ける特性を提案している。ウェブサービスを含む様々なサービスを統一的に説明しており、サービスと製品に関するオントロジーに関する文献としては比較的新しい。そこでここでは、住田らの提案する作用モデルに則ってサービスと製品を分かつ特性について考えてみたい。

^{*8} inseparability (不可分性), heterogeneity (不均質性), intangibility (無形性), perishability (消滅性) の略。非可分性はサービスの生産と消費が同時に行われること、不均質性はサービスは品質が均一でないこと、無形性は物としての形をもたないこと、消滅性はサービスが生産と同時に消費されるために在庫として保持できないことを示している。

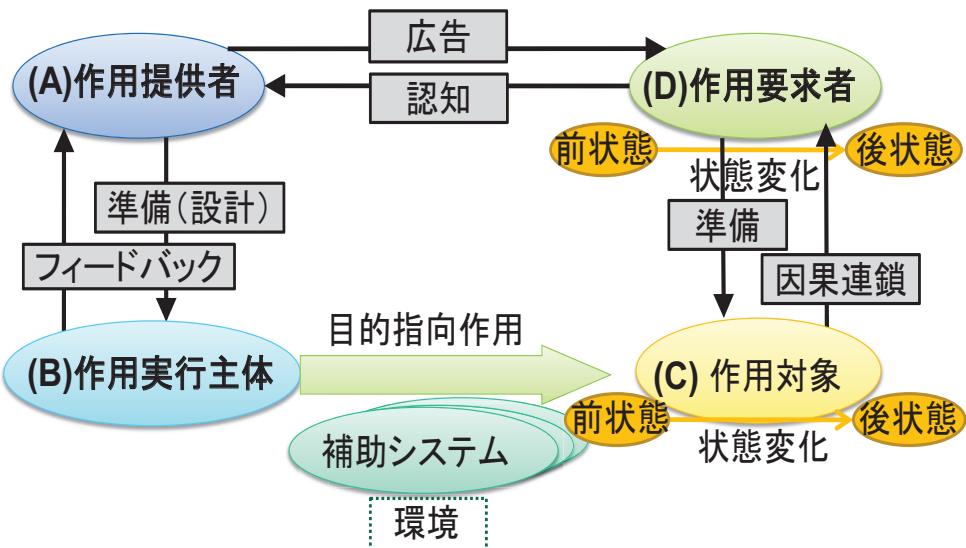


図 6.2: 住田らによる作用モデル（図は [住田 12] より引用）

図 6.2 に、住田らが提案する作用モデルの概要を示す。作用モデルでは、サービスおよび製品にまつわるステークホルダーとして (A) 作用提供者、(B) 作用実行主体、(C) 作用対象、(D) 作用要求者の 4 者を仮定する。ここで、(B) 作用実行主体は求められる作用を提供するサービスもしくは製品であり、顧客である (C) 作用対象に対して作用を提供する。教育サービスのように、作用の提供を求める主体（たとえば母親）と作用を与える対象（たとえば子ども）が異なることがあるため、作用対象に加えて (D) 作用要求者の存在を仮定している。作用要求者と作用対象は同一の場合もある。一方、作用を実際に提供する従業員を雇用するサービス運営者や、製品を製造する製造者の存在を表現するため、(A) 作用提供者の存在を仮定している。

このモデルではサービスと製品はともに作用を提供する主体であり、作用だけに着目すれば本質的な違いはない。しかし、その二つの間を分かつ性質として住田らは「作用要求者と作用実行主体の間の所有関係」を挙げている。たとえば、サービスであるマッサージ師によるマッサージと、製品であるマッサージチェアを例に挙げて考えてみる。サービスの場合は、マッサージ師が作用実行主体となって顧客の筋肉をほぐすという作用を提供するが、顧客である作用要求者とマッサージ師の間に所有関係は無い。あくまでマッサージ師は経営者である作用提供者との雇用関係にある。一方で製品の場合は、作用実行主体であるマッサージチェアと作用要求者である顧客の間に所有関係が発生する。このとき、作用提供者と作用実行主体との直接

表 6.1: サービスおよび製品の例

	人間	ソフトウェア	ハードウェア
顧客側所属 (製品的)	N/A	インストールが必要な 画像編集ソフトやオフ イスソフトなど	車や家電製品など一般 的な製品
提供側所属 (サービス的)	医療サービスや飲食 サービスなど主に人間 が提供するサービス	提供側が運用管理する ウェブサービスや蔵書 検索システムなど	インターネットに接続 された家電製品

的なつながりは切断されており、作用実行主体は作用要求者に属するものとなる。

仮にこの整理を採用すると、所有関係の有無が仮説検証を可能にするための条件に結びついていると考えることができる。一般にサービスと呼ばれるものは、サービス提供者である作用提供者との接続が保たれている。したがって、ウェブサイト最適化をはじめとする仮説検証を行うための前提条件が満たされている。一方で、一般に製品と呼ばれるものは顧客の所有のものに置かれるため、作用提供者との接続が切断される。そのため、仮説検証を行うための前提条件が満たされなくなる。つまり、作用実行主体の所属が作用提供者側であるか作用要求者側であるかが、サービスと製品を分かつ本質的な性質である。逆に言うと、その作用実行主体が人間であるか否かは本質的ではないことがわかる。これが、ウェブサービスや留守番電話サービスのように、人工物によって提供されるサービスが存在する所以である。

以上の整理を踏まえると、世の中のあらゆる作用を提供するものは、

- 作用実行主体が人間か人工物か
- 作用実行主体の所属が提供側か顧客側か

という軸で整理することができると考えられる。それぞれの象限に属するサービスおよび製品の例を表 6.1 に示す。ただし、ここではウェブサービスの位置を明確にするために、人工物をソフトウェアとハードウェアに分けて記述した。

まず、何らかの労働に携わる人間はサービスを提供する提供者との雇用関係にあり、顧客側

に所有されることはない^{*9}。医療サービスや飲食サービスなど、人間が主にサービスを提供するものがこの人間-提供側所属の象限に属する。

ソフトウェアについては、顧客側所属の意味合いが強いものと提供側所属の意味合いが強いものが存在する。CD や DVD などのメディアからインストールするソフトウェアは基本的にインストールされた端末の上で動くものであり、顧客側に所属する意味合いが強い。最近のソフトウェアはインターネットを介して利用状況を送信したり、エラーレポートを送る機能を提供したりするが、ウェブサービスのようにサーバのメンテナンス中は利用ができなくなったりすることではなく、また提供者から即時に変更を反映するようなこともできない。そのため、端末へのインストールを要する画像編集ソフトやオフィスソフトのようなソフトウェアは顧客側所属-ソフトウェアの象限に属する。また以上のような理由から、これらの製品にウェブサイト最適化の方法論を取り入れることで改善を行うことは難しい。

一方、提供側所属-ソフトウェアの象限には、ウェブサービスや蔵書検索システムなど、提供側が運用管理するソフトウェアによって提供されるサービスが属する。これらのソフトウェアは利用者である顧客に所属することなく、提供側が任意に修正することができる。これらのシステムに、異なるバリエーションを提供する機能やユーザの反応を計測する機構を取り付けることで、これまでに述べたよう高速なウェブサイト最適化を実現するための諸手法を導入することができる。

一般的なハードウェアは顧客側に属しており、提供者と利用状況を共有するような仕組みは導入されていない。たとえば、車や家電製品は日常生活で頻繁に使われる製品であるものの、現在ではインターネットや衛星通信などの手段で提供者と接続されているようなことはほとんど無いため、提供者は詳細な利用状況を知ることはできない。同様に、一度市場に出てしまったら修正を施すこともできない。そのため、何か不具合が発生した場合にはマスメディアを介したコミュニケーションを図ったり、ディーラーや家電量販店のネットワークを介した修正を行なったりする必要がある。

一方、今後 IoT 技術の進展によって、身の回りの様々な製品がインターネットに接続されるようになると、この状況が一変するかもしれない。様々な製品が固有の ID を持ち、インターネットを介して利用状況を作用提供者のサーバに送信する。作用提供者はその利用状況を元に

^{*9} ここでは、奴隸のように主人に所有される関係性のもと提供される作用は考えないものとする。

して、修正を加えたアップデートを施すことで不具合に対応できるようになるかもしれない。実際、テスラモーターズ^{*10}は提供する自家用車に出火の恐れがある不具合が発覚した際、インターネットを介したソフトウェア更新によって修理を行ない、利用者が自動車をディーラーを運ぶ手間を省いた^{*11}。つまり製品がインターネットに接続されるようになると、作用提供者との接続が確立されるため、サービスとしての性質を帯びるようになる。また、これは仮説検証を行うための条件であるため、ウェブサイト最適化手法が導入可能になることも意味している。インターネットに接続されたハードウェアは所有者のものでもあり、提供者のものでもある両面性を持ったものになる。こういった性質を持つ人工物に対するウェブサイト最適化の適用は、今後の研究課題としていきたい。

6.4.3 まとめ

本節ではウェブサイト最適化を可能にする条件として、仮説検証のための準備ができていること、すなわち「任意の修正を即座に反映できること」と「その修正に対する顧客の反応を計測できること」を挙げた。この条件の性質と作用実行主体の所属関係が密接な関係にあることを考察し、作用実行主体と作用提供者との接続が確保されることが、ウェブサイト最適化手法の導入には必要であることを述べた。従来は、作用実行主体と作用提供者が切り離された人工物がすなわち製品、雇用関係によって結び付けられた人間によって提供されるものがすなわちサービスと捉えることが一般的であった。しかしインターネットが登場したことによって、作用実行主体との接続を保つつつも作用要求者のもとで動作する人工物が一般的になり始めたため、サービスと製品の境界は曖昧なものになってきた。

そこで本節では、サービスもしくは製品という整理ではなく、顧客側もしくは提供側への所属という、より本質的な整理を導入することで作用提供主体を整理してウェブサイト最適化手法の応用可能性を考察した。その結果、将来 IoT 技術の普及とともにサービス的な性質を帯びてくるハードウェアにも、ウェブサイト最適化手法を導入することができる可能性が見えてきた。インターネットによって作用提供者と接続されたソフトウェアに対して仮説検証による改善を行うのがウェブサイト最適化であったが、今後インターネットによって接続されたハ

*10 Tesla <https://www.tesla.com>

*11 Tesla's Over-the-Air Fix: Best Example Yet of the Internet of Things? — WIRED <https://www.wired.com/insights/2014/02/teslas-air-fix-best-example-yet-internet-things/>

ドウェアに対しても仮説検証を通した改善が可能になるかもしれない。実際にハードウェアに対してウェブサイト最適化の方法論を導入し、より顧客の行動を引き出すことができるようになることの実証は、今後の研究課題としたい。

第7章

結論

本研究では、機械学習を用いることでユーザとウェブサイトの相互作用に起因する特性を抽出・活用し、高速なウェブサイト最適化を実現する最適化手法を提案した。第1章では本研究の背景および目的について説明し、第2章では本研究に関連する既存研究を説明し、本研究の位置づけを明確にした。第3章から第5章にわたる各論では、ウェブサイト最適化問題を構成する探索手法、評価関数、および解空間のそれぞれについて、高速なウェブサイト最適化を実現する最適化手法を提案した。

第3章では、高速なウェブサイト最適化を実現する探索手法の設計に取り組んだ。ウェブサイト最適化においてテストするバリエーションをボタンや画像などの要素の組み合わせとして捉えたときに、厳密には交互作用も含めたそれらの要素による作用がユーザに働きかけ、そのバリエーションのパフォーマンスとして観測される。しかし実際には要素が十分に離れている、もしくは性質が異なるなどの理由で、交互作用を考えずともバリエーションのパフォーマンスを推定でき、より少ないサンプルサイズで最適なバリエーションを推定できる可能性がある。ここでは、はじめに各要素の効果の線形性を仮定した回帰推定、後に交互作用の存在も仮定した局所探索を行う探索手法を導入することによって、より少ないサンプルサイズで最適なバリエーションを推定できることを示した。

第4章では、高速なウェブサイト最適化を実現する評価関数の設計に取り組んだ。ウェブサイト最適化ではウェブサイトの目的となる行為をユーザが達成すること、すなわちコンバージョンが発生することをバリエーションを評価する指標として据えるが、このときコンバージョン以外にもユーザの様々な振る舞いが、そのバリエーションを評価するための手がかりと

なりうる。たとえば、実際には商品の購入が発生せずとも、以前よりもユーザを長時間滞在させ、より商品に興味を持つてもらう事ができるようになったならば、それは長期的視野で見れば購入率の向上につながる改善であるはずである。ここでは、ユーザの様々なフィードバックの変化も考慮した評価指標を設計することで、より高速にバリエーションを発見するウェブサイト最適化手法を提案した。実際のウェブサイトのログデータを用いた評価実験の結果、提案手法を用いることにより少ないユーザ数で最適なバリエーションを推定できることがわかつた。さらに、観測に時間を要する評価関数についても、提案手法が探索時に構築するフィードバック特徴空間上のモデルは、未知のバリエーションについても長期的な評価値を推定できる機能を有していることを示した。

第5章では、高速なウェブサイト最適化を実現するための解空間の生成に取り組んだ。ウェブサイト最適化においてテストするバリエーションはウェブデザイナやエンジニアの人手によって制作されるのが一般的だが、これは膨大な解候補のなかから有望なバリエーション集合を勘と経験にもとづいて選択していると捉えることができる。このことがウェブサイト最適化を完全に自動化し、高速化するまでの障壁となっていた。ここでは、テストするバリエーションを制作する行為は、バリエーションを生成する対象となる要素の周辺のコンテキストに合ったもの、あらゆる解候補の中から選択することだと捉え、ウェブサイトのコンテキストを考慮してバリエーションの生成を行う手法を提案した。提案手法にもとづいて構築したシステムによって生成されたバリエーションを被験者に見せてアンケート調査した結果、本提案手法を用いることで有望なバリエーション集合を推定できることが示された。

第6章ではここまで述べた各論を踏まえ、提案手法の適用限界および応用可能性について議論した。特に、ウェブサービスに限らない一般のサービスへの応用可能性を議論し、消費者の行動とサービスの状態がデータ化されており、サービスの変更が即座に反映されるという条件を満たせば、本研究で取り上げた最適化手法を任意のサービスに応用できる可能性があることを述べた。今後ますます消費者とサービス提供者のやりとりがウェブを介して行われる流れが加速することを考えると、本研究で提案した手法は今後のサービス改善手法のスタンダードのひとつになりうるものだと考えている。

付録 A

Imagerous バリエーション例

第 3.3.4 項において評価された Imagerous (ウェブサイト B) のバリエーションの一例のスクリーンショットを示す。ただし、各解を構成する変数およびそれらが取りうる値は表 3.6 に示したとおりであり、各変数が取る変数値のインデックスの組み合わせによって解 x を表現するものとする。たとえば $x = (1, 1, 2, 0)$ は

{

画像の枠線の太さ: 5px,

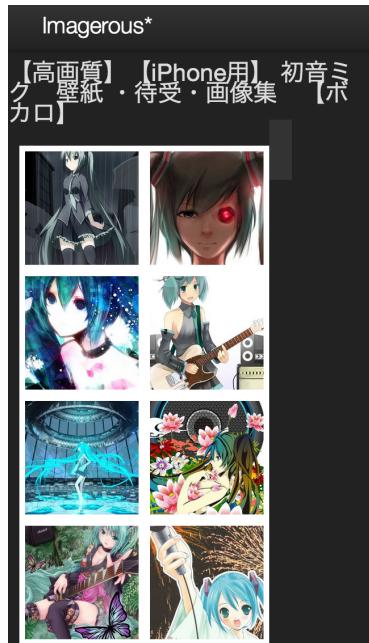
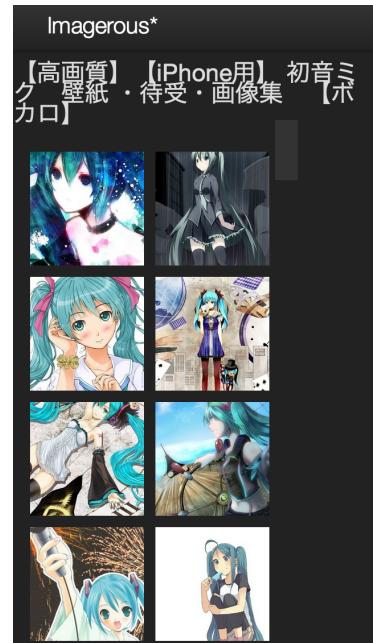
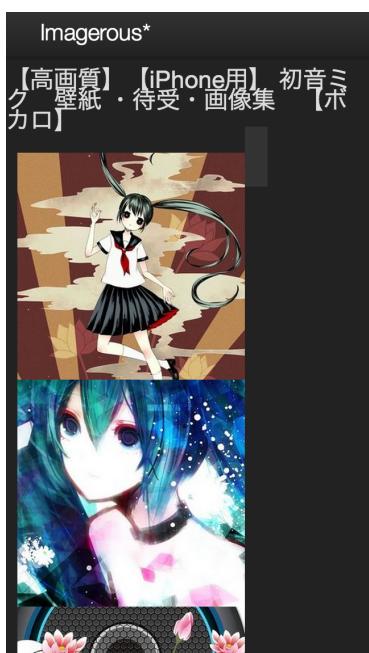
画像の間の間隔: 5px,

画像のサイズ: 300px,

画像の切り抜き: 正方形

}

という設定を表すものとする。

図 A.1: $\mathbf{x} = (0, 0, 0, 0)$ 図 A.2: $\mathbf{x} = (1, 0, 0, 0)$ 図 A.3: $\mathbf{x} = (0, 1, 0, 0)$ 図 A.4: $\mathbf{x} = (0, 0, 1, 0)$ 図 A.5: $\mathbf{x} = (0, 0, 0, 1)$ 図 A.6: $\mathbf{x} = (1, 2, 2, 1)$

謝辞

本研究を遂行するにあたり、指導教官である松尾 豊特任准教授から丁寧かつ熱心なご指導を賜りました。ここに厚く感謝の意を表します。また、本論文の副査である東京大学大学院工学系研究科 西野 成昭准教授、古田 一雄教授、堀 浩一教授、茂木 源人准教授には論文査読にあたり貴重なお時間を割いていただき、深い洞察を以って導いていただきました。深く感謝申し上げます。

私が恵まれた環境で研究をできたのは、日々松尾研究室を支えているスタッフの皆様のおかげです。特に秘書の永本 登代子さん、木全 弥栄さん、すでに退職されました中野 佐恵子さん、浪岡 亮子さんには書面作成や経理など様々な面で多大なるサポートをいただきました。ありがとうございます。また、中山 浩太郎特任講師および学術支援専門職員の皆さんによる計算機資源の整備がなければ、本研究を遂行することはできませんでした。感謝いたします。

私が継続的に研究活動に従事し、執筆に励むことができたのは、松尾研究室の研究仲間のおかげです。特に、お互いの執筆活動を支援する松尾研執筆サポートグループのメンバーである、岩澤 有祐氏、野中 尚輝氏、鈴木 雅大氏、黒滝 紘生氏に感謝いたします。そして、社会人博士として同期入学の落合 桂一氏に感謝いたします。彼らとのディスカッションがなければ、ここまで研究を続けることはできなかつたと思います。何より、研究の楽しさを教えてくれるかけがえのない時間でした。ありがとうございます。

私が仮説検証に基づくサービス改善の重要性およびその可能性の大きさを痛感した原体験は、オーマ株式会社にてウェブサービス構築に励む日々の中で得たものです。特に、苦楽を共にした元オーマ株式会社執行役員 アグチバヤル・アマルサナー氏、オーマ株式会社技術顧問 岡 瑞起氏に多大なる感謝の意を表します。

大津 裕史氏をはじめとする Wacul 株式会社のみなさんには、貴重なデータ提供および洞察

に富むディスカッションの双方で大変お世話になりました。心よりお礼申し上げます。また、一緒に共同研究に取り組んだ龍野 翔君のおかげで、チャレンジングな研究課題に取り組むことができました。ここに感謝の意を表します。

Google 合同会社のみなさんには、入社して半年で社会人博士になるという私の無茶な要望をご快諾いただき、多大なるサポートをいただきました。特に、入社して間もない私の申し入れを親身になって聞き入れてくれた Hai Kyung Min 氏、執筆活動に専念するため 1 ヶ月間休職する申し入れを快諾してくださった Nicholas Walsh 氏に感謝の意を表します。

最後に、私の社会人博士生活を見守ってくれた両親、そしていつも隣に寄り添ってくれた妻の涼菜に感謝します。どんなに研究がうまくいかない時も、仕事が忙しい時も、家に帰ると笑顔で迎えてくれる妻の存在に何度も救われました。本当にありがとう。

東京大学 大学院工学系研究科

技術経営戦略学専攻

飯塚 修平

参考文献

- [Agarwal 11] Agarwal, D., Chen, B.-C., Elango, P., and Wang, X.: Click shaping to optimize multiple objectives, in *Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 132–140, ACM (2011)
- [Ash 12] Ash, T., Ginty, M., and Page, R.: *Landing Page Optimization: The Definitive Guide to Testing and Tuning for Conversions*, ITPro collection, Wiley (2012)
- [Asllani 07] Asllani, A. and Lari, A.: Using genetic algorithm for dynamic and multiple criteria web-site optimizations, *European journal of operational research*, Vol. 176, No. 3, pp. 1767–1777 (2007)
- [Auer 02] Auer, P., Cesa-Bianchi, N., and Fischer, P.: Finite-time analysis of the multi-armed bandit problem, *Machine learning*, Vol. 47, No. 2-3, pp. 235–256 (2002)
- [Bajwa 06] Bajwa, I. S., Siddique, I., and Choudhary, M.: Web layout mining (wlm): a new paradigm for intelligent web layout design, in *ITI fourth International Conference on Information and Communications Technology* (2006)
- [Belle 98] Belle, van G. and Millard, S. P.: STRUTS: Statistical rules of thumb, *Departments of Environmental Health and Biostatistics, University of Washington* (1998)
- [Bengoetxea 02] Bengoetxea, E.: *Inexact graph matching using estimation of distribution algorithms*, PhD thesis, Ecole Nationale Supérieure des Télécommunications, Paris (2002)
- [Birattari 02] Birattari, M., Stützle, T., Paquete, L., and Varrentrapp, K.: A racing algorithm for configuring metaheuristics, in *Proceedings of the fourth Annual Conference on Genetic and Evolutionary Computation*, pp. 11–18, Morgan Kaufmann Publishers

- Inc. (2002)
- [Borodovsky 11] Borodovsky, S. and Rosset, S.: A/B testing at SweetIM: The importance of proper statistical analysis, in *Proceedings of the 2011 IEEE 11th International Conference on Data Mining Workshops*, pp. 733–740, IEEE (2011)
- [Brochu 10] Brochu, E., Cora, V. M., and De Freitas, N.: A tutorial on Bayesian optimization of expensive cost functions, with application to active user modeling and hierarchical reinforcement learning, *arXiv preprint arXiv:1012.2599* (2010)
- [Cai 03] Cai, D., Yu, S., Wen, J.-R., and Ma, W.-Y.: Extracting content structure for web pages based on visual representation, in *Web Technologies and Applications: fifth Asia-Pacific Web Conference*, pp. 406–417, Springer (2003)
- [Chamlertwat 12] Chamlertwat, W., Bhattacharjya, P., Rungkasiri, T., and Haruechaiyasak, C.: Discovering consumer insight from twitter via sentiment analysis, *J. UCS*, Vol. 18, No. 8, pp. 973–992 (2012)
- [Cohen 88] Cohen, J.: *Statistical Power Analysis for the Behavioral Sciences*, Psychology Press (1988)
- [Crook 09] Crook, T., Frasca, B., Kohavi, R., and Longbotham, R.: Seven pitfalls to avoid when running controlled experiments on the web, in *Proceedings of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1105–1114, ACM (2009)
- [Deng 13] Deng, A., Xu, Y., Kohavi, R., and Walker, T.: Improving the sensitivity of online controlled experiments by utilizing pre-experiment data, in *Proceedings of the sixth ACM International Conference on Web Search and Data Mining*, pp. 123–132, ACM (2013)
- [Diaz 95] Diaz, A. and Sigmund, O.: Checkerboard patterns in layout optimization, *Structural and Multidisciplinary Optimization*, Vol. 10, No. 1, pp. 40–45 (1995)
- [Dit 13] Dit, B., Revelle, M., Gethers, M., and Poshyvanyk, D.: Feature location in source code: a taxonomy and survey, *Journal of Software: Evolution and Process*, Vol. 25, No. 1, pp. 53–95 (2013)

- [Dmitriev 16] Dmitriev, P., Frasca, B., Gupta, S., Kohavi, R., and Vaz, G.: Pitfalls of long-term online controlled experiments, in *IEEE International Conference on Big Data*, pp. 1367–1376, IEEE (2016)
- [Edvardsson 05] Edvardsson, B., Gustafsson, A., and Roos, I.: Service portraits in service research: a critical review, *International Journal of Service Industry Management*, Vol. 16, No. 1, pp. 107–121 (2005)
- [Farhadi 10] Farhadi, A., Hejrati, M., Sadeghi, M. A., Young, P., Rashtchian, C., Hockenmaier, J., and Forsyth, D.: Every picture tells a story: Generating sentences from images, in *Computer Vision–ECCV 2010*, pp. 15–29, Springer (2010)
- [Feliot 17] Feliot, P., Bect, J., and Vazquez, E.: A Bayesian approach to constrained single-and multi-objective optimization, *Journal of Global Optimization*, Vol. 67, No. 1-2, pp. 97–133 (2017)
- [Filippi 10] Filippi, S., Cappe, O., Garivier, A., and Szepesvári, C.: Parametric bandits: The generalized linear case, in *Advances in Neural Information Processing Systems*, pp. 586–594 (2010)
- [Guo 15] Guo, Y. and Deng, A.: Flexible Online Repeated Measures Experiment, *arXiv preprint arXiv:1501.00450* (2015)
- [Heidrich-Meisner 09] Heidrich-Meisner, V. and Igel, C.: Hoeffding and Bernstein races for selecting policies in evolutionary direct policy search, in *Proceedings of the 26th Annual International Conference on Machine Learning*, pp. 401–408 (2009)
- [Hoffman 14] Hoffman, M., Shahriari, B., and Freitas, N.: On correlation and budget constraints in model-based bandit optimization with application to automatic machine learning, in *Artificial Intelligence and Statistics*, pp. 365–374 (2014)
- [Hohnhold 15] Hohnhold, H., O'Brien, D., and Tang, D.: Focusing on the long-term: It's good for users and business, in *Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1849–1858, ACM (2015)
- [Jansen 09] Jansen, B. J., Zhang, M., Sobel, K., and Chowdury, A.: Twitter power: Tweets as electronic word of mouth, *Journal of the American society for information*

- science and technology*, Vol. 60, No. 11, pp. 2169–2188 (2009)
- [Joshi 09] Joshi, P. M. and Liu, S.: Web document text and images extraction using DOM analysis and natural language processing, in *Proceedings of the ninth ACM Symposium on Document Engineering*, pp. 218–221, ACM (2009)
- [Kohavi 09] Kohavi, R., Longbotham, R., Sommerfield, D., and Henne, R. M.: Controlled experiments on the web: survey and practical guide, *Data Mining and Knowledge Discovery*, Vol. 18, No. 1, pp. 140–181 (2009)
- [Kohavi 11] Kohavi, R. and Longbotham, R.: Unexpected results in online controlled experiments, *ACM SIGKDD Explorations Newsletter*, Vol. 12, No. 2, pp. 31–35 (2011)
- [Kohavi 12] Kohavi, R., Deng, A., Frasca, B., Longbotham, R., Walker, T., and Xu, Y.: Trustworthy online controlled experiments: Five puzzling outcomes explained, in *Proceedings of the 18th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 786–794, ACM (2012)
- [Kohavi 14] Kohavi, R., Deng, A., Longbotham, R., and Xu, Y.: Seven rules of thumb for web site experimenters, in *Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1857–1866, ACM (2014)
- [Kohlschütter 08] Kohlschütter, C. and Nejdl, W.: A densitometric approach to web page segmentation, in *Proceedings of the 17th ACM Conference on Information and Knowledge Management*, pp. 1173–1182, ACM (2008)
- [Kumar 11] Kumar, R., Talton, J. O., Ahmad, S., and Klemmer, S. R.: Bricolage: example-based retargeting for web design, in *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, pp. 2197–2206, ACM (2011)
- [Landauer 98] Landauer, T. K., Foltz, P. W., and Laham, D.: An introduction to latent semantic analysis, *Discourse processes*, Vol. 25, No. 2-3, pp. 259–284 (1998)
- [Le 06] Le, D., Thoma, G. R., and Zou, J.: Combining DOM tree and geometric layout analysis for online medical journal article segmentation, in *Proceedings of the sixth ACM/IEEE-CS Joint Conference on Digital Libraries*, pp. 119–128, IEEE (2006)
- [Le 14] Le, Q. V. and Mikolov, T.: Distributed Representations of Sentences and Doc-

- uments., in *Proceedings of the 31st International Conference on Machine Learning*, Vol. 14, pp. 1188–1196 (2014)
- [Leffingwell 07] Leffingwell, D.: *Scaling software agility: best practices for large enterprises*, Pearson Education (2007)
- [Lewis 08] Lewis, M.: Evolutionary visual art and design, in *The Art of Artificial Evolution*, pp. 3–37, Springer (2008)
- [Li 10a] Li, L., Chu, W., Langford, J., and Schapire, R. E.: A contextual-bandit approach to personalized news article recommendation, in *Proceedings of the 19th International Conference on World Wide Web*, pp. 661–670, ACM (2010)
- [Li 10b] Li, W., Wang, X., Zhang, R., Cui, Y., Mao, J., and Jin, R.: Exploitation and exploration in a performance based contextual advertising system, in *Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 27–36, ACM (2010)
- [Lin 02] Lin, S.-H. and Ho, J.-M.: Discovering informative content blocks from Web documents, in *Proceedings of the eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 588–593, ACM (2002)
- [Lomas 16] Lomas, J. D., Forlizzi, J., Poonwala, N., Patel, N., Shodhan, S., Patel, K., Koedinger, K., and Brunskill, E.: Interface design optimization as a multi-armed bandit problem, in *Proceedings of the 2016 CHI Conference on Human Factors in Computing Systems*, pp. 4142–4153, ACM (2016)
- [Lu 10] Lu, T., Pál, D., and Pál, M.: Contextual multi-armed bandits, in *Proceedings of the 13th International Conference on Artificial Intelligence and Statistics*, pp. 485–492, PMLR (2010)
- [Moore 02] Moore, G. A.: *Crossing the chasm*, Capstone (2002)
- [Nie 09] Nie, Z., Wen, J.-R., and Ma, W.-Y.: Webpage understanding: beyond page-level search, *SIGMOD Rec.*, Vol. 37, No. 4, pp. 48–54 (2009)
- [Park 07] Park, S.: *Webpage design optimization using genetic algorithm driven CSS*, PhD thesis, Iowa State University (2007)

- [Penalver 98] Penalver, J. G. and Merelo, J.: Optimizing web page layout using an annealed genetic algorithm as client-side script, in *Proceedings of the International Conference on Parallel Problem Solving from Nature*, pp. 1018–1027, Springer (1998)
- [Ries 11] Ries, E.: *The Lean Startup: How Today's Entrepreneurs Use Continuous Innovation to Create Radically Successful Businesses*, Crown Books (2011)
- [Russo 16] Russo, D. and Van Roy, B.: An information-theoretic analysis of Thompson sampling, *Journal of Machine Learning Research*, Vol. 17, No. 68, pp. 1–30 (2016)
- [Sengamedu 08] Sengamedu, S. H. and Mehta, R. R.: Web page layout optimization using section importance, in *Proceedings of the 17th International Conference on World Wide Web*, ACM (2008)
- [Siroker 13] Siroker, D. and Koomen, P.: *A/B Testing: The Most Powerful Way to Turn Clicks Into Customers*, John Wiley & Sons (2013)
- [Sommerville 11] Sommerville, I.: *Software Engineering*, Pearson (2011)
- [Spear 04] Spear, S. J.: Learning to lead at Toyota, *Harvard Business Review*, Vol. 82, No. 5, pp. 78–91 (2004)
- [Srinivas 10] Srinivas, N., Krause, A., Seeger, M., and Kakade, S. M.: Gaussian process optimization in the bandit setting: no regret and experimental design, in *Proceedings of the 27th International Conference on Machine Learning*, pp. 1015–1022, Omnipress (2010)
- [Sutskever 14] Sutskever, I., Vinyals, O., and Le, Q. V.: Sequence to sequence learning with neural networks, in *Advances in neural information processing systems*, pp. 3104–3112 (2014)
- [Takagi 01] Takagi, H.: Interactive evolutionary computation: Fusion of the capabilities of EC optimization and human evaluation, *Proceedings of the IEEE*, Vol. 89, No. 9, pp. 1275–1296 (2001)
- [Tang 10] Tang, D., Agarwal, A., O'Brien, D., and Meyer, M.: Overlapping experiment infrastructure: More, better, faster experimentation, in *Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 17–

- 26, ACM (2010)
- [Thompson 09] Thompson, A.: Automated generation of website content and layout, *Michigan Celebration of Women in Computing*, p. 43 (2009)
- [Vinyals 15] Vinyals, O., Toshev, A., Bengio, S., and Erhan, D.: Show and tell: A neural image caption generator, in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 3156–3164 (2015)
- [Wolpert 97] Wolpert, D. H. and Macready, W. G.: No free lunch theorems for optimization, *IEEE Transactions on Evolutionary Computation*, Vol. 1, No. 1, pp. 67–82 (1997)
- [Womack 90] Womack, J. P., Jones, D. T., and Roos, D.: *Machine that changed the world*, Simon and Schuster (1990)
- [伊理 95] 伊理 正夫, 今野 浩, 刀根 薫: 最適化ハンドブック, 朝倉書店 (1995)
- [稲葉 14] 稲葉 通将, 神園 彩香, 高橋 健一: Twitter を用いた非タスク指向型対話システムのための発話候補文獲得, 人工知能学会論文誌, Vol. 29, No. 1, pp. 21–31 (2014)
- [岡谷 15] 岡谷 貴之: 深層学習, 講談社 (2015)
- [下村 08] 下村 芳樹, 新井 民夫: サービス工学におけるオントロジー中心設計の展開, 人工知能学会論文誌, Vol. 23, No. 6, pp. 721–727 (2008)
- [海野 15] 海野 裕也, 岡野原 大輔, 得居 誠也, 徳永 拓之: オンライン機械学習, 講談社 (2015)
- [久保 12] 久保 幹雄, Pedroso, J. P., 村松 正和, Rais, A.: あたらしい数理最適化: Python 言語と Gurobi で解く, 近代科学社 (2012)
- [金澤 04] 金澤 貴彦, 安田 恵一郎: Proximate Optimality Principleに基づく Tabu Search, 電気学会論文誌. C, Vol. 124, No. 3, pp. 912–920 (2004)
- [栗原 11] 栗原 伸一: 入門 統計学—検定から多変量解析・実験計画法まで—, オーム社 (2011)
- [穴井 15] 穴井 宏和, 斎藤 努: 今日から使える! 組合せ最適化 離散問題ガイドブック, 講談社 (2015)
- [山崎 16] 山崎 健史, 吉野 幸一郎, 前田 浩邦, 笹田 鉄郎, 橋本 敦史, 舟富 卓哉, 山肩 洋子, 森 信介 他: フローグラフからの手順書の生成, 情報処理学会論文誌, Vol. 57, No. 3, pp. 849–862 (2016)

- [山田 09] 山田 崇恭, 西脇 真二, 泉井 一浩, 吉村 允孝, 竹澤 晃弘：レベルセット法による形状表現を用いたフェーズフィールド法の考え方に基づくトポロジー最適化, 日本機械学会論文集 A 編, Vol. 75, No. 753, pp. 550–558 (2009)
- [柴田 09] 柴田 雅博, 富浦 洋一, 西口 友美：雑談自由対話を実現するための WWW 上の文書からの妥当な候補文選択手法, 人工知能学会論文誌, Vol. 24, No. 6, pp. 507–519 (2009)
- [住田 12] 住田 光平, 來村 徳信, 笹嶋 宗彦, 高藤 淳, 溝口 理一郎：オントロジー工学に基づくサービスの本質的性質の考察, 人工知能学会論文誌, Vol. 27, No. 3, pp. 176–192 (2012)
- [松岡 08] 松岡 由幸, 宮田 悟志：最適デザインの概念, 共立出版 (2008)
- [松本 92] 松本 吉弘：ソフトウェア工学, 丸善 (1992)
- [西脇 13] 西脇 真二 他：デジタルファブリケーション: 2. トポロジー最適化による構造創成設計, 情報処理, Vol. 54, No. 2, pp. 92–96 (2013)
- [倉橋 03] 倉橋 節也, 勝又 勇治, 寺野 隆雄：ベイジアン最適化手法と分布推定アルゴリズムの動向, 人工知能学会論文誌, Vol. 18, No. 5, pp. 487–494 (2003)
- [大村 13] 大村 平：実験計画と分散分析のはなし: 効率よい計画とデータ解析のコツ, 日科技連出版社 (2013)
- [田口 93] 田口 玄一：品質工学の定義とタグチメソッド, 品質工学, Vol. 1, No. 2, pp. 2–7 (1993)
- [畠塙 16] 畠塙 晃平, 瀧本 英二：オンライン予測, 講談社 (2016)
- [尾畠 00] 尾畠 貴信, 萩原 将文：感性を反映できるカラーポスター作成支援システム, 情報処理学会論文誌, Vol. 41, No. 3, pp. 701–710 (2000)
- [牧野 16] 牧野 貴樹, 濵谷 長史, 白川 真一, 浅田 稔, 麻生 英樹, 荒井 幸代, 飯間 等, 伊藤 真, 大倉 和博, 黒江 康明, 杉本 徳和, 坪井 祐太, 銀谷 賢治, 前田 新一, 松井 藤五郎, 南 泰浩, 宮崎 和光, 目黒 豊美, 森村 哲郎, 森本 淳, 保田 俊行, 吉本 潤一郎：これからの強化学習, 森北出版 (2016)
- [本村 12] 本村 陽一, 竹中 育, 石垣 司：サービス工学の技術: ビッグデータの活用と実践, 東京電機大学出版局 (2012)
- [本多 16] 本多 淳也, 中村 篤祥：バンディット問題の理論とアルゴリズム, 講談社 (2016)
- [柳浦 00] 柳浦 瞳憲, 茨木 俊秀：組合せ最適化問題に対するメタ戦略について, 電子情報通信

- 学会論文誌 D, Vol. 83, No. 1, pp. 3–25 (2000)
- [有沢 88] 有沢 誠：ソフトウェア工学, 岩波コンピュータサイエンス, 岩波書店 (1988)
- [龍野 16] 龍野 翔, 飯塚 修平, 松尾 豊：ウェブサイトのユーザ遷移に基づいたコンバージョン促進要因の抽出, 第 30 回人工知能学会全国大会論文集, Vol. 30, (2016)

発表文献

学会誌論文（査読あり）

- 田村 浩一郎, 上野山 勝也, 飯塚 修平, 松尾 豊. 深層学習を用いたアンサンブルモデルによる株主価値推定モデルの提案. 人工知能学会論文誌 (投稿中)
- 飯塚 修平, 濱野 将司, 川上 和也, 萩原 静厳, 川上 登福, 浜田 貴之, 松尾 豊. 閲覧・購買行動に着目した結婚情報サイトにおける商品間の勝敗関係の分析手法. 電子情報通信学会論文誌 D Vol.J99-D No.1, pp.109-118, 2016.
- 飯塚 修平, 松尾 豊. ウェブページ最適化問題の定式化と最適化手法の提案. 人工知能学会論文誌 Vol.29 No.5, p.460-468, 2014.
- 保住 純, 飯塚 修平, 中山 浩太郎, 高須 正和, 嶋田 絵理子, 須賀 千鶴, 西山 圭太, 松尾 豊. Webマイニングを用いたコンテンツ消費トレンド予測システム. 人工知能学会論文誌 Vol.29 No.5, p.449-459, 2014.

国際会議論文（査読あり）

- Shuhei Iitsuka**, Kazuya Kawakami, Seigen Hagiwara, Takayoshi Kawakami, Takayuki Hamada, and Yutaka Matsuo. Inferring Win–Lose Product Network from User Behavior. *In Proceedings of 2017 IEEE/WIC/ACM International Conference on Web Intelligence*, 2017.
- Shuhei Iitsuka** and Yutaka Matsuo. Website Optimization Problem and Its Solutions. *In Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp.447-456, 2015.

- Naoki Tani, Danushka Bollegala, Naiwala Chandrasiri, Keisuke Okamoto, Kazunari Nawa, **Shuhei Iitsuka**, and Yutaka Matsuo. Collaborative exploratory search in real-world context. In *Proceedings of the 20th ACM international conference on Information and knowledge management*, pp. 2137-2140, 2011.

国内発表

- **飯塚 修平**, 松尾 豊. バリエーションの提示がもたらす長期的効果に着目したウェブサイト最適化手法. 第 31 回人工知能学会全国大会. 2017.
- **飯塚 修平**, 松尾 豊. ウェブサイト最適化のためのバリエーション自動生成システム. 第 30 回人工知能学会全国大会. 2016.
- 龍野 翔, **飯塚 修平**, 松尾 豊. ウェブサイトのユーザ遷移に基づいたコンバージョン促進要因の抽出. 第 30 回人工知能学会全国大会. 2016.
- **飯塚 修平**, 松尾 豊. 高速なウェブサイト最適化のための KPI 設計手法の提案. 第 29 回人工知能学会全国大会. 2015.
- **飯塚 修平**, 松尾 豊. 高速なウェブページ最適化手法の提案. 第 28 回人工知能学会全国大会. 2014.
- **飯塚 修平**, 濱野 将司, 川上 和也, 松尾 豊, 萩原 静巖, 川上 登福, 浜田 貴之. ゼクシィ.net におけるユーザーの行動パターンの分析. 第 27 回人工知能学会全国大会. 2013.
- 保住 純, **飯塚 修平**, 中山 浩太郎, 高須 正和, 嶋田 絵理子, 須賀 千鶴, 西山 圭太, 松尾 豊. Web マイニングを用いたコンテンツ消費トレンド予測システム. 第 27 回人工知能学会全国大会. 2013.

解説記事

- **飯塚 修平**, 大澤 昇平, 松尾 豊. ウェブを用いた社会ネットワークの構築. 社会と調査. 2013.